

1
2
0
2
b
e
F
6
2

1
V
C
s
c

1
v
0
2
0
0
0
3
0
1
2
:
v
X
r
a

从自然语言监督中学习可迁移的视觉模型

亚历克·拉德福德^{*1} 钟·伍克·金^{*1} 克里斯·哈拉西¹ 阿迪亚·拉梅什¹ 加布里埃尔·高¹ 桑迪尼·阿加瓦尔¹ 吉里什·萨斯特里¹ 阿曼达·阿斯克尔¹ 帕梅拉·米什金¹ 杰克·克拉克¹ 格雷琴·克鲁格¹ 伊利亚·苏茨克弗¹

摘要

最先进的计算机视觉系统经过训练，能够预测一组固定的预定对象类别。这种受限的监督形式限制了其通用性和实用性，因为需要额外的标注数据来指定任何其他视觉概念。直接从关于图像的原始文本中学习是一种有前景的替代方案，它利用了更广泛的监督来源。我们证明，预测哪段文字描述与哪张图像相匹配这一简单的预训练任务，是一种高效且可扩展的方法，能够从互联网收集的4亿（图像，文本）对数据集中从头开始学习最先进的图像表示。预训练后，自然语言被用来引用已学习的视觉概念（或描述新的概念），从而实现模型在下游任务上的零样本迁移。我们通过在30多个不同的现有计算机视觉数据集上进行基准测试来研究这种方法的性能，涵盖的任务包括OCR、视频中的动作识别、地理定位以及多种类型的细粒度对象分类。该模型在大多数任务上都能实现非平凡的迁移，且通常无需任何数据集特定训练即可与全监督基线相竞争。例如，我们在ImageNet上零样本匹配了原始ResNet-50的准确率，而无需使用其训练所依赖的128万个训练样本中的任何一个。我们在<https://github.com/OpenAI/CLIP>发布了代码和预训练模型权重。

1. 引言与动机工作

直接从原始文本中学习的预训练方法在过去几年里彻底改变了自然语言处理领域 (Dai & Le, 2015; Peters等人, 2018; Howard & Ruder, 2018; Radford等人, 2018; Devlin等人, 2018; Raffel等人, 2019)。

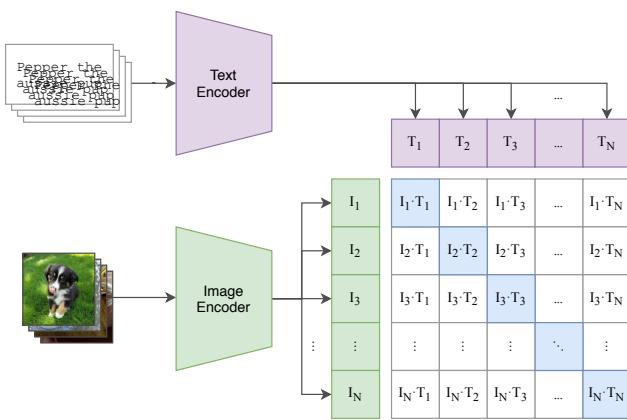
诸如自回归和掩码语言建模这类任务无关的目标，已在计算量、模型容量和数据规模上跨越多个数量级扩展，持续推动能力提升。“文本到文本”作为一种标准化输入输出接口的发展 (McCann等人, 2018; Radford等人, 2019; Raffel等人, 2019)，使得任务无关架构能够零样本迁移至下游数据集，无需专用输出头或针对特定数据集的定制。像GPT-3 (Brown等人, 2020) 这样的旗舰系统，如今在众多任务上与定制模型表现相当，却几乎不需要特定于数据集的训练数据。

这些结果表明，现代预训练方法在网络规模文本集合中可获得的总体监督超过了高质量众包标注的NLP数据集。然而，在其他领域如计算机视觉中，使用众包标注数据集（如ImageNet (Deng等, 2009)）预训练模型仍是标准做法。直接从网络文本中学习的大规模预训练方法能否在计算机视觉领域带来类似突破？先前的研究给出了积极信号。

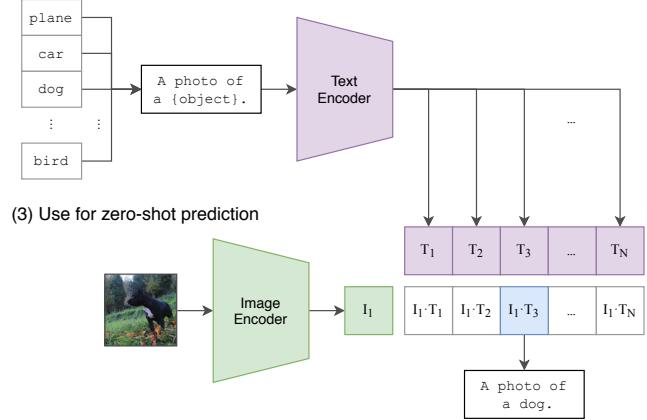
20多年前，Mori等人（1999年）通过训练模型预测与图像配对的文本文档中的名词和形容词，探索了改进基于内容的图像检索方法。Quattoni等人（2007年）证明，在预测图像相关标题中单词的分类器权重空间中进行流形学习，可以获得数据效率更高的图像表示。Srivastava与Salakhutdinov（2012年）通过在低级图像和文本标签特征上训练多模态深度玻尔兹曼机，深入探索了深度表示学习。Joulin等人（2016年）将这一研究方向现代化，并证明训练CNN预测图像标题中的单词能学习到有用的图像表示。他们将YFCC100M数据集（Thomee等人, 2016年）中图像的标题、描述和标签元数据转化为词袋多标签分类任务，表明用AlexNet (Krizhevsky等人, 2012年) 预训练预测这些标签所学习的表示，在迁移任务上的表现与基于ImageNet的预训练相当。随后，Li等人（2017年）将此方法扩展到预测短语n-gram及单个单词，并展示了其系统向其他图像任务的零样本迁移能力。

^{*}Equal contribution ¹OpenAI, San Francisco, CA 94110, USA.
Correspondence to: <{alec, jongwook}@openai.com>.

(1) Contrastive pre-training



(2) Create dataset classifier from label text



(3) Use for zero-shot prediction

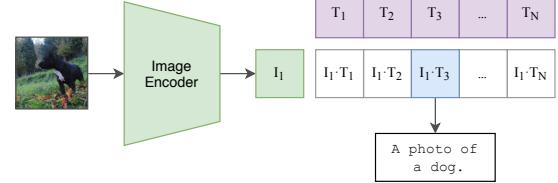


图1. 方法概述。标准图像模型通过联合训练图像特征提取器和线性分类器来预测某些标签，而CLIP则联合训练图像编码器和文本编码器，以预测一批（图像，文本）训练样本的正确配对。在测试阶段，学习到的文本编码器通过嵌入目标数据集类别的名称或描述，合成一个零样本线性分类器。

通过基于已学习的视觉n-gram词典对目标类别进行评分，并预测得分最高的类别，从而应用于分类数据集。采用更现代的架构和预训练方法，VirTex (Desai & Johnson, 2020)、ICMLM (Bulent Sariyildiz等人, 2020) 和ConVIRT (Zhang等人, 2020) 最近展示了基于Transformer的语言建模、掩码语言建模以及对比目标在从文本中学习图像表征方面的潜力。

尽管作为概念验证令人振奋，但利用自然语言监督进行图像表征学习仍属罕见。这很可能是因为在常见基准测试中展现的性能远低于其他方法。例如，Li等人 (2017) 在零样本设置下仅达到11.5%的ImageNet准确率，远低于当前最佳水平 (Xie等人, 2020) 的88.4%，甚至不及传统计算机视觉方法 (Deng等人, 2012) 50%的准确率。相反，范围更窄但针对性更强的弱监督应用提升了性能：Mahajan等人 (2018) 证明，预测Instagram图像上与ImageNet相关的标签是一项有效的预训练任务，经ImageNet微调后，这些预训练模型的准确率提升了5%以上，刷新了当时的最高水平。Kolesnikov等人 (2019) 和Dosovitskiy等人 (2020) 也通过预训练模型预测噪声标记的JFT-300M数据集类别，在更广泛的迁移基准测试中实现了显著提升。

这一研究方向代表了当前在从有限的有监督“黄金标签”学习与从几乎无限的原始文本学习之间所采取的实用折中方案。然而，这并非没有妥协——

这两项工作都精心设计并在过程中将监督类别分别限制在1000和18291类。自然语言凭借其通用性，能够表达并监督更广泛的视觉概念集合。两种方法还都采用静态softmax分类器进行预测，缺乏动态输出的机制。这严重削弱了它们的灵活性，并限制了其“零样本”能力。

这些弱监督模型与近期直接从自然语言学习图像表示的探索之间，一个关键差异在于规模。Mahajan等人 (2018) 和Kolesnikov等人 (2019) 的模型在数百万至数十亿图像上进行了加速器年量级的训练，而VirTex、ICMLM和ConVIRT仅在十万到二十万图像上进行了加速器天量级的训练。本研究中，我们弥合了这一差距，系统考察了在大规模自然语言监督下训练的图像分类器行为。得益于互联网上公开的海量此类数据，我们构建了一个包含4亿（图像，文本）对的新数据集，并证明ConVIRT的简化版本——我们称之为CLIP（对比语言-图像预训练）——是一种从自然语言监督中学习的高效方法。通过训练横跨近2个数量级计算规模的8个模型，我们研究了CLIP的可扩展性，发现其迁移性能与计算量呈平滑可预测的函数关系 (Hestness等人, 2017; Kaplan等人, 2020)。我们发现CLIP与GPT系列类似，在预训练过程中能学习执行广泛任务，包括OCR、地理定位、动作识别等。我们通过在30多个现有数据集上测试CLIP的零样本迁移性能来量化这一能力，并观察到

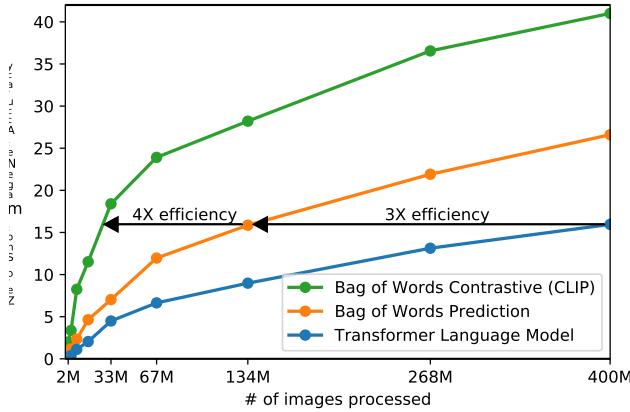


图2. 在零样本迁移任务中，CLIP的效率远超我们的图像描述基线模型。尽管基于Transformer的语言模型表现力极强，但我们发现其在零样本ImageNet分类任务上相对较弱。此处可见，其学习速度比预测文本词袋编码（BoW）的基线模型（Joulin等人，2016）慢3倍。而将预测目标替换为CLIP的对比学习目标后，效率又进一步提升了4倍。

它可以与之前针对特定任务的监督模型相竞争。我们还通过线性探针表征学习分析验证了这些发现，并表明CLIP不仅超越了当前公开可用的最佳ImageNet模型，同时计算效率更高。此外，我们发现零样本CLIP模型比同等准确度的监督式ImageNet模型具有更强的鲁棒性，这表明对任务无关模型进行零样本评估更能代表模型的真实能力。这些结果具有重大的政策与伦理意义，我们将在第7节对此进行探讨。

2. 方法

2.1. 自然语言监督

我们方法的核心在于从自然语言所含的监督信息中学习感知能力。如引言所述，这并非全新理念，然而该领域研究使用的术语却五花八门，甚至看似矛盾，且提出的动机也各不相同。张等人（2020）、戈麦斯等人（2017）、乔林等人（2016）以及德赛与约翰逊（2020）都提出了从图文配对数据中学习视觉表征的方法，却分别将其方法描述为无监督、自监督、弱监督和有监督。

我们强调，这一系列工作的共同点不在于所采用具体方法的细节，而在于对自然语言作为一种训练信号的重视。所有这些方法都在从*natural language super*-中学习

*vision*尽管早期研究在使用主题模型和n-gram表示时曾与自然语言的复杂性角力，但深度上下文表征学习的进步表明，我们现在已掌握有效利用这一丰富监督来源的工具（McCann等人，2017）。

从自然语言中学习相比其他训练方法具有几项潜在优势。与图像分类的标准众包标注相比，自然语言监督更容易扩展，因为它不需要将标注转换为经典的“机器学习兼容格式”，例如规范的1-of-N多数投票“黄金标签”。相反，基于自然语言的方法可以从互联网海量文本中 *passively* 获取监督信息进行学习。相较于大多数无监督或自监督学习方法，自然语言学习还有一个重要优势：它不仅学习表征，还将该表征与语言连接起来，从而实现灵活的零样本迁移。在接下来的小节中，我们将详细阐述我们所采用的具体方法。

2.2. 创建足够大的数据集

现有研究主要使用了三个数据集：MS-COCO（Lin等人，2014年）、Visual Genome（Krishna等人，2017年）和YFCC100M（Thomee等人，2016年）。虽然MS-COCO和Visual Genome是高质量的众包标注数据集，但以现代标准来看规模较小，各自仅包含约10万张训练照片。相比之下，其他计算机视觉系统的训练数据可达35亿**billion**张Instagram照片（Mahajan等人，2018年）。拥有1亿张照片的YFCC100M是一个潜在替代选项，但其每张图像的元数据稀疏且质量参差不齐。许多图像使用自动生成的文件名（如20160716_113957.JPG）作为“标题”，或包含相机曝光设置的“描述”。经过筛选仅保留带有英文自然语言标题和/或描述的图像后，数据集规模缩减至原来的1/6，仅剩1500万张照片，与ImageNet的规模大致相当。

自然语言监督的一个主要动机在于互联网上公开可获取的此类数据量极为庞大。由于现有数据集未能充分体现这一可能性，仅基于它们评估结果会低估该研究方向的潜力。为解决这一问题，我们从互联网各类公开资源中构建了一个包含4亿（图像，文本）对的新数据集。为了尽可能覆盖广泛的视觉概念，在构建过程中我们搜索了文本部分包含50万个查询词集中任意一词的（图像，文本）对¹。我们大致分类

¹The base query list is all words occurring at least 100 times in the English version of Wikipedia. This is augmented with bi-grams

通过每个查询包含最多20,000个（图像，文本）对来平衡结果。最终得到的数据集在总词数上与用于训练GPT-2的WebText数据集相当。我们将此数据集称为WIT，即WebImageText。

2.3. 选择高效的预训练方法

最先进的计算机视觉系统需要消耗极其庞大的计算资源。Mahajan等人（2018年）训练其ResNeXt101-32x48d模型耗费了19个GPU年，而Xie等人（2020年）训练Noisy Student EfficientNet-L2则消耗了33个TPUv3核心年。考虑到这两个系统仅训练用于预测1000个ImageNet类别，从自然语言中学习开放视觉概念集的任务显得尤为艰巨。在我们的探索过程中，我们发现训练效率是成功扩展自然语言监督的关键，并基于这一指标选定了最终的预训练方法。

我们最初的方法与VirTex类似，联合训练了一个图像CNN和文本transformer，从头开始预测图像的标题。然而，我们发现这种方法难以高效扩展。图2显示，一个拥有6300万参数的transformer语言模型（其计算量已是ResNet-50图像编码器的两倍）学习识别ImageNet类别的速度，比预测相同文本词袋编码的简单基线方法慢了足足三倍。

这两种方法有一个关键的共同点：它们都试图预测每张图片所附文本中的 $exact$ 个词汇。由于与图片共现的描述、评论及相关文本种类繁多，这一任务颇具挑战性。近期图像对比表征学习的研究发现，对比目标能比等效的预测目标学习到更优的表征（Tian等人，2019）。另有研究表明，尽管图像的生成模型可以学到高质量的图像表征，但其计算需求比同等性能的对比模型高出超过一个数量级（Chen等人，2020a）。基于这些发现，我们尝试训练一个系统来解决可能更简单的代理任务——仅预测文本 $as a whole$ 与哪张图片配对，而非预测文本的具体词汇。从相同的词袋编码基线出发，我们将图2中的预测目标替换为对比目标后，观察到ImageNet零样本迁移效率进一步提升达4倍。

给定一批 N （图像、文本）对，CLIP的训练目标是预测批次中 $N \times N$ 种可能的（图像，文本）配对哪些实际发生。为此，CLIP学习了一个

with high pointwise mutual information as well as the names of all Wikipedia articles above a certain search volume. Finally all WordNet synsets not already in the query list are added.

通过联合训练图像编码器和文本编码器，构建多模态嵌入空间，旨在最大化批次中 N 真实配对图像与文本嵌入的余弦相似度，同时最小化 $N^2 - N$ 错误配对嵌入的余弦相似度。我们基于这些相似度得分优化对称交叉熵损失。图3中，我们提供了CLIP实现核心部分的伪代码。据我们所知，这种批次构建技术和目标最初由*multi-class N-pair loss*Sohn（2016）在深度度量学习领域提出，后被Oord等人（2018）以InfoNCE损失的形式推广至对比表征学习，最近Zhang等人（2020）在医学影像领域将其适配于（文本，图像）对比表征学习。

由于预训练数据集的规模庞大，过拟合并非主要问题，因此CLIP的训练细节相较于Zhang等人（2020）的实现有所简化。我们从头开始训练CLIP，既未使用ImageNet权重初始化图像编码器，也未采用预训练权重初始化文本编码器。我们移除了表示空间与对比嵌入空间之间的非线性投影层——该设计由Bachman等人（2019）提出并经Chen等人（2020b）推广——仅保留线性投影将各编码器的表示映射到多模态嵌入空间。两个版本在训练效率上未见显著差异，我们推测非线性投影可能仅在与当前图像细节共同适应时，才在自监督表示学习方法中发挥作用。我们还移除了Zhang等人（2020）的文本变换函数 t_u （该函数从文本中均匀采样单句），因为CLIP预训练数据集中的多数（图像，文本）对本身已是单句形式。图像变换函数 t_v 也得到简化：训练时仅采用对缩放图像随机截取方形区域这一种数据增强方式。最后，控制softmax中logits范围的温度参数 τ 在训练时直接作为对数参数化的乘法标量进行优化，以避免其成为需调校的超参数。

2.4. 模型选择与缩放

我们考虑两种不同的图像编码器架构。第一种采用ResNet-50（He等，2016a）作为基础架构，因其广泛采用且性能可靠。我们对原版进行了多项改进：应用了He等（2019）提出的ResNet-D优化方案，以及Zhang（2019）的抗锯齿rect-2模糊池化技术。同时，我们将全局平均池化层替换为注意力池化机制。该注意力池化通过单层“类Transformer”多头QKV注意力实现，其中查询向量以全局平均池化特征为条件 $\{v^*\}$ 。

```

# image_encoder - ResNet or Vision Transformer
# text_encoder - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, 1] - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T) #[n, d_t]

# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)

# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss = (loss_i + loss_t)/2

```

图3. CLIP实现核心部分的类Numpy伪代码。

图像的表示。对于第二种架构，我们实验了最近提出的视觉变换器（ViT）（Dosovitskiy等人，2020）。我们严格遵循其实现，仅做了微小调整：在变换器前对合并的补丁和位置嵌入添加了一层额外的归一化，并采用了稍有不同的初始化方案。

文本编码器采用Transformer架构（Vaswani等人，2017年），并根据Radford等人（2019年）的描述进行了结构调整。基础模型规模为6300万参数、12层、512宽度、配备8个注意力头。该Transformer处理的是经过小写处理的字节对编码（BPE）文本表示，词汇表规模为49,152（Sennrich等人，2015年）。出于计算效率考虑，最大序列长度被限制在76个标记。文本序列以[SOS]和[EOS]标记为边界，并将Transformer最高层在[EOS]标记处的激活值作为文本特征表示——该特征会先经过层归一化处理，再线性投影至多模态嵌入空间。文本编码器中采用了掩码自注意力机制，以保留加载预训练语言模型或将语言建模作为辅助目标的能力，但相关探索留待未来工作。

以往的计算机视觉研究通常通过单独增加宽度（Mahajan等人，2018）或深度（He等人，2016a）来扩展模型，而对于ResNet图像编码器，我们采用了Tan & Le（2019）的方法，该方法发现将额外计算资源均衡分配给宽度、深度和分辨率三个维度，其效果优于仅将其分配给单一维度。

模型的一个维度。虽然Tan & Le（2019）针对其EfficientNet架构调整了各维度间的计算资源分配比例，但我们采用了一个简单的基线方案——将额外计算资源均等地用于增加模型的宽度、深度和分辨率。对于文本编码器，我们仅按比例扩展其宽度，使其与ResNet宽度的计算增量保持一致，而完全不调整深度。这是因为我们发现CLIP的性能对文本编码器容量的变化较为不敏感。

2.5. 训练

我们训练了5个ResNet系列模型和3个Vision Transformer模型。对于ResNet，我们训练了ResNet-50、ResNet-101，以及另外3个采用EfficientNet风格模型缩放、计算量分别约为ResNet-50的4倍、16倍和64倍的模型，分别记为RN50x4、RN50x16和RN50x64。对于Vision Transformer，我们训练了ViT-B/32、ViT-B/16和ViT-L/14。所有模型均训练32个周期。我们采用Adam优化器（Kingma & Ba, 2014），并对非增益或偏置的所有权重应用解耦权重衰减正则化（Loshchilov & Hutter, 2017），学习率通过余弦调度衰减（Loshchilov & Hutter, 2016）。初始超参数通过在基线ResNet-50模型上进行1周期训练时的网格搜索、随机搜索和手动调参组合设定。由于计算限制，更大模型的超参数采用启发式调整。可学习的温度参数 τ 初始化为相当于0.07的值（Wu等，2018），并进行截断以防止对数its缩放超过100倍——我们发现这对避免训练不稳定是必要的。我们使用了非常大的小批量尺寸32,768。采用混合精度（Micikevicius等，2017）加速训练并节省内存。为进一步节省内存，使用了梯度检查点（Griewank & Walther, 2000；Chen等，2016）、半精度Adam统计量（Dhariwal等，2020）以及经随机舍入的半精度文本编码器权重。嵌入相似度计算也进行了分片处理，各GPU仅计算其本地嵌入批次所需的成对相似度子集。最大的Net模型RN50x64在592块V100 GPU上训练了18天，而最大的Vision Transformer在256块V100 GPU上训练了12天。对于ViT-L/14，我们还以更高336像素分辨率预训练了额外1个周期以提升性能，类似FixRes（Touvron等，2019）。我们将该模型记为ViT-L/14@336px。除非另有说明，本文中所有标注为“CLIP”的结果均使用该性能最佳的模型。

3. 实验

3.1. 零样本迁移

3.1.1. 动机

在计算机视觉领域，零样本学习通常指图像分类中对未见物体类别的泛化研究 (Lampert等, 2009)。我们则以更广义的视角使用该术语，研究对未见数据集的泛化能力。这源于我们将此视为执行未见任务的代理目标，正如Larochelle等 (2008) 在零数据学习论文中所倡导的。尽管无监督学习领域的许多研究聚焦于机器学习系统的*representation learning*能力，我们提出将零样本迁移研究作为衡量机器学习系统*task-learning*能力的手段。从这个角度看，数据集评估的是特定分布上的任务表现。然而，许多主流计算机视觉数据集最初是研究社区为引导通用图像分类方法发展而创建的基准，而非针对具体任务的性能测量。虽然可以说SVHN数据集衡量的是谷歌街景照片分布上的门牌号转录任务，但CIFAR-10数据集测量的“真实”任务却难以界定。不过CIFAR-10的数据来源分布是明确的——TinyImages (Torralba等, 2008)。对于这类数据集，零样本迁移更多是评估CLIP对分布偏移和领域泛化的鲁棒性，而非任务泛化能力。相关分析详见第3.3节。

据我们所知，Visual N-Grams (Li等人, 2017年) 首次以上述方式研究了向现有图像分类数据集的零样本迁移。这也是我们已知的唯一另一项工作，它利用通用预训练模型研究了向标准图像分类数据集的零样本迁移，并成为理解CLIP的最佳参照点。该方法学习了包含142,806个视觉n-gram（涵盖1至5元语法）词典的参数，并采用差分版Jelinek-Mercer平滑算法优化这些n-gram，以最大化给定图像所有文本n-gram的概率。为实现零样本迁移，他们首先将数据集中每个类名的文本转换为n-gram表示，然后根据其模型计算概率，最终预测得分最高的类别。

我们专注于研究零样本迁移作为任务学习评估的灵感，源于自然语言处理领域展示任务学习的工作。据我们所知，Liu等人 (2018年) 首次将任务学习识别为一种“意外副作用”——当训练用于生成维基百科文章的语言模型学会了在不同语言间可靠地音译名称时。虽然GPT-1 (Radford等人, 2018年) 着重于预

作为一种提升监督微调效果的迁移学习方法进行训练时，该研究还包含了一项消融实验，证明四种启发式零样本迁移方法的性能在预训练过程中稳步提升，无需任何监督适配。这一分析为GPT-2 (Radford等人, 2019年) 奠定了基础，后者专注于通过零样本迁移{ v^* }来研究语言模型的任务学习能力。

3.1.2. 使用CLIP进行零样本迁移

CLIP经过预训练，能够预测其数据集中图像与文本片段是否配对。为了实现零样本分类，我们复用这一能力。针对每个数据集，我们将所有类别名称作为潜在文本配对集合，并依据CLIP预测最可能的（图像，文本）配对。具体而言，首先通过各自的编码器计算图像特征嵌入和所有可能文本的特征嵌入。随后计算这些嵌入的余弦相似度，通过温度参数 τ 进行缩放，并经由softmax归一化为概率分布。需注意，该预测层是一个多项式逻辑回归分类器，具有L2归一化的输入、L2归一化的权重、无偏置项及温度缩放特性。如此解读时，图像编码器是计算图像特征表示的计算机视觉骨干网络，而文本编码器则是一个超网络 (Ha等人, 2016)，它根据描述类别视觉概念的文本来生成线性分类器的权重。Lei Ba等人 (2015) 首次提出了这种形式的零样本图像分类器，而基于自然语言生成分类器的构想至少可追溯至Elhoseiny等人 (2013)。延续这一解读，CLIP预训练的每个步骤都可视为优化一个随机创建的代理计算机视觉数据集的性能，该数据集每类仅含1个样本，且通过自然语言描述定义了总计32,768个类别。在零样本评估阶段，我们会在文本编码器计算出零样本分类器后将其缓存，并复用于所有后续预测。这使得生成分类器的成本可分摊至数据集中所有预测任务上。

3.1.3. 与视觉N元语法的初步比较

在表1中，我们将Visual N-Grams与CLIP进行了比较。最佳CLIP模型将ImageNet上的准确率从概念验证阶段的11.5%提升至76.2%，且在不使用该数据集128万张众包标注训练样本的情况下，达到了原始ResNet-50的性能水平。此外，CLIP模型的top-5准确率显著高于其top-1准确率，该模型的top-5准确率达到95%，与Inception-V4 (Szegedy等人, 2016年) 持平。这种在零样本设定下与强监督基线性能相匹配的能力表明

	aYahoo	ImageNet	SUN
Visual N-Grams	72.4	11.5	23.0
CLIP	98.4	76.2	58.5

表1. 将CLIP与先前零样本迁移图像分类结果进行对比。CLIP在全部三个数据集上均实现了大幅性能提升。这一进步反映了自Visual N-Grams (Li等人, 2017) 开发以来四年间的诸多差异。

CLIP是迈向灵活实用零样本计算机视觉分类器的重要一步。如前所述, 与Visual N-Grams的比较旨在为CLIP的性能提供背景参照, 不应被解读为两者方法间的直接对比, 因为两个系统间许多影响性能的差异因素并未得到控制。例如, 我们使用的训练数据集规模大10倍, 采用的视觉模型每次预测所需的计算量高出近100倍, 训练总计算量可能超过其1000倍, 并且使用了Visual N-Grams发布时尚未出现的基于Transformer的架构。为进行更贴近的对比, 我们在Visual N-Grams训练所用的相同YFCC100M数据集上训练了CLIP ResNet-50模型, 发现其仅需一个V100 GPU日的训练即能达到他们报告的ImageNet性能水平。该基线模型也是完全从头开始训练, 而非像Visual N-Grams那样采用预训练ImageNet权重进行初始化。

CLIP在其他两个报告的数据集上也表现优于Visual N-Grams。在aYahoo上, CLIP实现了错误数量减少95%的显著提升; 而在SUN数据集上, 其准确率更是Visual N-Grams的两倍多。为了进行更全面的分析和压力测试, 我们实施了附录A中详述的大规模评估方案, 将评估范围从Visual N-Grams报告的3个数据集扩展至30余个数据集, 并与50多个现有计算机视觉系统进行对比, 从而对结果进行更全面的背景化解读。

3.1.4. 提示工程与集成

大多数标准的图像分类数据集将用于命名或描述类别的信息——这些信息支持基于自然语言的零样本迁移——视为事后补充。绝大多数数据集仅用标签的数字ID来标注图像, 并包含一个将这些ID映射回英文名称的文件。有些数据集, 如Flowers102和GTSRB, 在其发布版本中似乎完全未包含此类映射, 从而彻底阻碍了零样本迁移的实现。²对于许多数据集, 我们观察到这些标签可能

²Alec learned much more about flower species and German traffic signs over the course of this project than he originally anticipated.

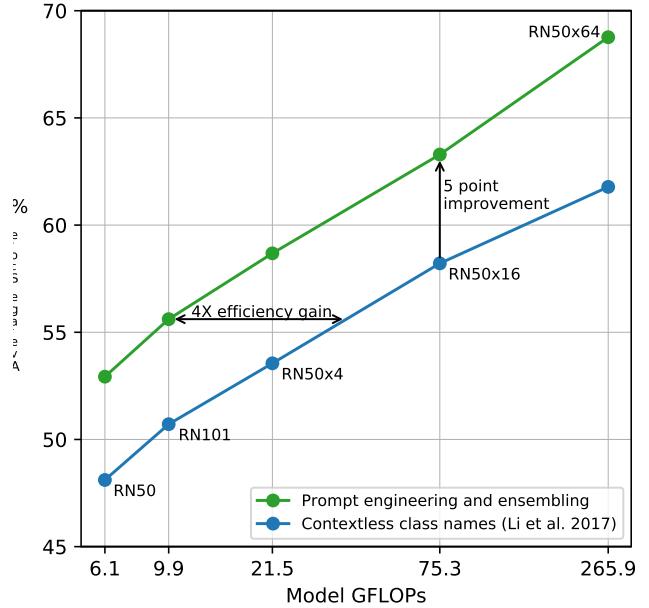


图4. 提示工程与集成方法提升零样本性能。相较于使用无上下文类别名称的基线方法, 提示工程与集成策略在36个数据集上平均将零样本分类性能提高了近5个百分点。这一改进效果类似于基线零样本方法增加4倍计算资源所获得的增益, 但在多次预测中分摊时, 这种提升是“免费”的。

选择有些随意, 并未预见到与零样本迁移相关的问题, 这种迁移依赖于任务描述才能成功实现。

一个常见问题是多义性。当类别名称是提供给CLIP文本编码器的唯一信息时, 由于缺乏上下文, 它无法区分词语的具体含义。在某些情况下, 同一单词的多个含义可能作为不同类别出现在同一数据集中! 例如ImageNet中既包含建筑起重机 (construction crane), 也包含会飞的鹤 (crane); 牛津-IIIT宠物数据集中的"boxer"类别, 根据上下文明显指犬种, 但对缺乏上下文的文本编码器而言, 同样可能指代运动员类型。

我们遇到的另一个问题是, 在预训练数据集中, 与图像配对的文本仅为单个单词的情况相对罕见。通常, 文本是以某种方式描述图像的完整句子。为了弥合这种分布差异, 我们发现使用提示模板“一张{标签}的照片。”是一个很好的默认选择, 有助于明确文本内容与图像相关。这种做法通常比仅使用标签文本的基线表现更优。例如, 仅采用这一提示就使ImageNet上的准确率提高了1.3%。

类似于围绕GPT-3的“提示工程”讨论(Brown等人, 2020; Gao等人, 2020), 我们也观察到, 通过为每个任务定制提示文本, 可以显著提升零样本性能。以下列举几个非穷尽的例子。在多个细粒度图像分类数据集上, 我们发现明确类别有助于提升效果。例如在Oxford-IIIT Pets数据集上, 使用“一张{标签}的照片, 一种宠物。”这样的提示来提供上下文效果良好。同样, 在Food101数据集上指定*a type of food*, 在FGVC Aircraft数据集上指定*a type of aircraft*也有帮助。对于OCR数据集, 我们发现将要识别的文本或数字用引号括起来能提高性能。最后, 在卫星图像分类数据集上, 明确说明图像属于此类形式并使用“一张{标签}的卫星照片。”的变体也取得了成效。

我们还尝试了通过集成多个零样本分类器作为另一种提升性能的方式。这些分类器通过使用不同的上下文提示生成, 例如“一张大{标签}的照片”和“一张小{标签}的照片”。我们选择在嵌入空间而非概率空间构建集成模型, 这样只需缓存一组平均后的文本嵌入向量, 使得集成计算成本在多次预测均摊后与使用单一分类器相当。实验表明, 集成多个生成的零样本分类器能稳定提升性能, 因此我们将其应用于大多数数据集。在ImageNet上, 我们集成了80种不同的上下文提示, 相比前述单一默认提示, 性能额外提升了3.5%。综合来看, 提示工程与集成策略共同将ImageNet准确率提高了近5%。图4直观展示了相较于Li等人(2017)直接嵌入类名的无上下文基线方法, 提示工程与集成如何改变一系列CLIP模型的性能表现。

3.1.5. 零样本CLIP性能分析

由于计算机视觉中任务无关的零样本分类器研究尚不充分, CLIP为深入理解此类模型提供了宝贵契机。本节我们将系统研究CLIP零样本分类器的各项特性。首要问题是探究零样本分类器的基本性能表现。为便于对照, 我们将其与一个简单的现成基线模型进行比较: 在经典ResNet-50特征上训练全监督、正则化的逻辑回归分类器。图5展示了27个数据集上的对比结果, 具体数据集设置详见附录A。

零样本CLIP略微超越这一基线更多——

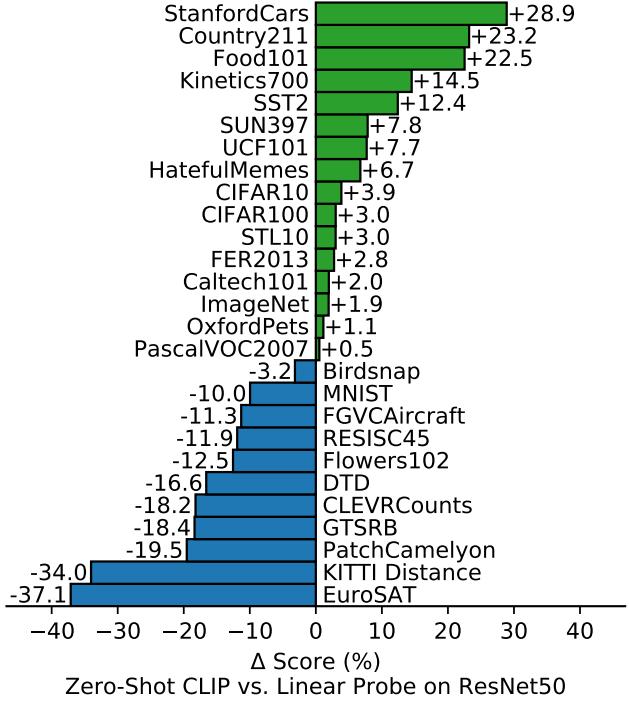


图5. 零样本CLIP与全监督基线模型表现相当。在涵盖27个数据集的评估套件中, 零样本CLIP分类器在包括ImageNet在内的16个数据集上超越了基于ResNet-50特征训练的全监督线性分类器。

在27个数据集中, 零样本CLIP在16个数据集上表现优于逻辑回归。深入分析单个数据集时, 我们发现了一些有趣的现象。在细粒度分类任务中, 模型性能差异显著: 在Stanford Cars和Food101这两个数据集上, 零样本CLIP比基于ResNet-50特征训练的逻辑回归高出20%以上; 而在Flowers102和FGVCAircraft上, 其表现却落后10%以上。OxfordPets和Birdsnap的数据结果则较为接近。我们认为这些差异主要源于WIT与ImageNet在不同任务上提供的监督信息量不同。“通用”物体分类数据集(如ImageNet、CIFAR10/100、STL10和PascalVOC2007)上, 两者性能较为接近, 但零样本CLIP均保持微弱优势。特别值得注意的是, 在STL10数据集上, CLIP以99.3%的准确率创造了新纪录——尽管完全没有使用任何训练样本。在视频动作识别领域的两个数据集中, 零样本CLIP显著超越ResNet-50: 在Kinetics700上领先14.5%, 在UCF101上领先7.7%。我们推测这是因为自然语言能为涉及动词的视觉概念提供更广泛的监督信号, 而ImageNet主要以名词为中心的物体监督为主。

观察零样本CLIP表现显著不佳的领域,

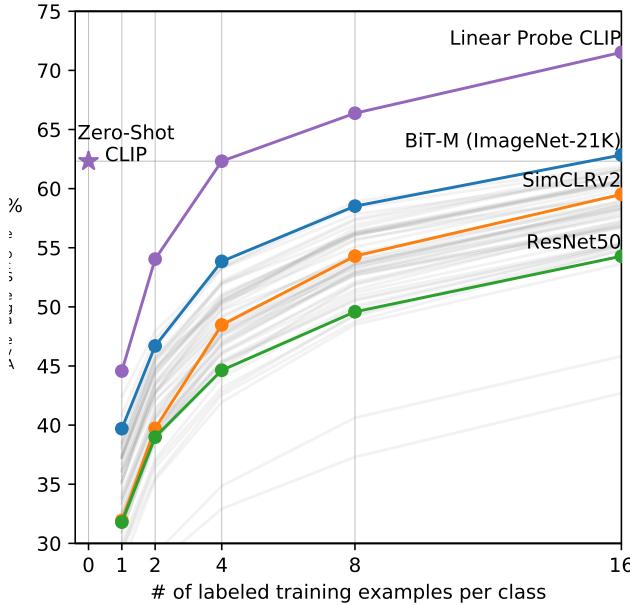


图6. 零样本CLIP超越少样本线性探针。零样本CLIP与在同一特征空间上训练的4样本线性分类器的平均性能相当，并几乎匹敌公开可用模型中16样本线性分类器的最佳结果。对于BiT-M和SimCLRv2，性能最佳的模型已高亮显示。浅灰色线条代表评估套件中的其他模型。本分析使用了每类至少含16个样本的20个数据集。

我们观察到，零样本CLIP在多项专业化、复杂或抽象任务上表现相当薄弱，例如卫星图像分类（EuroSAT和RESISC45）、淋巴结肿瘤检测（PatchCamelyon）、合成场景中的物体计数（CLEVRCounts），以及自动驾驶相关任务如德国交通标志识别（GTSRB）、判断最近车辆距离（KITTI Distance）。这些结果凸显了零样本CLIP在更复杂任务上的能力不足。相比之下，非专业人士却能稳健完成其中部分任务，如计数、卫星图像分类和交通标志识别，这表明模型仍有显著改进空间。但需谨慎的是，对于学习者毫无先验经验的困难任务（如几乎所有人类——可能包括CLIP——都未接触过的淋巴结肿瘤分类），衡量零样本迁移而非少样本迁移是否构成有意义的评估标准，目前尚不明确。

在将零样本性能与全监督模型进行比较时，可以理解CLIP的任务学习能力；而与少样本方法对比则更为直接，因为零样本正是其极限所在。图6中，我们直观展示了零样本CLIP如何与基于多种图像模型特征的少样本逻辑回归进行对比，这些模型包括当前公开可用的最佳ImageNet模型、自监督学习方法以及CLIP自身。虽然直观上

我们预期零样本表现会逊于单样本，但实际发现零样本CLIP在相同特征空间上的表现与4次逻辑回归相当。这很可能源于零样本与少样本方法间的关键差异。首先，CLIP的零样本分类器通过自然语言生成，使得视觉概念得以直接“传达”；而传统监督学习必须从训练样本中间接推断概念。缺乏上下文的基于示例的学习存在一个缺陷：许多不同假设都可能与数据相符，尤其是在单样本情况下。单张图像常包含多种视觉概念，尽管强大的学习者能利用视觉线索和启发式方法（如假设演示概念是图像中的主体对象），但这并无绝对保证。

解决零样本与小样本性能差异的一个潜在方案是，将CLIP的零样本分类器作为小样本分类器权重的先验。虽然向生成权重添加L2惩罚是这一思想的直接实现，但我们发现超参数优化往往会选择如此大的正则化值，以至于最终的小样本分类器“仅仅”等同于零样本分类器。探索如何更好地结合零样本迁移的优势与小样本学习的灵活性，是未来工作中一个极具前景的研究方向。

在将零样本CLIP与其他模型特征的少样本逻辑回归进行比较时，零样本CLIP大致匹配了我们评估套件中性能最佳的16样本分类器的表现，该分类器使用了在ImageNet-21K上训练的BiT-M ResNet-152x2的特征。我们确信，在JFT-300M上训练的BiT-L模型表现会更优，但这些模型尚未公开发布。BiT-M ResNet-152x2在16样本设置中表现最佳有些出人意料，因为如第3.2节所分析，在完全监督设置下，Noisy Student EfficientNet-L2在27个数据集上的平均表现要高出近5%。

除了研究零样本CLIP和少样本逻辑回归的平均表现外，我们还考察了在单个数据集上的性能。图7展示了在同一特征空间上，逻辑回归分类器需要多少每类标记样本才能达到零样本CLIP的性能水平。由于零样本CLIP同样属于线性分类器，这一对比估算了在此设定下零样本迁移的有效数据效率。为了避免训练成千上万个线性分类器，我们基于对数线性插值法进行估算：通过1、2、4、8、16样本（在可行情况下）及全监督线性分类器在各数据集上的表现，推算出零样本迁移的有效数据效率。研究发现零样本迁移能够 $\{v^*\}$

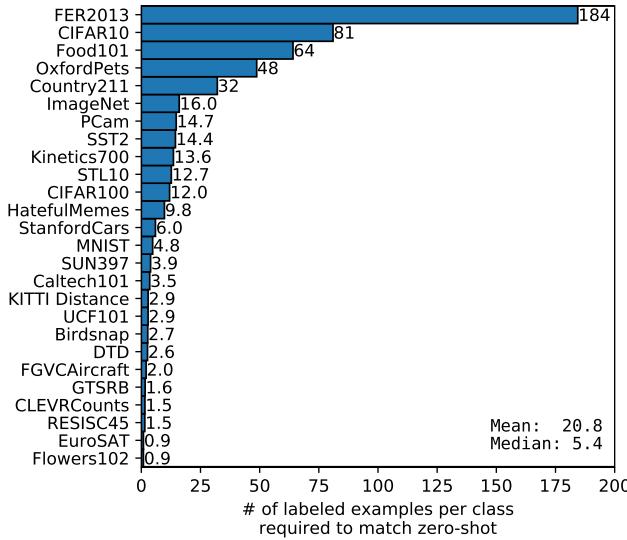


图7. 零样本迁移的数据效率差异显著。通过计算在同一CLIP特征空间上，线性分类器需要每个类别多少标注样本才能达到零样本分类器的性能，可以量化零样本迁移的有效性。数值基于1、2、4、8、16样本及全监督结果的半对数线性插值估算。性能差异范围极大——从两个数据集上仍低于单样本分类器，到匹配每个类别约184个标注样本的估计值。

不同数据集间的效率差异极大，每类所需的标注样本从不足1个到184个不等。Flowers102和EuroSAT这两个数据集的表现甚至不及单样本模型。半数数据集每类只需不到5个样本，中位数为5.4。但平均数据效率估计值为每类20.8个样本，这是因为有20%的数据集需要监督分类器为达到同等性能而消耗大量标注样本。在ImageNet上，零样本CLIP的性能与在同一特征空间训练的16样本线性分类器相当。

如果我们假设评估数据集足够大，使得在其上训练的线性分类器参数能够得到良好估计，那么由于CLIP的零样本分类器同样是一个线性分类器，全监督分类器的性能大致设定了零样本迁移所能达到的上限。在图8中，我们对比了CLIP的零样本性能与跨数据集的全监督线性分类器。虚线 $y = x$ 代表一个“最优”零样本分类器，其性能与对应的全监督分类器相当。对于大多数数据集，零样本分类器的性能仍比全监督分类器低10%至25%，这表明在提升CLIP的任务学习与零样本迁移能力方面仍有很大空间。

零样本性能与全监督性能之间存在0.82的正相关性（ $p < 10^{-6}$ ）。

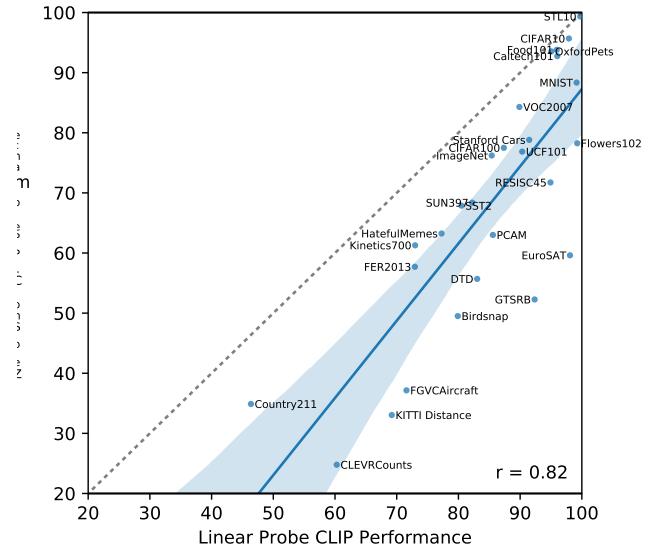


图8. 零样本性能与线性探针性能相关，但多数情况下仍非最优。跨数据集比较零样本与线性探针性能显示强相关性，零样本性能普遍低10至25个百分点。仅5个数据集中零样本性能接近线性探针性能 ($\{v^*\}$ 3个百分点差异)。

表现表明，CLIP在将底层表征与任务学习关联至零样本迁移时相对一致。然而，零样本CLIP仅在5个数据集上接近全监督性能：STL10、CIFAR10、Food101、OxfordPets和Caltech101。在这5个数据集中，零样本准确率和全监督准确率均超过90%。这意味着CLIP在底层表征质量较高的任务上，零样本迁移可能更为有效。通过线性回归模型预测零样本性能与全监督性能的关系，斜率显示全监督性能每提升1%，零样本性能相应提升1.28%。但95%置信区间仍包含小于1的值（0.93-1.79）。

过去几年间，深度学习系统的实证研究表明，其性能可依据训练计算量和数据集规模等关键指标进行预测（Hestness等人，2017；Kaplan等人，2020）。GPT系列模型迄今已展现出在训练计算量提升1000倍时，零样本性能持续提升的规律。图9中，我们验证了CLIP的零样本性能是否遵循类似的扩展规律。通过绘制5个ResNet CLIP模型在36个不同数据集上39项评估的平均错误率，发现当模型计算量增长44倍时，CLIP同样呈现出对数-对数线性扩展趋势。尽管整体趋势平稳，但个别评估任务的性能波动较大。我们尚不确定

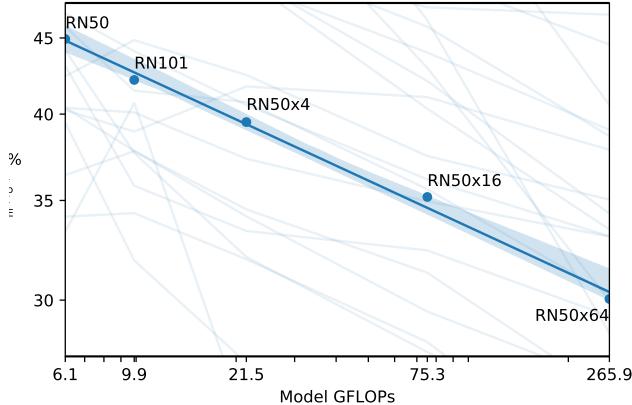


图9. 零样本CLIP性能随模型计算量呈平滑扩展趋势。在涵盖36个不同数据集的39次评估中，平均零样本错误率通过对数-对数线性趋势得到了良好建模，该趋势横跨5种不同CLIP模型、计算量相差44倍的范围。浅色线条表示单次评估的性能，显示出尽管整体趋势平滑，个体性能仍存在较大差异。

这是由于子任务间个别训练运行的高方差（如D'Amour等人（2020）所记载）掩盖了稳步提升的趋势，还是某些任务上的性能实际上并非随着计算量单调递增。

3.2. 表示学习

尽管我们在前一节中通过零样本迁移广泛分析了CLIP的任务学习能力，但更常见的是研究模型的表征学习能力。评估表征质量的方法多种多样，且对于“理想”表征应具备哪些特性也存在分歧（Locatello等人，2020）。在模型提取的表征上拟合线性分类器并测量其在各数据集上的性能是一种常用方法。另一种方式是测量模型端到端微调的性能。这增加了灵活性，先前研究已有力证明，在大多数图像分类数据集上，微调优于线性分类（Kornblith等人，2019；Zhai等人，2019）。虽然微调的高性能出于实用原因推动了对其研究，但我们仍选择基于线性分类器的评估，原因如下：我们的工作聚焦于开发一种高性能、与任务及数据集无关的预训练方法。微调由于在微调阶段会针对每个数据集调整表征，可能补偿并掩盖预训练阶段未能学习通用且鲁棒表征的缺陷。而线性分类器因其有限的灵活性，反而能凸显这些缺陷，为开发过程提供清晰反馈。对于CLIP，训练有监督的线性 $\{v^*\}$

分类器的另一个优势在于其方法与零样本分类器所采用的方法极为相似，这使得我们能够在第3.1节进行广泛的比较与分析。最后，我们的目标是将CLIP与一系列现有模型在多项任务上进行全面对比。研究27个不同数据集上的66种模型需要调整1782次不同的评估。微调开启了更大的设计和超参数空间，这使得公平评估变得困难，且计算成本高昂，难以比较多样化的技术集合，正如其他大规模实证研究中所讨论的（Lucic等人，2018；Choi等人，2019）。相比之下，线性分类器只需最少的超参数调整，并拥有标准化的实现和评估流程。更多评估细节请参阅附录A。

图10总结了我们的发现。为减少可能引发确认偏误或报告偏误的选择效应影响，我们首先在Kornblith等人（2019）提出的12个数据集评估套件上研究性能表现。虽然ResNet-50和ResNet-101等小型CLIP模型优于在ImageNet-1K上训练的其他ResNet（BiT-S及原始版本），但它们表现不及在ImageNet-21K上训练的ResNet（BiT-M）。这些小型CLIP模型也不如同等计算需求的EfficientNet系列模型。然而，CLIP训练的模型展现出优异的扩展性——我们训练的最大模型（ResNet-50x64）在综合得分和计算效率上均小幅超越现有最佳模型（Noisy Student EfficientNet-L2）。我们还发现CLIP视觉变换器的计算效率约为CLIP ResNets的3倍，这使我们在既定计算预算内实现了更高的整体性能。这些结果定性复现了Dosovitskiy等人（2020）的结论：当训练数据足够大时，视觉变换器比卷积网络具有更高计算效率。我们的最佳整体模型是ViT-L/14，该模型在我们的数据集上以336像素更高分辨率微调了1个额外周期，在此评估套件中平均超越现有最佳模型2.6%。

如图21定性所示，CLIP模型学习到的任务范围比以往从随机初始化端到端训练的单一计算机视觉模型所展示的更广。这些任务包括地理定位、光学字符识别、面部情绪识别以及动作识别。Kornblith等人（2019）的评估套件中并未涵盖这些任务。可以说，这反映了Kornblith等人（2019）研究中存在的一种选择偏差，偏向于与ImageNet重叠的任务。为解决这一问题，我们还采用了一个更广泛的27个数据集评估套件来衡量性能。该评估套件（附录A详述）包含代表上述任务的数据集、德国交通标志识别基准（Stallkamp等人，2011），以及从VTAB（Zhai等人，2019）改编的其他多个数据集。

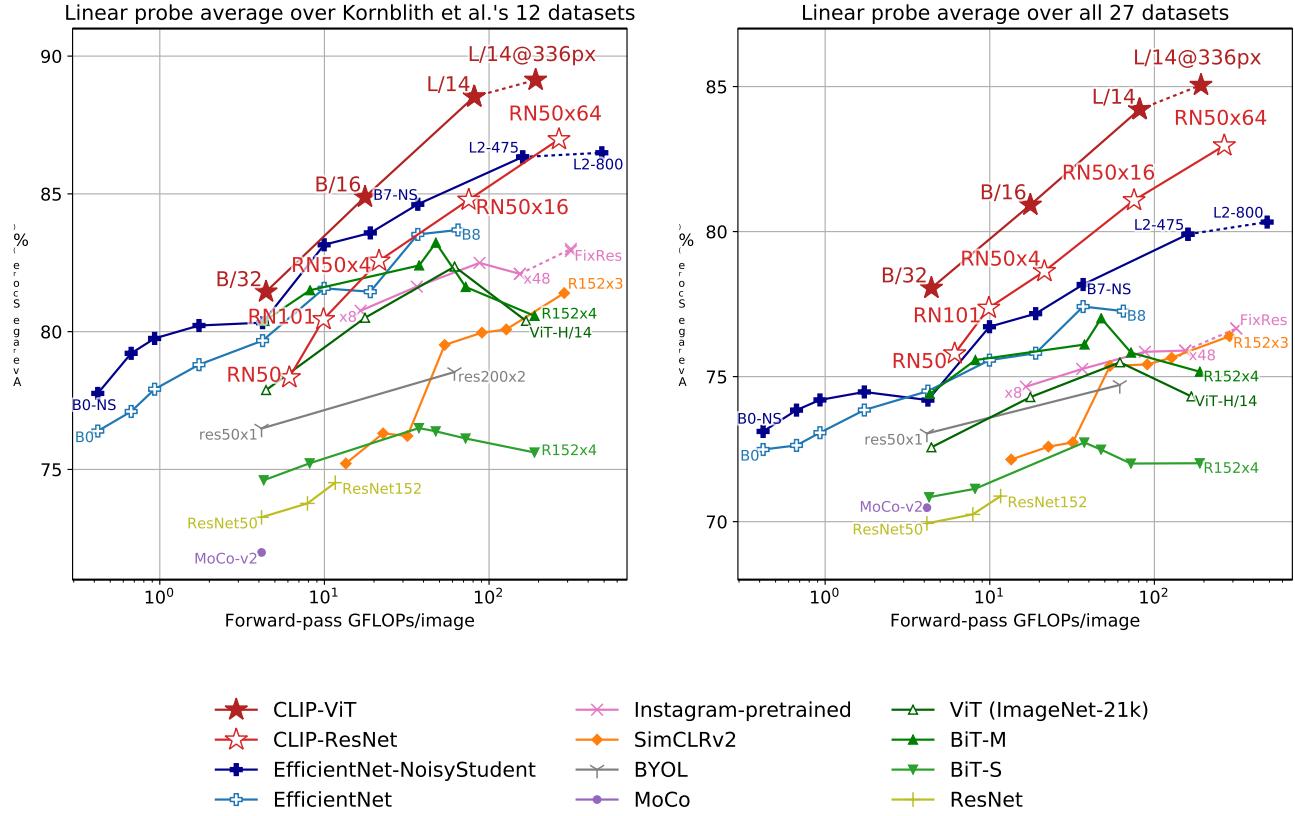


图10. CLIP模型与前沿计算机视觉模型的线性探针性能对比，包括EfficientNet (Tan & Le, 2019; Xie et al., 2020)、MoCo (Chen et al., 2020d)、Instagram预训练的ResNeXt模型 (Mahajan et al., 2018; Touvron et al., 2019)、BiT (Kolesnikov et al., 2019)、ViT (Dosovitskiy et al., 2020)、SimCLRv2 (Chen et al., 2020c)、BYOL (Grill et al., 2020) 以及原始ResNet模型 (He et al., 2016b)。(左)分数为Kornblith等人 (2019) 研究的12个数据集上的平均值。(右)分数为涵盖更广分布多样性的27个数据集上的平均值。虚线表示模型在高于预训练分辨率下进行微调或评估。各数据集具体分数见表10，各数据集性能曲线见图20。

在这个更广泛的评估套件中，CLIP的优势更为明显。所有CLIP模型，无论规模大小，在计算效率方面都优于所有被评估系统。最佳模型相对于先前系统的平均得分提升从2.6%增至5%。我们还发现，自监督系统在我们更广泛的评估套件中表现显著更优。例如，尽管SimCLRv2在Kornblith等人 (2019) 的12个数据集上平均仍逊色于BiT-M，但在我们的27个数据集评估套件中，SimCLRv2超越了BiT-M。这些发现表明，持续扩展任务多样性和覆盖范围有助于更好地理解系统的“通用”性能。我们认为，沿着VTAB路线开展更多评估工作将具有重要价值。

除了上述的总体分析外，我们还在图11中可视化了最佳CLIP模型与评估套件中最佳模型在全部27个数据集上的性能差异。CLIP在其中21个数据集上表现优于Noisy Student EfficientNet-L2模型。CLIP在需要OCR的任务（如SST2）上提升最为显著。

以及HatefulMemes）、地理定位与场景识别（Country2 11、SUN397），以及视频中的活动识别（Kinetics700 和UCF101）。此外，CLIP在细粒度汽车和交通标志识别（Stanford Cars和GTSRB）上也表现更优。这可能反映了ImageNet中监督信号过于狭窄的问题。例如GTSRB上14.7%的性能提升，或许暗示了ImageNet-1K的缺陷——该数据集对所有交通和街道标志仅使用单一标签。这种设定可能促使监督式表征压缩类内细节，从而损害细粒度下游任务的准确性。如前所述，CLIP在部分数据集上仍落后于EfficientNet。不出所料，EfficientNet相对CLIP优势最大的数据集正是其训练所用的ImageNet。在CIFAR10和CIFAR100等低分辨率数据集上，EfficientNet也略胜CLIP一筹。我们推测这至少部分源于CLIP缺乏基于尺度的数据增强。EfficientNet在PatchCamelyon和CLEVRCounts上的表现也稍好，这些数据集的整体性能仍...

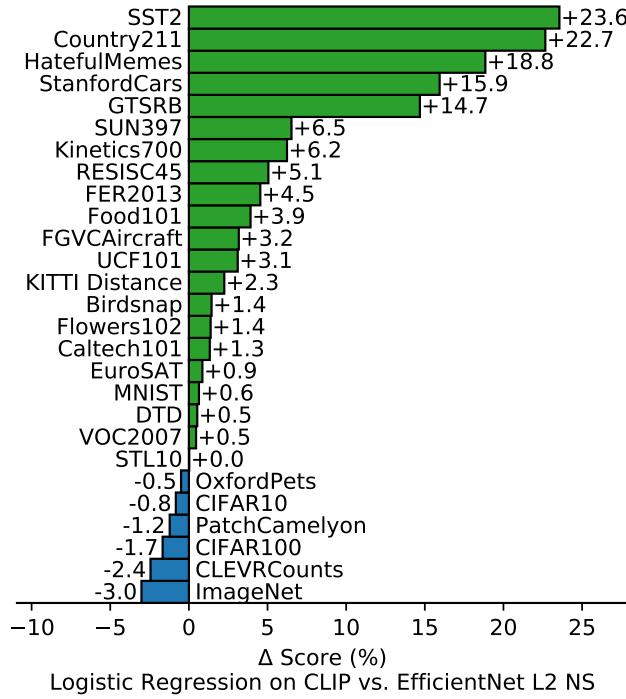


图11. CLIP的特征在多种数据集上表现优于最佳ImageNet模型的特征。在27个数据集中的21个上，基于CLIP特征拟合的线性分类器性能超越了使用Noisy Student EfficientNet-L2模型。

两种方法的 $\{v^*\}$ 都很低。

3.3. 对自然分布偏移的鲁棒性

2015年，有研究宣布深度学习模型在ImageNet测试集上的表现超越了人类水平（He等，2015）。然而经过多年的研究反复发现，这些模型仍会犯许多简单错误（Dodge & Karam, 2017; Geirhos等，2018; Alcorn等，2019）。针对这些系统的新基准测试往往显示，其性能远低于它们在ImageNet上的准确率及人类准确率（Recht等，2019; Barbu等，2019）。如何解释这种差异？研究者提出并探讨了多种观点（Ilyas等，2019; Geirhos等，2020）。这些解释的共同主题是：深度学习模型极其实擅长发现训练数据集中存在的相关性和模式，从而提升分布内性能。但其中许多相关性和模式实际是虚假的，并不适用于其他数据分布，导致在其他数据集上出现性能大幅下降。

我们提醒，迄今为止，这些研究大多将评估局限于在ImageNet上训练的模型。回顾讨论的主题，从这些初步发现过度泛化可能是一个错误。这些失败在多大程度上归因于深度学习、ImageNet，或是某些 $\{v^*\}$

两者的结合？CLIP模型通过在大规模数据集上采用自然语言监督进行训练，具备出色的零样本性能，这为我们从不同角度探究该问题提供了契机。

Taori等人（2020）近期开展了一项综合性研究，旨在量化和理解ImageNet模型在这些行为上的表现。Taori等人（2020）研究了ImageNet模型在*natural distribution shifts*评估时性能的变化情况。他们测量了模型在7种分布偏移数据集上的性能：ImageNet V2（Recht等人，2019）、ImageNet Sketch（Wang等人，2019）、Youtube-BB和ImageNet-Vid（Shankar等人，2019）、ObjectNet（Barbu等人，2019）、ImageNet Adversarial（Hendrycks等人，2019）以及ImageNet Rendition（Hendrycks等人，2020a）。这些数据集均由从不同来源收集的新图像构成，研究者将其与*synthetic distribution shifts*区分开来，例如ImageNet-C（Hendrycks & Dietterich, 2019）、风格化ImageNet（Geirhos等人，2018）或对抗攻击（Goodfellow等人，2014）——这些数据集是通过以各种方式扰动现有图像生成的。他们提出这一区分部分是因为发现，尽管已有多种技术被证明能提升模型在合成分布偏移上的性能，但这些技术往往无法在自然分布上带来一致的改进。³

在这些收集的数据集中，ImageNet模型的准确率远低于ImageNet验证集设定的预期水平。在接下来的总结讨论中，除非另有说明，我们将报告所有7个自然分布偏移数据集上的平均准确率，以及ImageNet相应类别子集的平均准确率。此外，对于Youtube-BB和ImageNet-Vid这两个具有不同评估设置的数据集，我们采用pm-0和pm-10准确率的平均值。

ResNet-101在这些自然分布偏移上的评估错误率是ImageNet验证集的5倍。然而令人鼓舞的是，Taori等人（2020）发现，分布偏移下的准确率会随着ImageNet准确率的提升而呈现可预测的增长，并且可以通过对数几率变换后的准确率线性函数很好地建模。Taori等人（2020）利用这一发现提出，鲁棒性分析应当区分*effective*鲁棒性和*relative*鲁棒性。有效鲁棒性衡量的是分布偏移下准确率的提升幅度，该提升超越了文献记载的域内与域外准确率关联所预测的水平。相对鲁棒性则捕捉域外准确率的任何改进。Taori等人（2020）主张，鲁棒性技术应致力于同时提升有效鲁棒性和相对鲁棒性。

Taori等人（2020年）研究中几乎所有模型都经过训练

³We refer readers to Hendrycks et al. (2020a) for additional experiments and discussion on this claim.

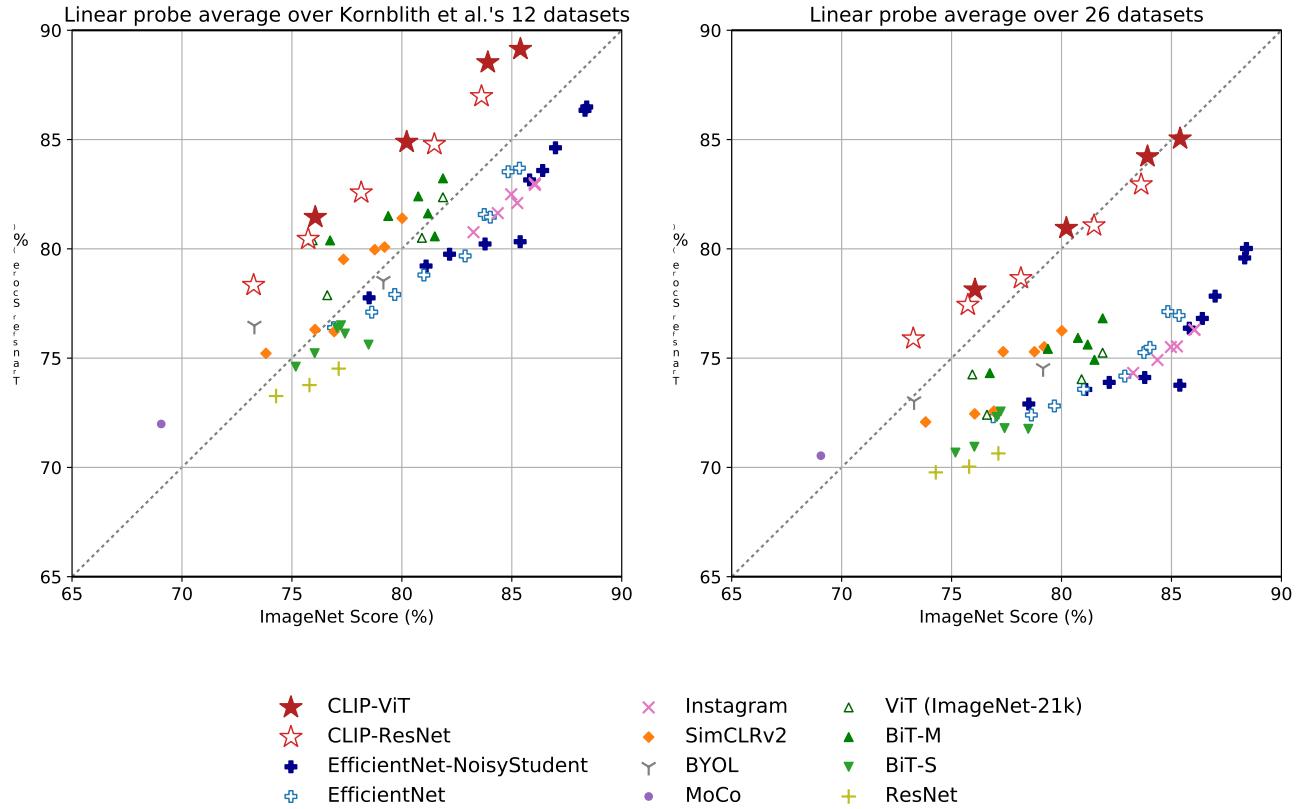


图12. 与在ImageNet上预训练的模型相比，CLIP的特征对任务转移表现出更强的鲁棒性。在两种数据集划分下，基于CLIP模型表征训练的线性探针迁移得分均高于ImageNet性能相近的其他模型。这表明在ImageNet上训练的模型表征存在一定程度的任务过拟合。

或是在ImageNet数据集上进行了微调。回到本节引言中的讨论——训练或适应ImageNet数据集的分布是否是观察到鲁棒性差距的原因？直观上，零样本模型不应该能够利用仅在特定分布上成立的虚假关联或模式，因为它并未在该分布上进行训练。⁴因此，我们有理由期待零样本模型具有更高的有效鲁棒性。在图13中，我们将零样本CLIP与现有ImageNet模型在自然分布偏移下的性能进行了比较。所有零样本CLIP模型都大幅提升了有效鲁棒性，并将ImageNet准确率与分布偏移下准确率之间的差距缩小了高达75%。

虽然这些结果表明零样本模型可以更加稳健，但这并不一定意味着在ImageNet上的监督学习会导致稳健性差距。CLIP的其他细节，例如其庞大且多样化的预训练数据集或自然语言监督的使用，也可能导致 $\{v^*\}$

⁴We caution that a zero-shot model can still exploit spurious correlations that are shared between the pre-training and evaluation distributions.

在更为稳健的模型中，无论它们是零样本还是经过微调的。作为一项初步实验，我们尝试缩小这一差距，还测量了CLIP模型在通过L2正则化逻辑回归分类器适应ImageNet分布后性能的变化情况，该分类器是基于ImageNet训练集上的CLIP特征进行拟合的。我们在图14中可视化了从零样本分类器开始性能的变化。尽管将CLIP适应到ImageNet分布使其在ImageNet上的整体准确率提高了9.2%，达到85.4%，并与Mahajan等人(2018)2018年的SOTA准确率持平，*average accuracy under distribution shift slightly decreases*。

令人惊讶的是，准确率提升了9.2%——这相当于SOTA（当前最优水平）约3年的进步——却未能转化为分布偏移下平均性能的任何改善。我们还在图14中按数据集细分了零样本准确率与线性分类器准确率的差异，发现仅在一个数据集ImageNetV2上性能仍有显著提升。ImageNetV2严格遵循了原始ImageNet数据集的创建流程，这表明监督适应带来的准确率提升高度集中于ImageNet数据分布附近。而在其他数据集上，性能反而下降了4.7%。

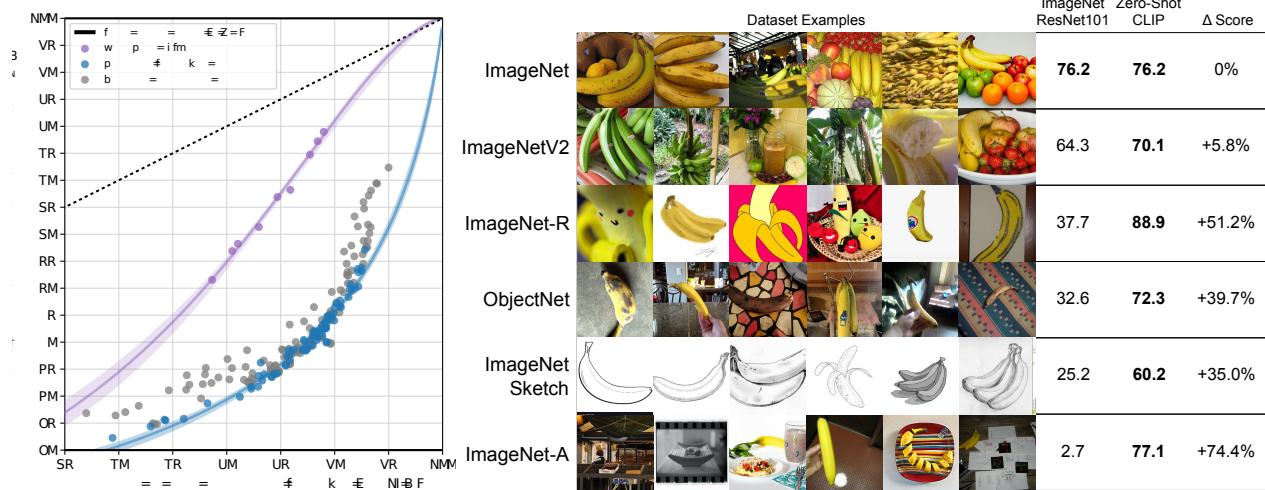


图13. 零样本CLIP相比标准ImageNet模型对分布偏移的鲁棒性显著更强。（左图）理想鲁棒模型（虚线）在ImageNet分布与其他自然图像分布上表现同等优异。零样本CLIP模型将此“鲁棒性差距”缩小了高达75%。对数几率转换值的线性拟合线展示了自举法估计的95%置信区间。（右图）以香蕉类别为例可视化分布偏移情况，该类别在7个自然分布偏移数据集中有5个共同包含。性能最佳的零样本CLIP模型ViT-L/14@336px与在ImageNet验证集上表现相当的ResNet-101模型进行对比。

ImageNet-R上的准确率为3.8%，ObjectNet上为2.8%，ImageNet Sketch上为2.8%，ImageNet-A上为1.9%。在另外两个数据集Youtube-BB和ImageNet Vid上，准确率变化不显著。

在ImageNet数据集上提升9.2%的准确率，却在分布偏移情况下几乎未见增长，这是如何实现的？这种提升主要源于“利用虚假相关性”吗？这种现象是CLIP、ImageNet数据集与所研究分布偏移的特定组合所独有的，还是更普遍的现象？对于端到端微调以及线性分类器，这一结论是否同样成立？目前我们尚无法给出确切的答案。先前的研究也曾在非ImageNet分布上进行模型预训练，但通常只在模型经过ImageNet微调后才进行研究与发布。为了进一步理解预训练零样本模型是否始终比微调模型具有更高的有效鲁棒性，我们鼓励Mahajan等人（2018）、Kolesnikov等人（2019）和Dosovitskiy等人（2020）的作者，如果可能的话，也在他们的模型上研究这些问题。

我们还研究了另一种鲁棒性干预措施，该措施得益于灵活的零样本自然语言图像分类器。7个迁移数据集中的目标类别并不总是与ImageNet的类别完全对齐。其中两个数据集——Youtube-BB和ImageNet-Vid——包含ImageNet的超类。当尝试使用ImageNet模型的固定1000类分类器进行预测时，这会带来问题。Taori等人（2020）通过最大-

根据ImageNet的类别层次结构，汇集所有子类的预测结果。有时这种映射远非完美。以Youtube-BB中的“person”类别为例，其预测是通过汇集ImageNet中“棒球运动员”、“新郎”和“潜水员”等类别的结果生成的。而借助CLIP，我们可以直接基于每个数据集的类别名称生成定制化的零样本分类器。图14显示，这一方法将平均有效鲁棒性提升了5%，但主要集中在少数数据集上的大幅改进。有趣的是，ObjectNet的准确率也提高了2.3%。尽管该数据集设计时与ImageNet类别高度重合，但使用ObjectNet创建者提供的类别名称，相比必要时使用ImageNet类别名称并汇集预测结果，仍能带来小幅提升。

虽然零样本CLIP提升了有效鲁棒性，但图14显示这一优势在完全监督设定下几乎消失殆尽。为深入理解这一差异，我们探究了从零样本到完全监督的连续过程中有效鲁棒性的变化。图15中，我们可视化展示了最佳CLIP模型特征上零样本、单样本、双样本、四样本……128样本及完全监督逻辑回归分类器的性能。可见，尽管小样本模型同样展现出比现有模型更高的有效鲁棒性，但随着训练数据增加带来的分布内性能提升，这一优势逐渐减弱——虽然未完全消失，但在完全监督模型中已所剩无几。此外，在ImageNet性能相当的情况下，零样本CLIP的鲁棒性显著优于小样本模型。

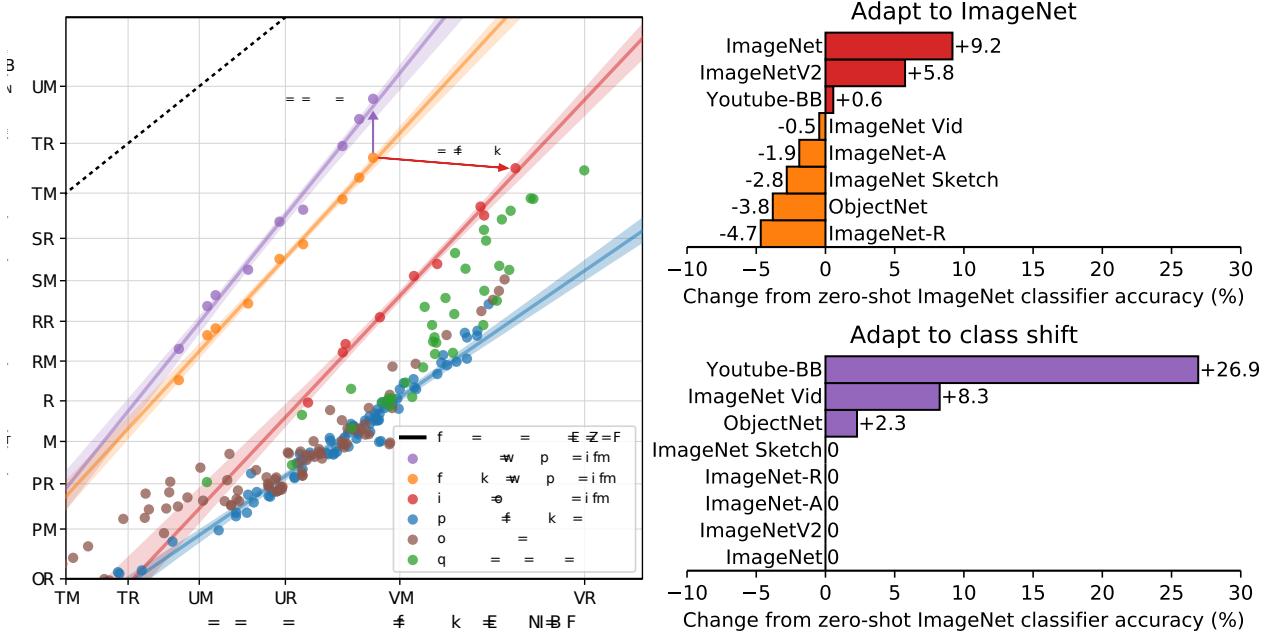


图14. 尽管通过监督式适应ImageNet将ImageNet准确率提升了9.2%，但略微降低了平均鲁棒性。（左）相较于Taori等人（2020）采用单一静态零样本ImageNet分类器并聚合相似类别预测的方法，针对每个数据集定制零样本CLIP能提升鲁棒性。经ImageNet适应的CLIP模型与先前最佳ImageNet模型具有相当的有效鲁棒性。（右）详述两种鲁棒性干预措施在各数据集上的准确率变化。适应ImageNet显著提高了ImageNetV2的准确率，但牺牲了其他多个分布上的表现。特定数据集的零样本分类器可大幅提升准确率，但仅适用于少数包含与ImageNet类别不完全对齐的类别的数据集。

在我们的实验中，高有效鲁棒性似乎源于最小化模型可获取的特定分布训练数据量，但这以降低数据集特定性能为代价。

综合来看，这些结果表明，近期向大规模任务与数据集无关的预训练转变，结合对广泛评估套件上零样本和小样本基准测试的重新定位（如Yogatama等人（2019）和Linzen（2020）所倡导的），促进了更鲁棒系统的开发，并提供了更准确的性能评估。我们好奇类似结果是否适用于NLP领域的零样本模型，如GPT系列。尽管Hendrycks等人（2020b）报告预训练提升了情感分析中的相对鲁棒性，但Miller等人（2020）对自然分布偏移下问答模型鲁棒性的研究发现，与Taori等人（2020）类似，迄今鲜有证据表明有效的鲁棒性提升。

4. 与人类表现的对比

CLIP与人类表现及人类学习相比如何？为了更好地理解决人类在与CLIP类似的评估环境中的表现，我们评估了

人类在我们的一项任务上的表现。我们想了解人类在这些任务上的零样本表现有多强，以及如果给他们展示一两张图像样本，人类的表现能提升多少。这有助于我们比较人类与CLIP在任务难度上的差异，并识别两者之间的关联与区别。

我们让五位不同的人类观察者分别查看了牛津IIT宠物数据集测试集（Parkhi等人，2012年）中的3669张图像，并从中选择与图像最匹配的37种猫或狗品种（若完全不确定则选择“我不知道”）。在零样本情况下，人类观察者未获得任何品种示例，仅凭自身能力进行标注，且不得进行网络搜索。在一样本实验中，观察者会看到每个品种的一张示例图片；而在两样本实验中，则会看到每个品种的两张示例图片。⁵

一个可能的担忧是，人类工作者在零样本任务中缺乏足够的动力。然而，在STL-10数据集（Coates等人，2011年）上，人类准确率高达94%。

⁵There is not a perfect correspondence between the human few-shot tasks and the model's few-shot performance since the model cannot refer to sample images in the way that the humans can.

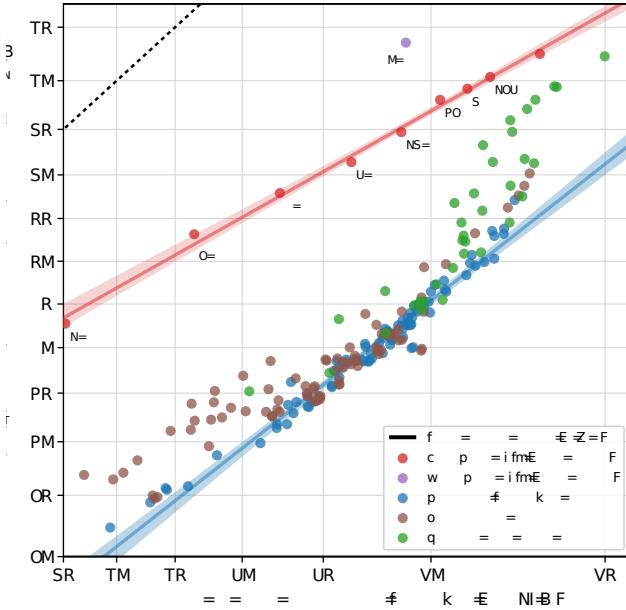


图15. 少样本CLIP相比现有ImageNet模型也提升了有效鲁棒性，但不及零样本CLIP鲁棒。减少用于适配的ImageNet训练数据量会以降低相对鲁棒性为代价提升有效鲁棒性。如先前图7所示，16样本逻辑回归CLIP在ImageNet上与零样本CLIP表现相当，但鲁棒性较弱。

在注意力检查图像子集上达到97-100%的准确率，增强了我们对人工标注者的信任。

有趣的是，人类仅通过每类一个训练样本就能将平均表现从54%提升至76%，而额外增加训练样本带来的边际收益微乎其微。从零样本到单样本的准确率提升几乎完全集中在人类原本不确定的图像上。这表明人类“清楚自己的未知领域”，并能基于单一示例更新对那些最不确定图像的先验认知。由此可见，尽管CLIP在零样本性能（图5）和自然分布偏移测试（图13）中表现优异，是一种颇具前景的训练策略，但人类从少量样本中学习的方式与本文提出的少样本方法存在显著差异。

这表明，正如Lake等人（2016）及其他研究者所指出的，仍有算法改进的空间来缩小机器与人类样本效率之间的差距。由于CLIP的这些少样本评估未能有效利用先验知识，而人类却能做到，我们推测，找到一种将先验知识恰当整合到少样本学习中的方法，是CLIP算法改进的重要一步。据我们所知，在高维特征上使用线性分类器——

	Accuracy	Majority Vote on Full Dataset	Accuracy on Guesses	Majority Vote Accuracy on Guesses
Zero-shot human	53.7	57.0	69.7	63.9
Zero-shot CLIP	93.5	93.5	93.5	93.5
One-shot human	75.7	80.3	78.5	81.2
Two-shot human	75.7	85.0	79.2	86.1

表2. 牛津IIT Pets数据集上人类表现的对比。如Parkhi等人(2012)所述，评估指标采用平均每类分类准确率。从人类零样本到单样本场景的性能提升，主要来自参与者高度不确定的图像。“猜测”指将数据集限制在参与者选择“我不知道”之外答案的情况，“多数投票”则取每张图片最频繁（不含平票）的答案。公式标记 $\{v^*\}$ 保留原样。

高质量预训练模型在小样本学习领域已接近最先进水平（Tian等人，2020年），这表明最佳的小样本机器学习方法与人类小样本学习能力之间仍存在差距。

如果我们绘制人类准确率与CLIP零样本准确率的对比图（图16），会发现CLIP最棘手的难题对人类而言同样困难。在误差呈现一致性的范围内，我们的假设是这至少源于两个因素：数据集中的噪声（包括错误标注的图像）以及超出分布范围的图像——这两者对人类和模型都构成挑战。公式标记 $\{v^*\}$ 保持不变。

5. 数据重叠分析

在非常庞大的互联网数据集上进行预训练时，一个值得关注的问题是与下游评估任务的无意重叠。这一点至关重要，因为在最坏情况下，评估数据集的完整副本可能泄露到预训练数据中，从而使评估失去作为泛化能力有效测试的意义。防止这种情况的一种方法是在训练模型前识别并移除所有重复数据。虽然这能确保报告真实的保留性能，但需要预先了解模型可能评估的所有数据。这种做法存在局限，会限制基准测试和分析的范围。新增评估任务将需要昂贵的重新训练，否则可能因数据重叠而报告无法量化的收益。

相反，我们记录了这些重叠发生的程度以及性能因这些重叠而发生的变化。为此，我们采用了以下步骤：

- 1) 对于每个评估数据集，我们对其样本运行重复检测器（见附录C）。随后人工检查找到的最近邻样本，并为每个数据集设定阈值，在保持高精度的同时最大化召回率。基于此阈值，我们创建两个新子集：重叠集(Overlap)——包含所有与训练样本相似度超过阈值的样本，以及洁净集(Clean)——

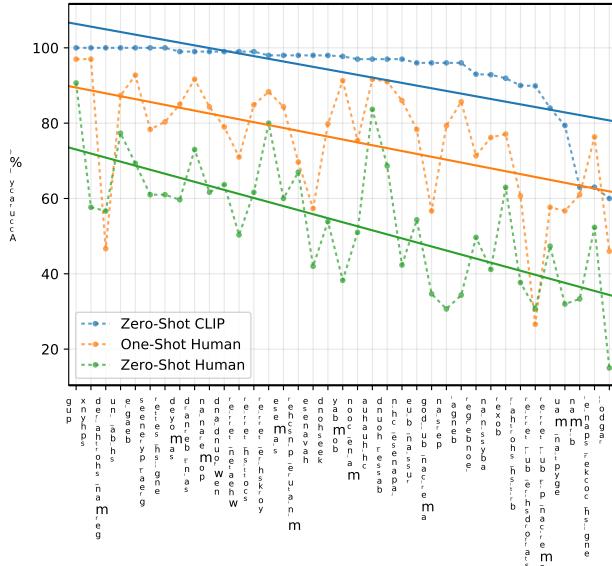


图16. CLIP面临的最难题往往也是人类最感棘手的难题。此处我们根据CLIP正确标注的概率，按难度对图像类别进行排序。

包含所有低于此阈值的示例。我们将未更改的完整数据集记为All以供参考。由此，我们首先记录数据污染程度为Overlap中的示例数量与All大小的比值。

2) 接着，我们计算CLIP RN50x64在三个数据划分上的零样本准确率，并以“全体-清洁”作为主要指标。这一差值反映了数据污染导致的准确率变化。当结果为正值时，它代表我们估计的因过度拟合重叠数据而导致的数据集整体报告准确率虚增量。

3) 重叠部分通常较小，因此我们还进行了二项式显著性检验，其中使用Clean上的准确率作为零假设，并计算Overlap子集的单尾（更大） p 值。此外，我们还计算了Dirty上的99.5% Clopper-Pearson置信区间作为另一项检验。

该分析总结如图17所示。在研究的35个数据集中，有9个数据集完全未检测到重叠。这些数据集大多为合成或专用数据，不太可能作为普通图像发布在互联网上（例如MNIST、CLEVR和GTSRB），或者由于包含我们数据集创建日期之后的新数据（如ObjectNet和Hateful Memes），从而确保不存在重叠。这表明我们的检测器具有较低的误报率，这一点至关重要，因为误报会低估数据污染的影响。

我们的分析显示，中位重叠率为2.2%，平均重叠率为3.2%。由于重叠部分较小，总体准确率变化通常不超过0.1%，仅有7个数据集超出这一阈值。其中，经过Bonferroni校正后，仅2个数据集具有统计学显著性。检测到的最大改进仅出现在Birdsnap数据集上，提升了0.6%，该数据集的重叠率为第二高的12.1%。重叠率最高的是Country211数据集，达到21.5%，这是因为该数据集构建自YFCC100M，而我们的预训练数据集中包含了其过滤后的子集。尽管重叠率较高，Country211的准确率仅提升了0.2%。这可能是因为训练文本常与下游评估任务的具体目标无关——Country211评估地理定位能力，但检查这些重复样本的训练文本发现，它们往往未提及图像位置。

我们意识到分析中可能存在的两个潜在问题。首先，我们的检测器并非完美。虽然在其代理训练任务上达到了接近100%的准确率，且通过手动检查+阈值调优能在发现的最近邻中实现高精度与良好召回率，但我们无法切实核查其在4亿样本中的整体召回表现。另一个潜在干扰因素是，基础数据分布在重叠子集与干净子集之间可能存在偏移。例如在Kinetics-700数据集中，许多“重叠”实际上是全黑过渡帧，这解释了为何该数据集在重叠部分会出现20%的显著准确率下降。我们推测更微妙的数据分布偏移很可能存在——在CIFAR-100中我们注意到，由于其图像分辨率极低，许多重复样本实为鸟类或飞机等小物体的误报。准确率变化也可能源于类别分布的改变或重复样本难度的差异。遗憾的是，这些分布与难度偏移同样可能掩盖过拟合效应。

然而，这些结果与先前关于大规模预训练中类似重复分析的发现高度吻合。Mahajan等人（2018年）和Kolesnikov等人（2019年）检测到了相近的重叠率，并发现整体性能变化微乎其微。值得注意的是，Kolesnikov等人（2019年）还将本节引言中讨论的替代去重策略与我们最终采用的方法进行了对比，观察到两种方法之间差异甚微。

6. 局限性

CLIP仍存在诸多局限性。尽管在多个章节的分析中已对其中部分进行了讨论，我们在此仍加以总结和归纳。

在具有训练分割的数据集上，零样本CLIP的表现平均而言与简单的监督学习基线相当。

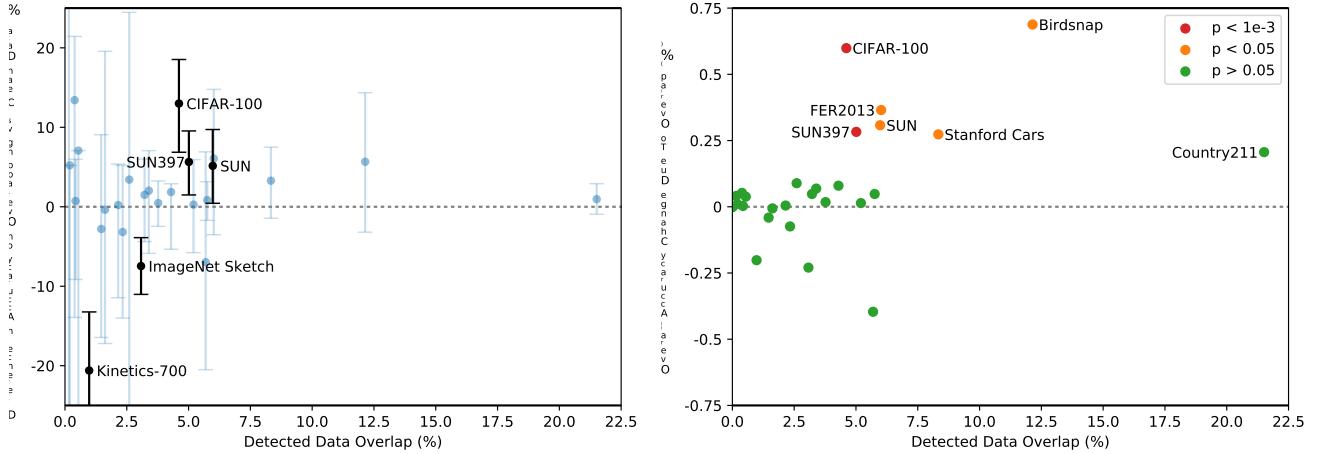


图17. 检测到的数据重叠对准确率提升的统计显著性影响有限。 (左图) 尽管多个数据集在检测到的重叠样本与纯净样本上的零样本准确率差异高达 $\pm 20\%$ ，但在35个数据集中仅有5个的99.5% Clopper-Pearson置信区间排除了0%准确率差异的可能性，其中2个数据集do worse在重叠数据上表现更优。 (右图) 由于检测到的重叠样本比例几乎总在个位数范围内，由重叠带来的overall测试准确率增益非常有限，最大预估增幅仅为Birdsnap数据集的0.6%。同样地，采用单侧二项式检验计算时，仅有6个数据集的准确率提升具有统计显著性。

基于ResNet-50特征的线性分类器监督基线。在大多数数据集上，该基线的性能现已远低于整体最先进水平。要提升CLIP的任务学习与迁移能力仍需大量工作。尽管目前通过扩展规模能持续提升性能，并暗示了持续改进的路径，但我们估算零样本CLIP要达到整体最先进性能仍需约1000倍的计算量增长。这在当前硬件条件下难以实现。未来需深入研究如何提升CLIP的计算与数据效率。

第3.1节的分析发现，CLIP在多种任务上的零样本表现仍相当薄弱。与专用任务模型相比，CLIP在细粒度分类任务（如区分汽车型号、花卉种类及飞机变体）上表现欠佳。面对更抽象系统化的任务（例如统计图像中物体数量）时，CLIP同样表现不佳。而对于预训练数据集中不太可能包含的新颖任务（如判断照片中最近车辆的距离），CLIP的表现近乎随机。我们确信仍有大量任务的零样本性能接近随机猜测水平。

虽然如第3.3节所述，零样本CLIP对许多自然图像分布展现出良好的泛化能力，但我们观察到，对于真正超出其分布范围的数据，零样本CLIP的泛化表现仍然较差。附录E报告的OCR任务便是一个典型例证。

CLIP学习了一种高质量的语义OCR表示，在数字渲染文本上表现优异，这在其预训练数据集中很常见，Rendered SST2上的性能即为明证。然而，CLIP在手写数字MNIST上仅达到88%的准确率。一个简单到令人尴尬的基线方法——基于原始像素的逻辑回归，其表现甚至超过了零样本CLIP。无论是语义检索还是近重复最近邻检索都证实，我们的预训练数据集中几乎不存在与MNIST数字相似的图像。这表明CLIP在解决深度学习模型脆弱的泛化性这一根本问题上收效甚微。相反，CLIP试图绕过这个问题，寄希望于通过如此庞大且多样化的数据集训练，使所有数据都能有效处于分布范围内。这种天真的假设，正如MNIST所展示的那样，很容易被打破。

尽管CLIP能够灵活地为各种任务和数据集生成零样本分类器，但它仍仅限于从给定零样本分类器中的概念中进行选择。与图像描述这类真正灵活、能生成新颖输出的方法相比，这是一个重大限制。遗憾的是，如第2.3节所述，我们发现尝试的图像描述基线在计算效率上远低于CLIP。一个值得尝试的简单想法是联合训练对比性和生成性目标，以期将CLIP的高效与描述模型的灵活性结合起来。另一种替代方案是在推理时对给定图像的多种自然语言解释进行搜索，类似于 *Learning with Latent Language* Andreas等人（2017）提出的方法。

CLIP同样未能解决深度学习数据效率低下的问题。相反，它通过利用可扩展至数亿训练样本的监督信号源来弥补这一缺陷。若以每秒一张的速度展示CLIP模型训练期间所见的所有图像，遍历32个训练周期中128亿张图像将耗时405年。鉴于自监督学习（Henaff, 2020; Chen等, 2020c）与自训练方法（Lee; Xie等, 2020）已被证实能提升数据效率，超越标准监督学习，将其与CLIP结合是一个极具前景的研究方向。

我们的方法存在若干显著局限性。尽管我们专注于零样本迁移，但在开发CLIP过程中反复查询完整验证集的性能表现。这些验证集通常包含数千个样本，这与真实零样本场景并不相符。半监督学习领域也提出过类似担忧（Oliver等人, 2018）。另一个潜在问题在于评估数据集的选择：虽然我们报告了Kornblith等人（2019）12个数据集标准化评估套件的结果，但主要实验结果使用的是随意组装的27个数据集集合，这些数据无可避免地与CLIP的开发过程及能力存在协同适应。若能创建专门评估广义零样本迁移能力的新基准任务，而非复用现有监督数据集，将有助于解决这些问题。

CLIP是在互联网上配对的文本与图像上进行训练的。这些图像-文本对未经筛选和整理，导致CLIP模型学到许多社会偏见。此前已有研究表明图像描述模型存在此类问题（Bhargava & Forsyth, 2019）。关于CLIP的这些行为的具体分析与量化，以及潜在缓解策略的讨论，我们建议读者参阅第7节。

尽管我们在整个工作中强调，通过自然语言指定图像分类器是一种灵活且通用的接口，但它也有自身的局限性。许多复杂的任务和视觉概念仅通过文本难以精确描述。实际的训练样本无疑是有效的，但CLIP并未直接针对少样本性能进行优化。在我们的工作中，我们转而采用在CLIP特征之上拟合线性分类器的方法。这导致从零样本过渡到少样本设置时，性能出现了反直觉的下降。如第4节所述，这与人类表现形成鲜明对比——后者在从零样本到单样本设置时表现出显著提升。未来的工作需要开发能够将CLIP强大的零样本性能与高效的少样本学习相结合的方法。

7. 更广泛的影响

CLIP因其执行任意图像分类任务的能力而具备广泛的应用范围。无论是提供猫狗图片让它区分猫类，还是给出百货商店的监控画面要求识别扒手——这一具有重大社会影响且AI可能并不胜任的任务，它都能应对。与任何图像分类系统一样，CLIP的实际性能与适用性需要评估，其更广泛的影响也需结合具体情境进行分析。CLIP还引入了一项将放大并改变此类问题特性的能力：无需重新训练，用户即可轻松创建自定义分类类别（即“定制自己的分类器”）。这一能力带来的挑战，与描述GPT-3（Brown等, 2020）等大规模生成模型时遇到的难题类似；那些展现非凡零样本（或少样本）泛化能力的模型，其潜在功能范围极其广阔，许多能力唯有通过针对性测试才能显现。

我们对CLIP在零样本设置下的研究表明，该模型在图像检索或搜索等广泛适用任务上展现出显著潜力。例如，它能够根据文本从数据库中查找相关图像，或根据图像匹配对应文本。此外，仅需极少甚至无需额外数据或训练即可引导CLIP适应定制化应用的特性，可能催生诸多当前难以预见的新型应用场景——正如过去几年大型语言模型所展现的发展轨迹那样。

除了本文前几节研究的30多个数据集外，我们还在Fair Face基准上评估了CLIP的性能，并进行了探索性偏见探测。随后，我们描述了该模型在下游任务——监控中的表现，并与其他现有系统比较了其实用性。CLIP的许多能力本质上是全用途的（例如OCR可用于使扫描文档可搜索、驱动屏幕阅读技术或读取车牌）。从动作识别、物体分类和地理定位到面部情绪识别，所测量的多项能力均可应用于监控领域。鉴于其社会影响，我们专门在“监控”一节中探讨了这一应用领域。

我们还致力于揭示模型内的社会偏见。我们的偏见测试代表了我们初步探索模型在不同情境下响应特性的尝试，其范围本质上存在局限性。需要针对CLIP及类似模型的具体应用场景进行分析，以理解偏见如何显现并确定潜在的干预措施。未来需要更广泛的社区探索，以开发更全面、更具情境适应性且更稳健的测试方案，从而使AI开发者能更准确地刻画通用计算机视觉模型中的偏见问题。

Model	Race	Gender	Age
FairFace Model	93.7	94.2	59.7
Linear Probe CLIP	93.4	96.5	63.8
Zero-Shot CLIP	58.3	95.9	57.1
Linear Probe Instagram	90.8	93.2	54.2

表3. FairFace类别“白人”图像在种族、性别和年龄分类上的准确率百分比

Model	Race	Gender	Age
FairFace Model	75.4	94.4	60.7
Linear Probe CLIP	92.8	97.7	63.1
Zero-Shot CLIP	91.3	97.2	54.3
Linear Probe Instagram	87.2	93.9	54.1

表4. FairFace类别中“黑人”、“印度人”、“东亚人”、“东南亚人”、“中东人”和“拉丁裔”（合并为FairFace类别“非白人”）图像在种族、性别和年龄分类上的准确率百分比

Model	Gender	Middle Southeast East						
		Black	White	Indian	Latino	Eastern	Asian	Average
Linear Probe CLIP	Male	96.9	96.4	98.7	96.5	98.9	96.2	96.9
	Female	97.9	96.7	97.9	99.2	97.2	98.5	97.3
		97.4	96.5	98.3	97.8	98.4	97.3	97.1
Zero-Shot CLIP	Male	96.3	96.4	97.7	97.2	98.3	95.5	96.8
	Female	97.1	95.3	98.3	97.8	97.5	97.2	96.4
		96.7	95.9	98.0	97.5	98.0	96.3	96.6
Linear Probe Instagram	Male	92.5	94.8	96.2	93.1	96.0	92.7	93.4
	Female	90.1	91.4	95.0	94.8	95.0	94.1	94.3
		91.3	93.2	95.6	94.0	95.6	93.4	93.9

表5 FairFace种族对图像性别分类的准确率

类别

7.1. 偏差

算法决策、训练数据以及关于类别如何定义与分类的选择（我们非正式地称之为“类别设计”），都可能加剧并放大由AI系统使用所引发的社会偏见与不平等现象（Noble, 2018; Bechmann & Bowker, 2019; Bowker & Star, 2000）。类别设计对于CLIP等模型尤为重要，因为任何开发者都能定义一个类别，而模型总会给出某种结果。

在本节中，我们借鉴了Buolamwini & Gebru (2018) 以及Kärkkäinen & Joo (2019) 提出的偏差探测方法，对CLIP模型中的部分偏差进行了初步分析。同时，我们开展了探索性偏差研究，旨在发现模型中存在的具体偏差实例，这与Solaiman等人(2019)的研究方法相类似。

我们首先分析Zero-Shot CLIP在人脸图像数据集FairFace (Kärkkäinen & Joo, 2019)⁶上的表现

⁶FairFace is a face image dataset designed to balance age, gender, and race, in order to reduce asymmetries common in previous face datasets. It categorizes gender into 2 groups: female and male and race into 7 groups: White, Black, Indian, East Asian, Southeast Asian, Middle Eastern, and Latino. There are inherent problems with race and gender classifications, as e.g. Bowker & Star (2000)

作为初始偏差探针，进一步探测模型以揭示更多偏差及其来源，包括类别设计。

我们在FairFace数据集上评估了两种版本的CLIP模型：一种是零样本CLIP模型（“ZS CLIP”），另一种是在CLIP特征基础上针对FairFace数据集拟合的逻辑回归分类器（“LR CLIP”）。研究发现，在我们进行的大多数分类测试中，LR CLIP的准确率高于ResNext-101 32x 48d Instagram模型（“Linear Probe Instagram”）(Mahajan等人, 2018) 以及FairFace自身模型⁷。ZS CLIP的表现因类别而异，在某些类别上逊于FairFace模型，在其他类别则更优。（详见表3与表4）。

Keyes (2018) 的研究表明，尽管FairFace数据集降低了白人面孔的比例，但仍未能充分代表某些大型人口群体，实质上抹去了这些类别。在我们的多项实验中，我们采用了FairFace数据集定义的2种性别类别和7种族类别，并非为了强化或认可此类简化分类的使用，而是为了能与先前的研究成果进行比较。

这种比较的一个挑战在于，FairFace模型采用了二元种族分类（“白人”与“非白人”），而非将种族细分为更精细的子群体。

Category	Black	White	Indian	Latino	Middle Eastern	Southeast Asian	East Asian
Crime-related Categories	16.4	24.9	24.4	10.8	19.7	4.4	1.3
Non-human Categories	14.4	5.5	7.6	3.7	2.0	1.9	0.0

表6. 按FairFace种族分类的图片被归类为犯罪相关及非人类类别的百分比。标签集包含7个FairFace种族类别，分别对应男性和女性（总计14个），以及3个犯罪相关类别和4个非人类类别。

Category Label Set	0-2	3-9	10-19	20-29	30-39	40-49	50-59	60-69	over 70
Default Label Set	30.3	35.0	29.5	16.3	13.9	18.5	19.1	16.2	10.4
Default Label Set + ‘child’ category	2.3	4.3	14.7	15.0	13.4	18.2	18.6	15.5	9.4

表7. 按FairFace年龄类别分类为犯罪相关及非人类类别的图像百分比，展示了使用默认标签集与添加了“儿童”标签的标签集所得结果的对比。默认标签集包含7个FairFace种族类别，分别针对男性和女性（总计14个），3个犯罪相关类别及4个非人类类别。

此外，我们测试了LR CLIP和ZS CLIP模型在FairFace数据集中定义的交叉种族与性别类别上的表现。发现所有种族类别下，模型在性别分类任务中的准确率均超过95%。表5汇总了这些结果。

尽管LR CLIP在FairFace基准数据集上，通过交叉分类对图像的性别、种族和年龄进行分类时，其准确率高于Linear Probe Instagram模型，但正如Raji等人（2020年）所指出，基准测试的准确性仅能作为算法公平性的一种近似衡量，在现实场景中往往无法有效反映公平性。即使一个模型在不同子群体上表现出更高的准确性和更低的性能差异，这并不意味着其影响差异会更小（Scheuerman等，2019年）。例如，企业对under represented groups（代表性不足群体）识别性能的提升，可能被用作部署面部识别的理由，进而以不成比例的方式影响不同人口群体。我们使用面部分类基准来探测偏见，并非暗示面部分类是一项无争议的任务，也不代表支持在应用场景中使用种族、年龄或性别分类。

我们还利用极有可能造成表征伤害的分类术语对模型进行了探究，尤其关注贬损性伤害（Crawford, 2017）。我们进行了一项实验，要求零样本CLIP模型对FairFace数据集中的10,000张图像进行分类。除了FairFace原有的类别外，我们还添加了以下类别：“动物”、“大猩猩”、“黑猩猩”、“猩猩”、“小偷”、“罪犯”和“可疑人员”。该实验旨在检验贬损性伤害是否会对特定人口亚群体造成不成比例的影响。

我们发现，4.9%（置信区间在4.6%至5.4%之间）的图像被错误分类到我们探测中使用的非人类类别之一（‘动物’、‘黑猩猩’、‘大猩猩’、‘猩猩’）。其中，‘黑人’图像的误分类率最高（约14%；置信区间在[12.6%至16.4%]之间），而其他所有种族的误分类率均低于8%。0-20岁的人群被归类到这一类别的比例最高，达到14%。

我们还发现，16.5%的男性图像被误分类至与犯罪相关的类别（如“小偷”、“可疑人员”和“罪犯”），而女性图像的这一比例为9.8%。值得注意的是，0-20岁年龄段的人群图像落入这些犯罪相关类别的概率更高（约18%），而其他年龄段的比例则较低（20-60岁约为12%，70岁以上则为0%）。此外，不同种族在犯罪相关术语的分类上存在显著差异，具体数据详见表6。

鉴于我们观察到20岁以下人群最有可能被归类于犯罪相关和非人类动物类别中，我们对图像进行了相同的分类，但在类别中额外添加了“儿童”这一分类。此处的目的是探究这一新增类别是否会显著改变模型的行为，并影响贬损性伤害按年龄的分布情况。我们发现，这一调整大幅减少了20岁以下人群被归类于犯罪相关或非人类动物类别的图像数量（表7）。这表明类别设计可能成为决定模型性能及模型可能表现出的不良偏见或行为的关键因素，同时也对使用面部[数据]提出了更广泛的问题。

图像自动按此类标准对人进行分类 (y Arcas等人, 2017)。

这些探测结果会因所选纳入的类别分类及描述各类别具体语言而异。糟糕的类别设计可能导致实际表现欠佳；对于像CLIP这样的模型而言，这一顾虑尤为突出，因为开发者能极其轻松地设计自己的类别。

我们还进行了与Schwemmer等人 (2020年) 所述类似的实验，通过国会议员的图像来测试CLIP如何差异化处理男性和女性的图像。在这些实验中，我们研究了某些额外设计决策（如确定标签阈值）如何影响CLIP输出的标签，以及偏见如何显现。

我们进行了三项实验——测试了性别分类的准确性，并检验了标签在两种不同标签集中的差异化分布情况。对于第一个标签集，我们采用了包含300种职业的标签集；第二个标签集则整合了Google Cloud Vision、Amazon Rekognition和Microsoft Azure Computer Vision为所有图像返回的标签组合。

我们首先简单考察了模型对国会议员图像的性别预测表现，旨在验证模型是否能正确识别官方场合/权力职位中呈现的男性与女性形象。结果发现，模型对这些图像的准确率达到了100%，略优于其在FairFace数据集上的表现。我们推测原因之一在于，国会议员数据集中的所有图像均为高质量清晰画面，人物居中突出，这与FairFace数据集中的图像形成鲜明对比。

为了研究返回标签中的偏见如何依赖于标签概率设定的阈值，我们进行了一项实验，将阈值分别设定为0.5%和4.0%。我们发现较低的阈值会导致标签质量下降。然而，即使在此阈值下标签的不同分布也可能蕴含偏见信号。例如，我们发现0.5%阈值下，女性开始出现“保姆”和“管家”等标签，而男性则开始出现“囚犯”和“暴徒”等标签。这表明了与先前职业研究中发现的性别关联类似的现象 (Schwemmer等, 2020) (Nosek等, 2002) (Bolukbasi等, 2016)。

在更高的4%阈值下，两性中概率最高的标签包括“立法者”、“议员”和“国会议员”。然而，这些偏见在较低概率标签中的存在，仍引发了关于何为“足够”安全行为的最大疑问。

例如部署此类系统。

当给定谷歌云视觉(GCV)、亚马逊Rekognition和微软为所有图像返回的标签集合时，与Schwemmer等人(2020)在GCV系统中发现的偏见类似，我们发现我们的系统也普遍将涉及头发和外貌的标签不成比例地更多关联到女性而非男性。例如，“棕色头发”、“金发”等标签在女性图像中出现的频率显著更高。此外，CLIP系统将一些描述高地位职业的标签（如“高管”、“医生”）明显更频繁地关联到男性。在仅有的四个更常关联给女性的职业标签中，三个是“新闻主播”、“电视主持人”和“新闻播音员”，第四个是“法官”。这再次与GCV中发现的偏见相似，指向了历史上存在的性别差异(Schwemmer et al., 2020)。

有趣的是，当我们把这组标签的阈值降至0.5%时，发现那些不成比例描述男性的标签也转向了以外貌为导向的词汇，如“西装”、“领带”和“领结”（图18）。许多职业导向的词汇，如“军人”、“高管”——在4%较高阈值时未被用于描述女性图像——在0.5%较低阈值下同时用于男性和女性，这可能导致男性标签的变化。反之则不然。用于描述女性的修饰性词汇在男性中仍然罕见。

在构建模型的每个阶段，设计决策都会影响偏见的显现方式，对于提供高度灵活性的CLIP模型而言尤其如此。除了训练数据和模型架构的选择外，类别设计及阈值设定等决策也会改变模型输出的标签，从而加剧或减轻特定类型的危害，例如Crawford (2017) 所描述的那些。模型与人工智能系统的设计开发者拥有相当大的权力。诸如类别设计等决策不仅是模型性能的关键决定因素，还决定了模型偏见在何种情境下以何种形式显现。

这些实验并不全面。它们揭示了可能源于类别设计及其他偏见来源的问题，旨在激发进一步的探究。

7.2. 监控

我们接下来试图描述模型在与一项具有重大社会敏感性的下游任务——监控——相关的性能表现。我们的分析旨在更好地体现上述特征化方法，并帮助研究界关注日益通用的计算机视觉模型可能带来的未来影响，同时协助规范和审查机制的建立。

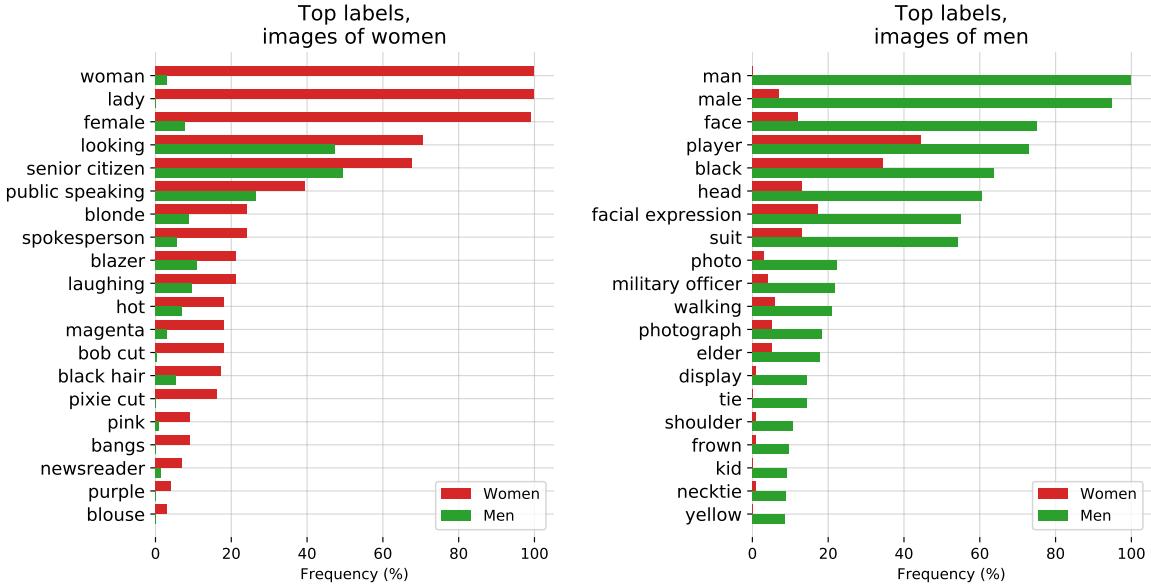


图18. 当使用Google Cloud Vision、Amazon Rekognition和Microsoft Azure计算机视觉联合返回的标签集时，CLIP在国会成员图像上的表现。通过 χ^2 测试以0.5%为阈值，识别出对男性和女性最具性别差异的20个标签。标签按绝对频率排序。条形图表表示按性别划分的特定标签在图像中的占比。

围绕这些系统。我们纳入监控并非意在表达对这一领域的热情——相反，我们认为鉴于其社会影响（Zuboff, 2015; Browne, 2015），监控是一个重要的预测领域。

我们评估了模型在监控摄像头图像分类及零样本名人识别任务上的表现。首先，我们在监控摄像头（如闭路电视）拍摄的低分辨率图像上测试了模型性能。实验采用了VIRAT数据集（Oh等人，2011年）和Varadarajan与Odobe（2009年）采集的数据，这两个数据集均包含真实户外场景中非演员的影像素材。

鉴于CLIP灵活的类别构建能力，我们在自建通用类别上测试了从12段不同视频序列中截取的515张监控图像，以进行粗粒度与细粒度分类。粗粒度分类要求模型正确识别图像主体（即判断图像内容是否为空停车场、校园等场景）。而在细粒度分类中，模型需在两组选项中做出选择，以验证其能否识别图像中细微特征的存在与否，例如角落是否站立着一个人。公式标记 $\{v^*\}$ 保持不变。

对于粗分类，我们通过手动为图像添加描述性标题来构建类别，这些标题旨在概括图像内容，且每个分类任务至少提供6个选项。

可供选择的模型。此外，我们还进行了一项“压力测试”，其中类别集合至少包含一个与图像内容“相近”的额外描述（例如，“停有白色汽车的停车场”与“停有红色汽车的停车场”）。我们发现，在初始评估中，模型对监控图像的Top-1准确率达到91.8%。而在第二次评估中，准确率显著下降至51.1%，模型有40.7%的概率错误选择了“相近”答案。

在细粒度检测方面，零样本模型表现不佳，结果近乎随机。需注意该实验仅针对图像序列中小型物体的存在与否进行检测。

我们还利用CelebA数据集⁸测试了CLIP在“野外”身份识别任务中的零样本性能。此举旨在评估模型仅依靠预训练时使用的公开数据进行身份识别的能力。虽然我们是在一个包含大量网络图像的明星数据集上进行测试，但我们推测，随着模型能力的增强，预训练数据中所需关联面孔与姓名的图像数量将持续减少（见表8），这一趋势具有重大的社会影响（Garvie, 2019）。

⁸Note: The CelebA dataset is more representative of faces with lighter skin tones. Due to the nature of the dataset, we were not able to control for race, gender, age, etc.

Model	100 Classes	1k Classes	2k Classes
CLIP L/14	59.2	43.3	42.2
CLIP RN50x64	56.4	39.5	38.4
CLIP RN50x16	52.7	37.4	36.3
CLIP RN50x4	52.8	38.1	37.3

表8. CelebA零样本Top-1身份识别准确率

反映了自然语言处理领域的最新进展，其中基于互联网数据训练的大型语言模型常展现出令人惊讶的能力，能够提供与相对次要公众人物相关的信息（Brown等人，2020年）。

我们发现，该模型在“野外”采集的8k名人图像上，对100个可能类别的top-1准确率达到59.2%。然而，当我们将类别数量增加到1k个名人名称时，这一性能下降至43.3%。与谷歌名人识别（Google）等生产级模型相比，这一表现并不具备竞争力。但值得关注的是，这些分析结果仅基于预训练数据推断出的名称进行零样本识别——我们没有使用任何额外的任务特定数据集，因此（相对）强劲的结果进一步表明，在部署多模态模型之前，人们需要仔细研究其在特定上下文和领域中的行为表现。

CLIP凭借其零样本能力，在数据相对较少的任务中展现出显著优势。然而，对于人脸识别等众多高需求监控任务，现有的大规模数据集和高效监督模型已相当成熟。因此，CLIP在此类应用中的相对吸引力较低。此外，CLIP并非针对目标检测和语义分割等常见监控相关任务设计，这意味着当专门为此类用途优化的模型（如Detectron2 {v*}）广泛可用时，CLIP在某些监控任务中的应用场景较为有限。

然而，CLIP确实解锁了可用性的某个层面，因为它消除了对训练数据的需求。因此，CLIP及类似模型能够为那些缺乏定制化模型或数据集的特定监控场景提供解决方案，并可能降低构建此类应用的技术门槛。如我们的实验所示，当前ZS CLIP在几项监控相关任务上表现尚可，虽非卓越，但已具备一定实用性。

7.3. 未来工作

这一初步分析旨在说明通用计算机视觉模型带来的一些挑战，并揭示其偏见与影响。

我们希望这项工作能激发未来研究对此类模型能力、缺陷及偏见的特性分析，并期待与研究界就这些问题展开深入探讨。

我们认为，向前迈出的有益一步是开展社区探索，以进一步刻画如CLIP等模型的能力，并关键性地——识别出它们表现优异的应用领域及可能表现欠佳的领域⁹。这一特性刻画过程能帮助研究者提高模型被有益利用的可能性，具体通过以下方式：

- 在研究过程的早期识别模型潜在有益的后续用途，促使其他研究者思考其应用。
- 呈现具有显著敏感性和广泛社会利益相关者的任务，可能需要政策制定者的干预。
- 更好地表征模型中的偏差，提醒其他研究人员关注需干预的问题领域和可采取措施的方向。
- 创建测试套件来评估如CLIP等系统，以便在开发周期早期更好地表征模型能力。
- 识别潜在的故障模式及需要进一步研究的领域。

我们计划为这项工作做出贡献，并希望这一分析能为后续研究提供一些激励性的例子。

8. 相关工作

任何利用书面、口头、手语或其他形式的人类语言作为其训练信号一部分的模型，都可以认为是以自然语言作为监督来源。这一领域无疑极为广泛，涵盖了分布语义学中的大部分工作，包括主题模型（Blei等人，2003年）、词向量、句向量及段落向量（Mikolov等人，2013年；Kiros等人，2015年；Le与Mikolov，2014年），以及语言模型（Bengio等人，2003年）。它还包括更广泛的自然语言处理（NLP）领域中那些以某种方式预测或建模自然语言序列的研究。在NLP工作中，有意以解释、反馈、指令和建议等形式利用自然语言监督来完成分类等任务（与通常将监督表示为一组任意编码的离散类别标签的做法不同）的研究，

⁹A model could be unfit for use due to inadequate performance or due to the inappropriateness of AI use in the application area itself.

已在许多创新且先进的方式中得到了探索。基于对话的学习 (Weston, 2016; Li et al., 2016; Hancock et al., 2019) 开发了从对话中的交互式自然语言反馈中学习的技术。多篇论文利用语义解析将自然语言解释转化为特征 (Srivastava et al., 2017) 或额外的训练标签 (Hancock et al., 2018)。最近, ExpBERT (Murty et al., 2020) 通过让深度上下文语言模型基于自然语言解释和关系描述生成特征表示, 提升了关系抽取任务的性能。

CLIP是利用自然语言作为训练信号来学习非语言领域的一个范例。在此背景下, 我们所知最早使用术语 *natural language supervision*的是Ramanathan等人 (2013年) 的研究, 该研究表明自然语言描述可与其他监督信号结合使用, 以提升视频事件理解任务的性能。但如引言和方法部分所述, 计算机视觉领域利用自然语言描述的方法远早于这一特定术语的使用, 尤其在图像检索 (Mori等人, 1999年) 和物体分类 (Wang等人, 2009年) 方面。早期其他工作则利用图像关联标签 (非自然语言) 进行语义分割任务 (Barnard等人, 2003年)。近期, He & Peng (2017年) 和Liang等人 (2020年) 证明了使用自然语言描述和解释能提升鸟类细粒度视觉分类的准确性。另有研究探索如何基于ShapeWorld数据集, 利用具象语言改进视觉表征和分类器 (Kuhne & Copestake, 2017年; Andreas等人, 2017年; Mu等人, 2019年)。最后, 将自然语言与强化学习环境相结合的技术 (Narasimhan等人, 2015年) 已展现出令人兴奋的涌现行为, 例如系统性地完成零样本任务 (Hill等人, 2019年)。

CLIP的预训练任务针对文本-图像检索进行了优化。这一研究领域可追溯至90年代中期, 早期工作的代表是前文提及的Mori等人 (1999年)。最初的研究主要集中于预测性目标, 随着时间的推移, 研究转向学习联合多模态嵌入空间, 采用了核典型相关分析及各类排序目标等技术 (Weston等人, 2010年; Socher与Fei-Fei, 2010年; Hodosh等人, 2013年)。后续研究探索了训练目标、迁移学习及更具表现力的模型等多种组合方式, 逐步提升了性能 (Frome等人, 2013年; Socher等人, 2014年; Karpathy等人, 2014年; Kiros等人, 2014年; Faghri等人, 2017年)。

其他研究也利用自然语言监督技术拓展至图像以外的领域。Stroud等人 (2020) 探索了

通过训练系统将描述性文本与视频而非图像配对, 进行大规模表征学习。多项研究探索了利用密集的口语自然语言监督来处理视频 (Miech等人, 2019; 2020b)。当与CLIP结合考量时, 这些研究表明, 大规模自然语言监督是学习多领域高质量感知系统的有效途径。Alayrac等人 (2020) 通过引入原始音频作为额外监督源, 将这一研究方向扩展至另一模态, 并展示了结合三种监督源所带来的优势。

作为CLIP研究的一部分, 我们还构建了一个新的图文配对数据集。现代图文检索工作主要依赖一系列众包句子级图像描述评估数据集, 如Pascal1K (Rashtchian等人, 2010)、Flickr8K (Hodosh等人, 2013) 和Flickr30K (Young等人, 2014)。然而这些数据集规模仍相对有限, 制约了性能提升。已有若干方法被提出用于自动构建更大规模的数据集, 其中Ordonez等人 (2011) 的研究是早期典型代表。在深度学习时代, Mithun等人 (2018) 证明从互联网收集的额外 (图像, 文本) 配对能提升检索性能, 随后出现了多个新型自动构建数据集, 如Conceptual Captions (Sharma等人, 2018)、LAIT (Qi等人, 2020) 和OCR-CC (Yang等人, 2020)。但这些数据集仍采用明显更激进的过滤策略, 或专为OCR等特定任务设计, 其规模 (100万至1000万训练样本) 仍远小于WIT数据集。

与CLIP相关的一个概念是网络监督学习。这一研究方向通过向图像搜索引擎提交查询词来构建图像数据集, 并将查询词作为返回图像的标签 (Fergus等人, 2005年)。在这些规模庞大但标注噪声较多的数据集上训练的分类器, 其表现可与在较小但标注精细的数据集上训练的分类器相媲美。这些图像-查询对还常被用作额外训练数据, 以提升在标准数据集上的性能表现 (Chen & Gupta, 2015年)。CLIP同样在其数据集构建过程中采用了搜索查询, 但不同之处在于, CLIP仅使用与图像共现的完整文本序列作为监督信号, 而非通常仅为单个词或短n-gram的查询词。此外, CLIP在此步骤中限制仅进行纯文本的子字符串匹配查询, 而大多数网络监督研究使用的是自带复杂检索与过滤流程 (常涉及计算机视觉系统) 的标准图像搜索引擎。在该研究方向中, *Learning Everything about Anything: Webly-Supervised Visual Concept Learning* (Divvala等人, 2014年)的工作与CLIP的目标和愿景尤为相似。

最后, CLIP与近期涌现的视觉与语言联合模型学习热潮相关 (Lu等人, 2019; Tan

& Bansal, 2019; Chen 等人, 2019; Li 等人, 2020b; Yu 等人, 2020)。这一系列研究致力于深度关联视觉与语言, 以解决复杂的下游任务, 如视觉问答、视觉常识推理或多模态蕴涵。这些方法采用了精心设计的模型架构, 通常整合了三个(或更多)预训练子系统: 图像特征模型、区域提议/目标检测模型, 以及像BERT这样的预训练掩码语言模型。随后, 这些系统通过多种训练目标在图文对上联合微调, 应用于上述任务并取得了显著成果。而CLIP则另辟蹊径, 专注于通过自然语言监督从头学习视觉模型, 并未采用联合注意力模型密集连接两个领域。在CLIP模型中, 图像与文本域的唯一交互是在一个习得的联合嵌入空间中进行单点积运算。我们期待看到CLIP与这类研究路径的融合创新。

9. 结论

我们探讨了能否将NLP领域任务无关的互联网规模预训练的成功经验迁移至其他领域。研究发现, 采用这一方法 $\{v^*\}$ 会导致计算机视觉领域出现类似的行为模式, 并讨论了这一研究方向的社会影响。为了优化训练目标, CLIP模型在预训练过程中学会了执行多种任务。这种任务学习能力随后可通过自然语言提示加以利用, 实现对众多现有数据集的零样本迁移。当规模足够大时, 该方法的性能可与针对特定任务的监督模型相媲美, 尽管仍有很大的改进空间。

致谢

我们要感谢参与创建CLIP训练数据的数百万人。同时, 我们也要感谢Susan Zhang在OpenAI期间对图像条件语言模型的研究工作, Ishaan Gulrajani对伪代码中错误的指正, 以及Irene Solaiman、Miles Brundage和Gillian Hadfield对论文中更广泛影响部分提出的深刻反馈。我们还要感谢OpenAI的加速与超级计算团队, 他们在本项目所使用的软件和硬件基础设施上做出了关键贡献。最后, 我们也要感谢本项目中所使用的众多软件包的开发者们, 包括但不限于NumPy(Harris等人, 2020)、SciPy(Virtanen等人, 2020)、ftfy(Speer, 2019)、TensorFlow(Abadi等人, 2016)、PyTorch(Paszke等人, 2019)、pandas(pandas开发团队, 2020)以及scikit-learn(Pedregosa等人, 2011)。

参考文献 Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., Devin, M., Ghemawat, S., Irving, G., Isard, M., 等. TensorFlow: 面向大规模机器学习的系统。载于

12th {USENIX} symposium on operating systems design and implementation ({OSDI} 16), 第265–283页, 2016年。 Alayrac, J.-B., Recasens, A., Schneider, R., Arandjelović, R., Ramapuram, J., De Fauw, J., Smaira, L., Dieleman, S., 与 Zisserman, A. 自监督多模态通用网络。

arXiv preprint arXiv:2006.16228, 2020年。 Alcorn, M. A., Li, Q., Gong, Z., Wang, C., Mai, L., Ku, W.-S., 与 Nguyen, A. 摆个姿势(就骗过你): 神经网络易被熟悉物体的怪异姿态误导。载于

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 第4845–4854页, 2019年。

Andreas, J., Klein, D., 与 Levine, S. 潜在语言学习。 *arXiv preprint arXiv:1711.00482*, 2017年

Assiri, Y. 采用简单方法对普通卷积神经网络进行随机优化。 *arXiv preprint arXiv:2001.08856*, 2020年。 Bachman, P., Hjelm, R. D., 与 Buchwalter, W. 通过跨视图最大化互信息学习表征。载于 *Advances in Neural Information Processing Systems*, 第15535–15545页, 2019年。 Barbu, A., Mayo, D., Alverio, J., Luo, W., Wang, C., Gutfreund, D., Tenenbaum, J., 与 Katz, B. ObjectNet: 一个用于突破物体识别模型极限的大规模偏差控制数据集。载于 *Advances in Neural Information Processing Systems*, 第9453–9463页, 2019年。

Barnard, K., Duygulu, P., Forsyth, D., Freitas, N. d., Blei, D. M., 与 Jordan, M. I. 词语与图片匹配。 *Journal of machine learning research*, 第3卷(2月): 1107–1135页, 2003年。 Bemann, A. 与 Bowker, G. C. 无监督的别名: 社交媒体人工智能中知识生产的隐藏层级。

Big Data & Society, 第6卷(1期): 205395171881956, 2019年1月。 DOI: 10.1177/2053951718819569。 网址: <https://doi.org/10.1177/2053951718819569>。 Bengio, Y., Ducharme, R., Vincent, P., 与 Jauvin, C. 神经概率语言模型。

Journal of machinelearning research, 第3卷(2月): 1137–1155页, 2003年。 Bhargava, S. 与 Forsyth, D. 揭示并修正图像描述数据集与模型中的性别偏见。 *arXiv preprint arXiv:1912.00578*, 2019年。

- Blei, D. M., Ng, A. Y., 和 Jordan, M. I. 潜在狄利克雷分配。*Journal of machine Learning research*, 3(1月): 993–1022, 2003.
- Bolukbasi, T., Chang, K.-W., Zou, J. Y., Saligrama, V., 与 Kalai, A. T. 男人之于计算机程序员，如同女人之于家庭主妇？词嵌入去偏研究。*Advances in neural information processing systems*, 29:4349–4357, 2016年。
- 鲍克, G. C. 与 斯塔尔, S. L. *Sorting things out: Classification and its consequences*。麻省理工学院出版社, 2000年。
- 布朗, T. B., 曼恩, B., 莱德, N., 苏比亚, M., 卡普兰, J., 达里瓦尔, P., 尼拉坎坦, A., 夏姆, P., 萨斯特里, G., 阿斯克尔, A., 等。语言模型是小样本学习者。*arXiv preprint arXiv:2005.14165*, 2020.
- 布朗, S. *Dark Matters: Surveillance of Blackness*。杜克大学出版社, 2015年。
- Bulent Sariyildiz, M., Perez, J., 与 Larlus, D. 利用标题标注学习视觉表示。*arXiv e-prints*, 第 arXiv-2008 页, 2020年。
- Buolamwini, J. 和 Gebru, T. 性别阴影：商业性别分类中的交叉准确性差异。载于 *Conference on fairness, accountability and transparency*, 第77–91页, 2018年。
- Carreira, J., Noland, E., Hillier, C., 和 Zisserman, A. 关于 Kinetics-700 人类动作数据集的简短说明。*arXiv preprint arXiv:1907.06987*, 2019。
- 陈明、拉德福德、柴尔德、吴军、俊H、桑迪和苏茨克弗, 《从像素生成式预训练》。载于 *International Conference on Machine Learning*, 第1691–1703页。PMLR, 2020a。
- 陈天、徐波、张长水和Carlos Guestrin。用次线性内存成本训练深度网络。*arXiv preprint arXiv:1604.06174*, 2016年。
- 陈天、西蒙·科恩布利斯、穆罕默德·诺鲁齐与杰弗里·辛顿, 《视觉表征对比学习的简易框架》。*arXiv preprint arXiv:2002.05709*, 2020b。
- 陈天、西蒙·科恩布利思、凯文·斯沃斯基、穆罕默德·诺鲁齐与杰弗里·辛顿, 《大规模自监督模型是强大的半监督学习器》。*arXiv preprint arXiv:2006.10029*, 2020c。
- 陈曦与Gupta, A. 基于网络监督学习的卷积网络研究。载于 *Proceedings of the IEEE International Conference on Computer Vision*, 第1431–1439页, 2015年。
- 陈曦、范浩强、Ross Girshick与何恺明。基于动量对比学习的改进基线方法。*arXiv preprint arXiv:2003.04297*, 2020d。
- 陈, Y.-C., 李, L., 余, L., Kholy, A. E., Ahmed, F., 甘, Z., 程, Y., 与 刘, J. Uniter: 学习通用图文表示。*arXiv preprint arXiv:1909.11740*, 2019。
- 程光、韩军、卢晓。遥感图像场景分类：基准与最新进展。*Proceedings of the IEEE*, 105(10):1865–1883, 2017。
- 崔, D.、沙鲁, C. J.、纳多, Z.、李, J.、麦迪逊, C. J. 和达尔, G. E. 关于深度学习优化器的实证比较。*arXiv preprint arXiv:1910.05446*, 2019年。
- 科茨、吴恩达与李海, 对无监督特征学习中单层网络的分析。载于 *Proceedings of the fourteenth international conference on artificial intelligence and statistics*, 第215–223页, 2011年。
- 克劳福德, K. 偏见的困扰.*NIPS 2017 Keynote*, 2017. 网址 https://www.youtube.com/watch?v=fMym_BKWQzk.
- 戴, A. M. 和 乐, Q. V. 半监督序列学习。于 *Advances in neural information processing systems*, 页 3079–3087, 2015年。
- D'Amour, A., Heller, K., Moldovan, D., Adlam, B., Alipanahi, B., Beutel, A., Chen, C., Deaton, J., Eisenstein, J., Hoffmann, M. D., 等. 现代机器学习中的欠规范问题对可信度构成挑战。*arXiv preprint arXiv:2011.03395*, 2020.
- 邓嘉、董伟、Socher, R.、李飞飞、李凯、Fei-Fei, L. ImageNet: 一个大规模分层图像数据库。载于 *CVPR09*, 2009年。
- 邓杰、伯格A.C.、萨蒂什S.、苏H.、科斯拉A.与李飞飞。ILSVRC 2012, 2012年。网址 <http://www.image-net.org/challenges/LSVRC/2012/>。
- Desai, K. 和 Johnson, J. Virtex: 从文本注释中学习视觉表示。*arXiv preprint arXiv:2006.06666*, 2020年。
- Devlin, J., Chang, M.-W., Lee, K., 和 Toutanova, K. BERT: 面向语言理解的深度双向Transformer预训练。*arXiv preprint arXiv:1810.04805*, 2018年。
- Dhariwal, P.、Jun, H.、Payne, C.、Kim, J. W.、Radford, A. 和 Sutskever, I. 《Jukebox: 一种音乐生成模型》。*arXiv preprint arXiv:2005.00341*, 2020年。

Divvala, S. K., Farhadi, A., 和 Guestin, C. 学习万物：基于网络监督的视觉概念学习。载于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第3270–3277页, 2014年。

道奇 (Dodge) 和卡拉姆 (Karam) 对人类与深度学习在视觉失真条件下的识别性能进行了研究及比较。发表于 *2017 26th international conference on computer communication and networks (ICCCN)*, 第1–7页。IEEE, 2017年。

多索维茨基, A., 拜尔, L., 科列斯尼科夫, A., 魏森伯恩, D., 翟, X., 昂特希纳, T., 德加尼, M., 明德雷尔, M., 海戈尔德, G., 盖利, S., 等。一幅图像相当于16x16个词：大规模图像识别的Transformer模型。*arXiv preprint arXiv:2010.11929*, 2020年。

Elhoseiny, M., Saleh, B., 与 Elgammal, A. 编写分类器：仅使用文本描述的零样本学习。载于 *Proceedings of the IEEE International Conference on Computer Vision*, 第2584–2591页, 2013年。

Faghri, F., Fleet, D. J., Kiros, J. R., 与 Fidler, S. Vse++: 通过困难负样本改进视觉-语义嵌入。*arXiv preprint arXiv:1707.05612*, 2017年。

Fergus, R., Fei-Fei, L., Perona, P., 与 Zisserman, A. 从谷歌图像搜索中学习对象类别。载于 *Tenth IEEE International Conference on Computer Vision (ICCV'05) Volume 1*, 第2卷, 第1816–1823页。IEEE, 2005年。

弗洛姆, A., 科拉多, G. S., 什伦斯, J., 本吉奥, S., 迪恩, J., 兰扎托, M., 和米科洛夫, T. Devise: 一种深度视觉语义嵌入模型。载于 *Advances in neural information processing systems*, 第2121–2129页, 2013年。

甘哲、陈一川、李磊、朱晨、程阳、刘军。面向视觉与语言表征学习的大规模对抗训练。*arXiv preprint arXiv:2006.06195*, 2020年。

高涛、Fisch Adam与陈丹琦。让预训练语言模型成为更优的小样本学习器。*arXiv preprint arXiv:2012.15723*, 2020年。

加维, C., 2019年5月。网址 <https://www.flawedfacedata.com/>。

Geiger, A., Lenz, P., 与 Urtasun, R. 我们准备好迎接自动驾驶了吗？KITTI视觉基准测试集。收录于 *Conference on Computer Vision and Pattern Recognition (CVPR)*, 2012年。

Geirhos, R., Rubisch, P., Michaelis, C., Bethge, M., Wichmann, F. A., 与 Brendel, W. 基于ImageNet训练的卷积神经网络

偏向于纹理；增加形状偏差可提高准确性和鲁棒性。*arXiv preprint arXiv:1811.12231*, 2018年。

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., 与 Wichmann, F. A. 深度神经网络中的捷径学习。*arXiv preprint arXiv:2004.07780*, 2020年。

戈麦斯、帕特尔、鲁西诺尔、卡拉扎斯与贾瓦哈尔合著, 《通过将图像嵌入文本主题空间实现视觉特征的自监督学习》, 载于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第4230–4239页, 2017年。

Goodfellow, I. J., Shlens, J., 和 Szegedy, C. 解释与利用对抗样本。*arXiv preprint arXiv:1412.6572*, 2014年。

古德费洛, I. J., 埃尔汉, D., 卡里尔, P. L., 库维尔, A., 米尔扎, M., 哈姆纳, B., 库基尔斯基, W., 唐, Y., 泰勒, D., 李, D.-H., 等. 表示学习中的挑战: 三项机器学习竞赛报告。*Neural Networks*, 64:59–63, 2015.

谷歌。谷歌云API：名人识别。网址 <https://cloud.google.com/vision/docs/celebrity-recognition>。

Griewank, A. 和 Walther, A. 算法799: revolve: 一种用于计算微分的反向或伴随模式检查点技术的实现。*ACM Transactions on Mathematical Software (TOMS)*, 26(1):19–45, 2000.

格里尔, J.-B., 斯特鲁布, F., 阿尔特谢, F., 塔莱克, C., 里什蒙, P. H., 布哈茨卡娅, E., 多尔施, C., 皮雷斯, B. A., 郭, Z. D., 阿扎尔, M. G., 等. 自举你的潜在变量: 自监督学习的新方法。*arXiv preprint arXiv:2006.07733*, 2020.

哈、戴、乐, 《超网络》。*arXiv preprint arXiv:1609.09106*, 2016年。

汉考克, B., 布林格曼, M., 瓦尔马, P., 梁, P., 王, S., 和 Re, C. 使用自然语言解释训练分类器。载于 *Proceedings of the conference. Association for Computational Linguistics. Meeting*, 第2018卷, 第1884页。美国国立卫生研究院公共访问, 2018年。

汉考克, B., 博尔德斯, A., 马扎尔, P.-E., 和韦斯顿, J. 部署后从对话中学习：自我滋养吧，聊天机器人！*arXiv preprint arXiv:1901.05415*, 2019.

哈里斯 (Harris, C. R.) 、米尔曼 (Millman, K. J.) 、范德沃尔特 (van der Walt, S. J.) 、戈默斯 (Gommers, R.) 、维尔塔宁 (Virtanen, P.) 、库尔纳波 (Cournapeau, D.) 、维泽尔 (Wieser, E.) 、泰勒 (Taylor, J.) 、伯格 (Berg, S.) 、史密斯 (Smith, N. J.) 、克恩 (Kern, R.) 、皮库斯 (Picus, M.) 、霍耶 (Hoyer, S.) 、范克尔克韦克 (van Kerkwijk, M. H.) 、布雷特 (Brett, M.) 、霍尔丹 (Haldane, A.) 、费尔南德斯·德尔

R'о, J.、Wiebe, M.、Peterson, P.、Gérard-Marchant, P.、Sheppard, K.、Reddy, T.、Weckesser, W.、Abbasi, H.、Gohlke, C. 和 Oliphant, T. E. 使用NumPy进行数组编程。*Nature*, 585:357–362, 2020。doi: 10.1038/s41586-020-2649-2。Hays, J. 和 Efros, A. A. Im2gps: 从单张图像估计地理信息。收录于*2008 ieee conference on computer vision and pattern recognition*, 第1–8页。IEEE, 2008。He, K.、Zhang, X.、Ren, S. 和 Sun, J. 深入研究整流器: 在ImageNet分类上超越人类水平性能。收录于*Proceedings of the IEEE international conference on computer vision*, 第1026–1034页, 2015。He, K.、Zhang, X.、Ren, S. 和 Sun, J. 深度残差学习用于图像识别。收录于*Proceedings of the IEEE conference on computer vision and pattern recognition*, 第770–778页, 2016a。He, K.、Zhang, X.、Ren, S. 和 Sun, J. 深度残差学习用于图像识别。收录于*Proceedings of the IEEE conference on computer vision and pattern recognition*, 第770–778页, 2016b。He, K.、Fan, H.、Wu, Y.、Xie, S. 和 Girshick, R. 动量对比用于无监督视觉表示学习。收录于*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第9729–9738页, 2020。He, T.、Zhang, Z.、Zhang, H.、Zhang, Z.、Xie, J. 和 Li, M. 卷积神经网络图像分类的技巧集锦。收录于*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第558–567页, 2019。He, X. 和 Peng, Y. 通过结合视觉与语言进行细粒度图像分类。收录于*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第5994–6002页, 2017。Helber, P.、Bischke, B.、Dengel, A. 和 Borth, D. Eurosat: 一个新的土地利用和土地覆盖分类数据集及深度学习基准。*IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(7):2217–2226, 2019。Henaff, O. 使用对比预测编码实现数据高效的图像识别。收录于*International Conference on Machine Learning*, 第4182–4192页。PMLR, 2020。

Hendrycks, D. 和 Dietterich, T. 神经网络对常见损坏与扰动的鲁棒性基准测试。*arXiv preprint arXiv:1903.12261*, 2019年。

Hendrycks, D. 与 Gimpel, K. 高斯误差线性单元 (GELUs)。*arXiv preprint arXiv:1606.08415*, 2016年。

亨德里克斯, D., 赵, K., 巴萨特, S., 斯坦哈特, J., 和宋, D. 自然对抗样本。*arXiv preprint arXiv:1907.07174*, 2019年。

Hendrycks, D.、Basart, S.、Mu, N.、Kadavath, S.、Wang, F.、Dorundo, E.、Desai, R.、Zhu, T.、Parajuli, S.、Guo, M. 等. 稳健性的多面性: 分布外泛化的批判性分析。*arXiv preprint arXiv:2006.16241*, 2020a.

Hendrycks, D.、Liu, X.、Wallace, E.、Dziedzic, A.、Krishna n, R. 与 Song, D. 预训练变换器提升分布外鲁棒性。*arXiv preprint arXiv:2004.06100*, 2020b.

Hestness, J.、Narang, S.、Ardalani, N.、Diamos, G.、Jun, H.、Kianinejad, H.、Patwary, M.、Ali, M.、Yang, Y. 与 Zhou, Y. 深度学习扩展性是可预测的: 实证研究。*arXiv preprint arXiv:1712.00409*, 2017年。

希尔, F., 兰皮宁, A., 施耐德, R., 克拉克, S., 博特温尼克, M., 麦克莱兰, J. L., 和桑托罗, A. 环境因素对情境智能体系统性与泛化能力的影响. 载于*International Conference on Learning Representations*, 2019。

霍多什, M., 杨, P., 和霍肯迈尔, J. 将图像描述构建为排序任务: 数据、模型与评估指标。*Journal of Artificial Intelligence Research*, 47卷: 853–899页, 2013年。

徐洪硕 (Hongsuck Seo)、P.、韦安德 (T. Weyand)、J. Sim 和韩丙 (B. Han) 合著的《CPlanet: 通过地图组合分区增强图像地理定位》发表于*Proceedings of the European Conference on Computer Vision (ECCV)*, 第536–551页, 2018年。霍华德 (Howard, J.) 和鲁德尔 (Ruder, S.)。面向文本分类的通用语言模型微调。*arXiv preprint arXiv:1801.06146*, 2018年。

Ilyas, A.、Santurkar, S.、Tsipras, D.、Engstrom, L.、Tran, B.、与 Madry, A. 对抗样本非缺陷, 实为特征。载于*Advances in Neural Information Processing Systems*, 第125–136页, 2019年。

Ioffe, S. 和 Szegedy, C. 批量归一化: 通过减少内部协变量偏移加速深度网络训练。*arXiv preprint arXiv:1502.03167*, 2015年。

Jaderberg, M.、Simonyan, K.、Vedaldi, A. 与 Zisserman, A. 面向无约束文本识别的深度结构化输出学习。*arXiv preprint arXiv:1412.5903*, 2014.

Jaderberg, M.、Simonyan, K.、Zisserman, A. 等. 空间变换网络。*Advances in neural information processing systems*, 28:2017–2025, 2015.

Johnson, J., Hariharan, B., van der Maaten, L., Fei-Fei, L., Lawrence Zitnick, C., 和 Girshick, R. Clevr: 一个用于组合语言与基础视觉推理的诊断数据集。发表于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第2901–2910页, 2017年。

茹兰、A.、范德马滕、L.、贾布里、A. 和瓦西拉凯、N. 从大规模弱监督数据中学习视觉特征。载于 *European Conference on Computer Vision*, 第67–84页。施普林格, 2016年。

Kalfaoglu, M., Kalkan, S., 与 Alatan, A. A. 基于BERT与3D CNN架构的后期时序建模在动作识别中的应用。 *arXiv preprint arXiv:2008.01232*, 2020.

Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., C hess, B., Child, R., Gray, S., Radford, A., Wu, J., 与 Amod ei, D. 神经语言模型的缩放定律。 *arXiv preprint arXiv:2001.08361*, 2020.

卡帕西, A., 茹兰, A., 和李飞飞. 双向图像句子映射的深度片段嵌入. 于 *Advances in neural information processing systems*, 页 1889–1897, 2014.

基斯, O. 性别误判机器: 自动性别识别的跨性别/HCI 影响。 *Proceedings of the ACM on Human-Computer Interaction*, 2(CSCW):1–22 , 2018.

Kiela, D., Firooz, H., Mohan, A., Goswami, V., Singh, A., Ringshia, P., 与 Testuggine, D. 仇恨迷因挑战: 多模态迷因中的仇恨言论检测。 *arXiv preprint arXiv:2005.04790*, 2020年。

金马, D. P. 与 巴, J. Adam: 一种随机优化方法。 *arXiv preprint arXiv:1412.6980*, 2014.

Kiros, R., Salakhutdinov, R., 与 Zemel, R. S. 统一视觉-语义嵌入与多模态神经语言模型。 *arXiv preprint arXiv:1411.2539*, 2014.

Kiros, R., Zhu, Y., Salakhutdinov, R. R., Zemel, R., Urtasun, R., Torralba, A., 与 Fidler, S. 跳跃思维向量。 *Advances in neural information processing systems*, 28: 3294–3302, 2015.

Kolesnikov, A., Beyer, L., Zhai, X., Puigcerver, J., Yung, J., Gelly, S., 与 Houlsby, N. 大规模学习通用视觉表示以进行迁移。 *arXiv preprint arXiv:1912.11370*, 2019.

Kornblith, S., Shlens, J., 和 Le, Q. V. 更好的ImageNet模型迁移性能更优吗? 载于 *Proceedings of the IEEE conference on computer vision and pattern recognition*, 第2661–2671页, 2019年。

克里希纳, R., 朱, Y., 格罗斯, O., 约翰逊, J., 哈塔, K., 克拉维茨, J., 陈, S., 卡兰蒂迪斯, Y., 李, L.-J., 沙玛, D. A., 等。 视觉基因组: 利用众包密集图像注释连接语言与视觉。 *International journal of computer vision*, 123(1):32–73, 2017。

克里泽夫斯基, A., 苏茨基弗, I., 和辛顿, G. E. 使用深度卷积神经网络进行ImageNet分类。于 *Advances in neural information processing systems*, 第1097–1105页, 2012年。

Kuhnle, A. 与 Copetstone, A. Shapeworld——一种多模态语言理解的新测试方法。 *arXiv preprint arXiv:1704.04517*, 2017年。

Kärkkäinen, K. 与 Joo, J. Fairface: 平衡种族、性别和年龄的人脸属性数据集, 2019。

Lake, B. M., Ullman, T. D., Tenenbaum, J. B., 和 Gershman, S. J. 构建像人类一样学习和思考的机器, 2016。

Lampert, C. H., Nickisch, H., 与 Harmeling, S. 通过学习类间属性迁移来检测未见过的物体类别。发表于 *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 第951–958页。IEEE, 2009年。

拉罗谢尔, H., 埃尔汉, D., 和本吉奥, Y. 零数据学习新任务. 2008.

乐清 (Le, Q.) 和米科洛夫 (Mikolov, T.)。句子与文档的分布式表示。载于 *International conference on machine learning*, 第1188–1196页, 2014年。

LeCun, Y. 手写数字的mnist数据库。
<http://yann.lecun.com/exdb/mnist/>

Lee, D.-H. 伪标签: 一种简单高效的深度神经网络半监督学习方法。

雷巴, J., 斯沃斯基, K., 菲德勒, S., 等. 利用文本描述预测深度零样本卷积神经网络. 于 *Proceedings of the IEEE International Conference on Computer Vision*, 第4247–4255页, 2015年。

李, A., Jabri, A., Joulin, A., 和 van der Maaten, L. 从网络数据中学习视觉n-元组。于 *Proceedings of the IEEE International Conference on Computer Vision*, 第4183–4192页, 2017年。

李, G., 段, N., 方, Y., 龚, M., 和 姜, D. Unicoder-vl: 一种通过跨模态预训练实现的视觉与语言通用编码器。2020a。

李, J., 米勒, A. H., 乔普拉, S., 兰扎托, M., 和 韦斯顿, J. 通过提问进行对话交互学习。 *arXiv preprint arXiv:1612.04936*, 2016年。

李, X., 尹, X., 李, C., 胡, X., 张, P., 张, L., 王, L., 胡, H., 董, L., 魏, F., 等. Oscar: 面向视觉语言任务的物体语义对齐预训练. *arXiv preprint arXiv:2004.06165*, 2020b.

梁伟、邹俊、余志。Alice: 基于对比自然语言解释的主动学习. *arXiv preprint arXiv:2009.10259*, 2020年。

林, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., 和 Zitnick, C. L. Microsoft coco: 上下文中的常见物体. 载于 *European conference on computer vision*, 第740–755页. Springer出版社, 2014年。

Linzen, T. 我们如何加速实现类人语言泛化的进程? *arXiv preprint arXiv:2005.00955*, 2020.

Lippe, P., Holla, N., Chandra, S., Rajamanickam, S., Antonius, G., Shutova, E., 与 Yannakoudakis, H. 一种用于检测仇恨表情包的多模态框架. *arXiv preprint arXiv:2012.12871*, 2020.

刘鹏杰、Saleh, M.、Pot, E.、Goodrich, B.、Sepassi, R.、Kaiser, L. 和 Shazeer, N. 通过总结长序列生成维基百科. *arXiv preprint arXiv:1801.10198*, 2018年。

洛卡特洛, F., 鲍尔, S., 卢西奇, M., Rätsch, G., 盖利, S., 施尔科普夫, B., 与巴切姆, O. 对无监督学习解耦表示及其评估的冷静审视. *arXiv preprint arXiv:2010.14766*, 2020年。

洛施奇洛夫, I. 和胡特, F. Sgdr: 带热重启的随机梯度下降法. *arXiv preprint arXiv:1608.03983*, 2016年。

Loshchilov, I. 和 Hutter, F. 解耦权重衰减正则化. *arXiv preprint arXiv:1711.05101*, 2017年。

陆静、巴特拉、帕里克与李晨在2019年发表的《Vilbert: 面向视觉与语言任务的预训练任务无关视觉语言表征》一文中, 于*Advances in Neural Information Processing Systems*第13至23页提出了该研究成果。

Lu, Z., Xiong, X., Li, Y., Stroud, J., 与 Ross, D. 利用弱监督数据和姿态表示进行动作识别, 2020。网址 <https://www.youtube.com/watch?v=KOQFxbPPLOE&t=1390s>。

卢西奇, M., 库拉赫, K., 米哈尔斯基, M., 盖利, S., 和布斯奎特, O. GAN是否生而平等? 一项大规模研究. *Advances in neural information processing systems*, 31: 700–709, 2018.

Mahajan, D., Girshick, R., Ramanathan, V., He, K., Paluri, M., Li, Y., Bharambe, A., 与 van der Maaten, L. 探索弱监督预训练的极限. 收录于

Proceedings of the European Conference on Computer Vision (ECCV), 第181–196页, 2018年。

麦肯恩, B., 布拉德伯里, J., 熊, C., 与索彻, R. 翻译中的学习: 上下文词向量. 载于 *Advances in neural information processing systems*, 第62 94–6305页, 2017年。

McCann, B., Keskar, N. S., Xiong, C., 与 Socher, R. 自然语言十项全能: 多任务学习即问答. *arXiv preprint arXiv:1806.08730*, 2018年。

Micikevicius, P., Narang, S., Alben, J., Diamos, G., Elsen, E., Garcia, D., Ginsburg, B., Houston, M., Kuchaiev, O., Venkatesh, G., 等. 混合精度训练. *arXiv preprint arXiv:1710.03740*, 2017.

Miech, A., Zhukov, D., Alayrac, J.-B., Tapaswi, M., Laptev, I., 与 Sivic, J. Howto100m: 通过观看上亿条旁白视频片段学习文本-视频嵌入. 载于 *Proceedings of the IEEE international conference on computer vision*, 第2630–2640页, 2019年。

Miech, A., Alayrac, J.-B., Laptev, I., Sivic, J., 与 Zisserman, A. Rareact: 记录异常互动的视频数据集. *arXiv preprint arXiv:2008.01018*, 2020a。

Miech, A., Alayrac, J.-B., Smaira, L., Laptev, I., Sivic, J., 与 Zisserman, A. 从未经筛选的教学视频中端到端学习视觉表示. 载于 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 第9879–9889页, 2020b年。

Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., 与 Dean, J. 单词与短语的分布式表示及其组合性. *Advances in neural information processing systems*, 26:3 111–3119, 2013年。

米勒, J., 克劳斯, K., 雷希特, B., 和施密特, L. 自然分布偏移对问答模型的影响. *arXiv preprint arXiv:2004.14444*, 2020.

Mishra, A., Alahari, K., 与 Jawahar, C. 利用高阶语言先验的场景文本识别. 2012。

Mithun, N. C., Panda, R., Papalexakis, E. E., 与 Roy-Chowdhury, A. K. 基于网络监督的跨模态图像-文本检索联合嵌入方法. 载于 *Proceedings of the 26th ACM international conference on Multimedia*, 第1 856–1864页, 2018年。

森, Y., 高桥, H., 和冈, R. 基于图像分割与向量量化结合词语的图像到文字转换. Citeseer, 1999年。

Mu, J., Liang, P., 与 Goodman, N. 用语言塑造视觉表征以实现少样本分类. *arXiv preprint arXiv:1911.02683*, 2019年。

Muller-Budack, E., Pustu-Iren, K., 与 Ewerth, R. 利用层次模型与场景分类的照片地理位置估算。载于 *Proceedings of the European Conference on Computer Vision (ECCV)*, 第563–579页, 2018年。

Murty, S., Koh, P. W., 与 Liang, P. Expbert: 利用自然语言解释进行表示工程。arXiv preprint arXiv:2005.01932, 2020年。

Narasimhan, K., Kulkarni, T., 与 Barzilay, R. 基于深度强化学习的文本游戏语言理解。arXiv preprint arXiv:1506.08941, 2015.

Netzer, Y., Wang, T., Coates, A., Bissacco, A., Wu, B., 与 Ng, A. Y. 通过无监督特征学习识别自然图像中的数字。2011。

诺布尔, S. U. 《压迫的算法: 搜索引擎如何强化种族主义》。2018。

Nosek, B. A., Banaji, M. R., 与 Greenwald, A. G. 从示范网站中采集内隐群体态度与信念。Group Dynamics: Theory, Research, and Practice, 6(1):101, 2002.

哦, S., 胡格斯, A., 佩雷拉, A., 坎图尔, N., 陈, C.-C., 李, J. T., 穆克吉, S., 阿加瓦尔, J., 李, H., 戴维斯, L., 等。用于监控视频中事件识别的大规模基准数据集。载于CVPR 2011, 第3153–3160页。IEE, 2011年。

奥利弗, A., 奥德纳, A., 拉菲尔, C. A., 丘布克, E. D., 与 古德费洛, I. 深度半监督学习算法的现实评估。Advances in neural information processing systems, 31:3235–3246, 2018.

奥德, A. v. d., 李, Y., 和维尼尔斯, O. 基于对比预测编码的表征学习。arXiv preprint arXiv:1807.03748, 2018.

Ordonez, V., Kulkarni, G., 与 Berg, T. Im2text: 使用百万张带标题照片描述图像。Advances in neural information processing systems, 24:1143–1151, 2011年。

pandas开发团队, T. pandas-dev/pandas: Pan-das, 2020年2月。URL <https://doi.org/10.5281/zenodo.3509134>。

帕尔基, O. M., 维达利, A., 齐瑟曼, A., 与贾瓦哈尔, C. V. 猫与狗。载于IEEE Conference on Computer Vision and Pattern Recognition, 2012年。

帕斯克, A., 格罗斯, S., 马萨, F., 勒雷尔, A., 布拉德伯里, J., 钱南, G., 基林, T., 林, Z., 吉梅尔申, N., 安蒂加, L., 德斯梅森, A., 科普夫, A., 杨, E., 德维托, Z., 瑞森, M., 特贾尼, A., 奇拉姆库尔西, S., 斯坦纳, B., 方, L.,

白静、钦塔拉。PyTorch: 一种命令式风格的高性能深度学习库。于Advances in Neural Information Processing Systems 32, 第8024–8035页, 2019年。

佩德雷戈萨, F., 瓦罗夸, G., 格拉姆福特, A., 米歇尔, V., 蒂里翁, B., 格里塞尔, O., 布隆德尔, M., 普雷滕霍费尔, P., 韦斯, R., 杜堡, V., 范德普拉斯, J., 帕索斯, A., 库尔纳波, D., 布鲁谢, M., 佩罗, M., 和杜谢奈, E. Scikit-learn : Python中的机器学习。Journal of Machine Learning Research, 12:2825–2830, 2011年。

彭宁顿 (Pennington, J.)、索赫尔 (Socher, R.) 和曼宁 (Manning, C. D.) 合著的《GloVe: 词表示的全局向量》一文, 发表于Proceedings of the 2014 conference on empirical methods in natural language processing (EMNLP), 第1532–1543页, 2014彼得斯 (Peters, M. E.)、纽曼 (Neumann, M.)、伊耶尔 (Iyyer, M.)、加德纳 (Gardner, M.)、克拉克 (Clark, C.)、李 (Lee, K.) 和泽特勒迈尔 (Zettlemoyer, L.)。深度上下文词表征。arXiv preprint arXiv:1802.05365, 2018年。

齐东、苏力、宋杰、崔恩、巴蒂·T和萨切蒂·A。Image BERT: 基于大规模弱监督图文数据的跨模态预训练。arXiv preprint arXiv:2001.07966, 2020年。

Quattoni, A., Collins, M., 与 Darrell, T. 利用带标题的图像学习视觉表示。刊于2007 IEEE Conference on Computer Vision and Pattern Recognition, 第1–8页。IEEE, 2007年。

Radford, A., Narasimhan, K., Salimans, T., 与 Sutskever, I. 通过生成式预训练提升语言理解能力, 2018。

Radford, A., Wu, J., Child, R., Luan, D., Amodei, D., 与 Sutskever, I. 语言模型是无监督多任务学习者。2019。

Raffel, C., Shazeer, N., Roberts, A., Lee, K., Narang, S., Matena, M., Zhou, Y., Li, W., 与 Liu, P. J. 探索统一文本到文本转换器的迁移学习极限。arXiv preprint arXiv:1910.10683, 2019。

Raji, I. D., Gebru, T., Mitchell, M., Buolamwini, J., Lee, J., 与 Denton, E. 《直面问题: 面部识别审计中的伦理关切研究》, 2020年。

拉马纳坦, V., 梁, P., 和李飞飞。利用自然语言描述理解视频事件。载于Proceedings of the IEEE International Conference on Computer Vision, 第905–912页, 2013年。

Rashtchian, C., Young, P., Hodosh, M., 与 Hockenmaier, J. 利用亚马逊土耳其机器人收集图像标注。载于Proceedings of the NAACL HLT 2010 Workshop on Creating Speech and Language Data with Amazon's Mechanical Turk, 第139–147页, 2010年。

- Recht, B., Roelofs, R., Schmidt, L., 和 Shankar, V. Image Net分类器能否泛化至ImageNet? *arXiv preprint arXiv:1902.10811*, 2019年。
- Salimans, T. 和 Kingma, D. P. 权重归一化: 一种加速深度神经网络训练的简单重参数化方法。于 *Advances in neural information processing systems*, 页 9 01–909, 2016年。
- Scheuerman, M. K., Paul, J. M., 与 Brubaker, J. R. 计算机如何识别性别: 商业面部分析服务中的性别分类评估。于 *Proceedings of the ACM on Human-Computer Interaction*, 3(CSCW): 1 –33, 2019.
- 施韦默、C.、奈特、C.、贝洛-帕尔多、E. D.、奥克洛布贾、S.、斯洪维尔德、M. 和洛克哈特、J. W. 诊断图像识别系统中的性别偏见。 *Socius*, 6: 237802312096717 1, 2020年。
- Sennrich, R., Haddow, B., 和 Birch, A. 使用子词单元进行稀有词汇的神经机器翻译。 *arXiv preprint arXiv:1508.07909*, 2015年。
- Shankar, V., Dave, A., Roelofs, R., Ramanan, D., Recht, B., 与 Schmidt, L. 图像分类器能否跨越时间泛化? *arXiv preprint arXiv:1906.02168*, 2019。
- Sharma, P., Ding, N., Goodman, S., 与 Soriceut, R. 概念性标注: 一个经过清洗、上位词化处理的图像替代文本数据集, 用于自动图像描述生成。于 *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 第2556–25 65页, 2018年。
- 辛格、纳塔拉詹、沙阿、姜、陈、巴特拉、帕里克与罗尔巴赫。迈向能够阅读的VQA模型。发表于 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 第8 317–8326页, 2019年。
- Socher, R. 与 Fei-Fei, L. 连接多模态: 利用未对齐文本语料库进行半监督图像分割与标注。载于 *2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 第966–973页。IEEE, 2010年。
- Socher, R., Perelygin, A., Wu, J., Chuang, J., Manning, C. D., Ng, A. Y., 与 Potts, C. 基于情感树库的语义组合性递归深度模型。载于 *Proceedings of the 2013 conference on empirical methods in natural language processing*, 第1631–1642页, 2013年。
- Socher, R., Karpathy, A., Le, Q. V., Manning, C. D., 与 Ng, A. Y. 基于组合语义的图像句子检索与描述生成。 *Transactions of the Association for Computational Linguistics*, 2:207–218, 2 014.
- Sohn, K. 改进的深度度量学习与多类别n对损失目标。载于 *Advances in neural informationprocessing systems*, 第1857–1865页, 2016年。
- 索莱曼, I., 布伦戴奇, M., 克拉克, J., 阿斯克尔, A., 赫伯特-沃斯, A., 吴, J., 拉德福德, A., 克鲁格, G., 金, J. W., 克雷普斯, S., 麦凯恩, M., 纽豪斯, A., 布拉扎基斯, J., 麦古菲, K., 和王, J. 语言模型的发布策略与社会影响, 2019。
- Soomro, K., Zamir, A. R., 与 Shah, M. Ucf101: 一个包含101类野外视频人类动作的数据集。 *arXiv preprint arXiv:1212.0402*, 2012年。
- 斯佩尔, R. ftfy. Zenodo, 2019. 网址 <https://doi.org/10.5281/zenodo.2591652>. 版本5.5.
- Srivastava, N. 和 Salakhutdinov, R. 使用深度玻尔兹曼机进行多模态学习。见 *NIPS*, 2012年。
- Srivastava, S., Labutov, I., 与 Mitchell, T. 从自然语言解释中联合学习概念与语义解析。见 *Proceedings of the 2017 conference on empirical methods in natural language processing*, 第1 527–1536页, 2017年。
- Stallkamp, J., Schlipsing, M., Salmen, J., 与 Igel, C. 德国交通标志识别基准: 一项多类别分类竞赛。载于 *IEEE InternationalJoint Conference on Neural Networks*, 第1453–1460页, 2011年。
- Stroud, J. C., Ross, D. A., Sun, C., Deng, J., Sukthankar, R., 与 Schmid, C. 从文本网络监督中学习视频表示。 *arXiv preprint arXiv:2007.14937*, 2020。
- Szegedy, C., Ioffe, S., Vanhoucke, V., 和 Alemi, A. Inception-v4、Inception-ResNet及残差连接对学习的影响。 *arXiv preprint arXiv:1602.07261*, 2016年。
- 谭, H. 和 Bansal, M. Lxmert: 基于Transformer学习跨模态编码器表示。 *arXiv preprint arXiv:1908.07490*, 2019年。
- 谭铭与乐清伟。EfficientNet: 重新思考卷积神经网络的模型缩放。 *arXiv preprint arXiv:1905.11946*, 2019年。
- 陶里, R., 戴夫, A., 尚卡尔, V., 卡里尼, N., 雷希特, B., 与施密特, L. 测量图像分类对自然分布偏移的鲁棒性。 *arXiv preprint arXiv:2007.00644*, 2020年。
- Thomee, B., Shamma, D. A., Friedland, G., Elizalde, B., Ni, K., Poland, D., Borth, D., 与 Li, L.-J. Yfcc100m: 多媒体研究中的新数据。 *Communications of the ACM*, 59(2): 64–73, 2016.

田毅、Krishnan, D. 和 Isola, P. 对比多视图编码。
arXiv preprint arXiv:1906.05849, 2019年。

田雨、王洋、D. Krishnan、J. B. Tenenbaum 和 P. Isola , 《重新思考小样本图像分类: 一个好的嵌入向量就足够了吗?》*arXiv preprint arXiv:2003.11539*, 2020年。

托拉尔巴 (Torralba, A.) 、弗格斯 (Fergus, R.) 和弗里曼 (Freeman, W. T.) 。八千万微小图像: 用于非参数化物体与场景识别的大规模数据集。

IEEE transactions on pattern analysis and machine intelligence, 30(11):1958–1970, 2008年。

Touvron, H., Vedaldi, A., Douze, M., 与 Jégou, H. 修复训练-测试分辨率差异。载于 *Advances in neural information processing systems*, 第8252–8262页, 2019年。

Varadarajan, J. 与 Odobeza, J.-M. 面向场景分析与异常检测的主题模型。载于 *2009 IEEE 12th International Conference on Computer Vision Workshops, ICCV Workshops*, 第1338–1345页。IEEE, 2009年。

瓦斯瓦尼 (Vaswani, A.) 、沙泽尔 (Shazeer, N.) 、帕尔玛 (Parmar, N.) 、乌斯祖雷特 (Uszkoreit, J.) 、琼斯 (Jones, L.) 、戈麦斯 (Gomez, A. N.) 、凯泽 (Kaiser,) 与波洛苏金 (Polosukhin, I.) 合著, 《注意力就是你所需要的一切》。载于 *Advances in neural information processing systems*, 第59 Advances in neural information processing systems, 第59 98–600页, 2017年。面向数字病理学的旋转等变卷积神经网络。2018年6月。

维尔塔宁 (Virtanen, P.) 、戈默斯 (Gommers, R.) 、奥列芬特 (Oliphant, T. E.) 、哈伯兰 (Haberland, M.) 、雷迪 (Reddy, T.) 、库尔纳波 (Cournapeau, D.) 、布罗夫斯基 (Burovski, E.) 、彼得森 (Peterson, P.) 、韦克瑟 (Weckesser, W.) 、布赖特 (Bright, J.) 、范德沃尔特 (van der Walt, S. J.) 、布雷特 (Brett, M.) 、威尔逊 (Wilson, J.) 、米尔曼 (Millman, K. J.) 、马约罗夫 (Mayorov, N.) 、纳尔逊 (Nelson, A. R. J.) 、琼斯 (Jones, E.) 、克恩 (Kern, R.) 、拉尔森 (Larson, E.) 、凯里 (Carey, C. J.) 、波拉特 (Polat, İ.) 、冯 (Feng, Y.) 、摩尔 (Moore, E. W.) 、范德普拉斯 (VanderPlas, J.) 、拉克萨尔德 (Laxalde, D.) 、佩尔克托尔德 (Perktold, J.) 、西姆尔曼 (Cimrman, R.) 、亨里克森 (Henriksen, I.) 、金特罗 (Quintero, E. A.) 、哈里斯 (Harris, C. R.) 、阿奇博尔德 (Archibald, WoMN), Jacob贝罗 (Ribeiro, J.A) 深度学习图像识别 (Deep learning) 载于 *Proc. NeurIPS 2017* 及 *Proc. NeurIPS 2018* 载于 *Proc. NeurIPS 2018* 载于 *Proc. NeurIPS 2019* 载于 *Proc. NeurIPS 2020* 载于 *Proc. NeurIPS 2021* 载于 *Proc. NeurIPS 2022* 载于 *Proc. NeurIPS 2023* 载于 *Proc. NeurIPS 2024* 载于 *Proc. NeurIPS 2025* 载于 *Proc. NeurIPS 2026* 载于 *Proc. NeurIPS 2027* 载于 *Proc. NeurIPS 2028* 载于 *Proc. NeurIPS 2029* 载于 *Proc. NeurIPS 2030* 载于 *Proc. NeurIPS 2031* 载于 *Proc. NeurIPS 2032* 载于 *Proc. NeurIPS 2033* 载于 *Proc. NeurIPS 2034* 载于 *Proc. NeurIPS 2035* 载于 *Proc. NeurIPS 2036* 载于 *Proc. NeurIPS 2037* 载于 *Proc. NeurIPS 2038* 载于 *Proc. NeurIPS 2039* 载于 *Proc. NeurIPS 2040* 载于 *Proc. NeurIPS 2041* 载于 *Proc. NeurIPS 2042* 载于 *Proc. NeurIPS 2043* 载于 *Proc. NeurIPS 2044* 载于 *Proc. NeurIPS 2045* 载于 *Proc. NeurIPS 2046* 载于 *Proc. NeurIPS 2047* 载于 *Proc. NeurIPS 2048* 载于 *Proc. NeurIPS 2049* 载于 *Proc. NeurIPS 2050* 载于 *Proc. NeurIPS 2051* 载于 *Proc. NeurIPS 2052* 载于 *Proc. NeurIPS 2053* 载于 *Proc. NeurIPS 2054* 载于 *Proc. NeurIPS 2055* 载于 *Proc. NeurIPS 2056* 载于 *Proc. NeurIPS 2057* 载于 *Proc. NeurIPS 2058* 载于 *Proc. NeurIPS 2059* 载于 *Proc. NeurIPS 2060* 载于 *Proc. NeurIPS 2061* 载于 *Proc. NeurIPS 2062* 载于 *Proc. NeurIPS 2063* 载于 *Proc. NeurIPS 2064* 载于 *Proc. NeurIPS 2065* 载于 *Proc. NeurIPS 2066* 载于 *Proc. NeurIPS 2067* 载于 *Proc. NeurIPS 2068* 载于 *Proc. NeurIPS 2069* 载于 *Proc. NeurIPS 2070* 载于 *Proc. NeurIPS 2071* 载于 *Proc. NeurIPS 2072* 载于 *Proc. NeurIPS 2073* 载于 *Proc. NeurIPS 2074* 载于 *Proc. NeurIPS 2075* 载于 *Proc. NeurIPS 2076* 载于 *Proc. NeurIPS 2077* 载于 *Proc. NeurIPS 2078* 载于 *Proc. NeurIPS 2079* 载于 *Proc. NeurIPS 2080* 载于 *Proc. NeurIPS 2081* 载于 *Proc. NeurIPS 2082* 载于 *Proc. NeurIPS 2083* 载于 *Proc. NeurIPS 2084* 载于 *Proc. NeurIPS 2085* 载于 *Proc. NeurIPS 2086* 载于 *Proc. NeurIPS 2087* 载于 *Proc. NeurIPS 2088* 载于 *Proc. NeurIPS 2089* 载于 *Proc. NeurIPS 2090* 载于 *Proc. NeurIPS 2091* 载于 *Proc. NeurIPS 2092* 载于 *Proc. NeurIPS 2093* 载于 *Proc. NeurIPS 2094* 载于 *Proc. NeurIPS 2095* 载于 *Proc. NeurIPS 2096* 载于 *Proc. NeurIPS 2097* 载于 *Proc. NeurIPS 2098* 载于 *Proc. NeurIPS 2099* 载于 *Proc. NeurIPS 2100* 载于 *Proc. NeurIPS 2101* 载于 *Proc. NeurIPS 2102* 载于 *Proc. NeurIPS 2103* 载于 *Proc. NeurIPS 2104* 载于 *Proc. NeurIPS 2105* 载于 *Proc. NeurIPS 2106* 载于 *Proc. NeurIPS 2107* 载于 *Proc. NeurIPS 2108* 载于 *Proc. NeurIPS 2109* 载于 *Proc. NeurIPS 2110* 载于 *Proc. NeurIPS 2111* 载于 *Proc. NeurIPS 2112* 载于 *Proc. NeurIPS 2113* 载于 *Proc. NeurIPS 2114* 载于 *Proc. NeurIPS 2115* 载于 *Proc. NeurIPS 2116* 载于 *Proc. NeurIPS 2117* 载于 *Proc. NeurIPS 2118* 载于 *Proc. NeurIPS 2119* 载于 *Proc. NeurIPS 2120* 载于 *Proc. NeurIPS 2121* 载于 *Proc. NeurIPS 2122* 载于 *Proc. NeurIPS 2123* 载于 *Proc. NeurIPS 2124* 载于 *Proc. NeurIPS 2125* 载于 *Proc. NeurIPS 2126* 载于 *Proc. NeurIPS 2127* 载于 *Proc. NeurIPS 2128* 载于 *Proc. NeurIPS 2129* 载于 *Proc. NeurIPS 2130* 载于 *Proc. NeurIPS 2131* 载于 *Proc. NeurIPS 2132* 载于 *Proc. NeurIPS 2133* 载于 *Proc. NeurIPS 2134* 载于 *Proc. NeurIPS 2135* 载于 *Proc. NeurIPS 2136* 载于 *Proc. NeurIPS 2137* 载于 *Proc. NeurIPS 2138* 载于 *Proc. NeurIPS 2139* 载于 *Proc. NeurIPS 2140* 载于 *Proc. NeurIPS 2141* 载于 *Proc. NeurIPS 2142* 载于 *Proc. NeurIPS 2143* 载于 *Proc. NeurIPS 2144* 载于 *Proc. NeurIPS 2145* 载于 *Proc. NeurIPS 2146* 载于 *Proc. NeurIPS 2147* 载于 *Proc. NeurIPS 2148* 载于 *Proc. NeurIPS 2149* 载于 *Proc. NeurIPS 2150* 载于 *Proc. NeurIPS 2151* 载于 *Proc. NeurIPS 2152* 载于 *Proc. NeurIPS 2153* 载于 *Proc. NeurIPS 2154* 载于 *Proc. NeurIPS 2155* 载于 *Proc. NeurIPS 2156* 载于 *Proc. NeurIPS 2157* 载于 *Proc. NeurIPS 2158* 载于 *Proc. NeurIPS 2159* 载于 *Proc. NeurIPS 2160* 载于 *Proc. NeurIPS 2161* 载于 *Proc. NeurIPS 2162* 载于 *Proc. NeurIPS 2163* 载于 *Proc. NeurIPS 2164* 载于 *Proc. NeurIPS 2165* 载于 *Proc. NeurIPS 2166* 载于 *Proc. NeurIPS 2167* 载于 *Proc. NeurIPS 2168* 载于 *Proc. NeurIPS 2169* 载于 *Proc. NeurIPS 2170* 载于 *Proc. NeurIPS 2171* 载于 *Proc. NeurIPS 2172* 载于 *Proc. NeurIPS 2173* 载于 *Proc. NeurIPS 2174* 载于 *Proc. NeurIPS 2175* 载于 *Proc. NeurIPS 2176* 载于 *Proc. NeurIPS 2177* 载于 *Proc. NeurIPS 2178* 载于 *Proc. NeurIPS 2179* 载于 *Proc. NeurIPS 2180* 载于 *Proc. NeurIPS 2181* 载于 *Proc. NeurIPS 2182* 载于 *Proc. NeurIPS 2183* 载于 *Proc. NeurIPS 2184* 载于 *Proc. NeurIPS 2185* 载于 *Proc. NeurIPS 2186* 载于 *Proc. NeurIPS 2187* 载于 *Proc. NeurIPS 2188* 载于 *Proc. NeurIPS 2189* 载于 *Proc. NeurIPS 2190* 载于 *Proc. NeurIPS 2191* 载于 *Proc. NeurIPS 2192* 载于 *Proc. NeurIPS 2193* 载于 *Proc. NeurIPS 2194* 载于 *Proc. NeurIPS 2195* 载于 *Proc. NeurIPS 2196* 载于 *Proc. NeurIPS 2197* 载于 *Proc. NeurIPS 2198* 载于 *Proc. NeurIPS 2199* 载于 *Proc. NeurIPS 2200* 载于 *Proc. NeurIPS 2201* 载于 *Proc. NeurIPS 2202* 载于 *Proc. NeurIPS 2203* 载于 *Proc. NeurIPS 2204* 载于 *Proc. NeurIPS 2205* 载于 *Proc. NeurIPS 2206* 载于 *Proc. NeurIPS 2207* 载于 *Proc. NeurIPS 2208* 载于 *Proc. NeurIPS 2209* 载于 *Proc. NeurIPS 2210* 载于 *Proc. NeurIPS 2211* 载于 *Proc. NeurIPS 2212* 载于 *Proc. NeurIPS 2213* 载于 *Proc. NeurIPS 2214* 载于 *Proc. NeurIPS 2215* 载于 *Proc. NeurIPS 2216* 载于 *Proc. NeurIPS 2217* 载于 *Proc. NeurIPS 2218* 载于 *Proc. NeurIPS 2219* 载于 *Proc. NeurIPS 2220* 载于 *Proc. NeurIPS 2221* 载于 *Proc. NeurIPS 2222* 载于 *Proc. NeurIPS 2223* 载于 *Proc. NeurIPS 2224* 载于 *Proc. NeurIPS 2225* 载于 *Proc. NeurIPS 2226* 载于 *Proc. NeurIPS 2227* 载于 *Proc. NeurIPS 2228* 载于 *Proc. NeurIPS 2229* 载于 *Proc. NeurIPS 2230* 载于 *Proc. NeurIPS 2231* 载于 *Proc. NeurIPS 2232* 载于 *Proc. NeurIPS 2233* 载于 *Proc. NeurIPS 2234* 载于 *Proc. NeurIPS 2235* 载于 *Proc. NeurIPS 2236* 载于 *Proc. NeurIPS 2237* 载于 *Proc. NeurIPS 2238* 载于 *Proc. NeurIPS 2239* 载于 *Proc. NeurIPS 2240* 载于 *Proc. NeurIPS 2241* 载于 *Proc. NeurIPS 2242* 载于 *Proc. NeurIPS 2243* 载于 *Proc. NeurIPS 2244* 载于 *Proc. NeurIPS 2245* 载于 *Proc. NeurIPS 2246* 载于 *Proc. NeurIPS 2247* 载于 *Proc. NeurIPS 2248* 载于 *Proc. NeurIPS 2249* 载于 *Proc. NeurIPS 2250* 载于 *Proc. NeurIPS 2251* 载于 *Proc. NeurIPS 2252* 载于 *Proc. NeurIPS 2253* 载于 *Proc. NeurIPS 2254* 载于 *Proc. NeurIPS 2255* 载于 *Proc. NeurIPS 2256* 载于 *Proc. NeurIPS 2257* 载于 *Proc. NeurIPS 2258* 载于 *Proc. NeurIPS 2259* 载于 *Proc. NeurIPS 2260* 载于 *Proc. NeurIPS 2261* 载于 *Proc. NeurIPS 2262* 载于 *Proc. NeurIPS 2263* 载于 *Proc. NeurIPS 2264* 载于 *Proc. NeurIPS 2265* 载于 *Proc. NeurIPS 2266* 载于 *Proc. NeurIPS 2267* 载于 *Proc. NeurIPS 2268* 载于 *Proc. NeurIPS 2269* 载于 *Proc. NeurIPS 2270* 载于 *Proc. NeurIPS 2271* 载于 *Proc. NeurIPS 2272* 载于 *Proc. NeurIPS 2273* 载于 *Proc. NeurIPS 2274* 载于 *Proc. NeurIPS 2275* 载于 *Proc. NeurIPS 2276* 载于 *Proc. NeurIPS 2277* 载于 *Proc. NeurIPS 2278* 载于 *Proc. NeurIPS 2279* 载于 *Proc. NeurIPS 2280* 载于 *Proc. NeurIPS 2281* 载于 *Proc. NeurIPS 2282* 载于 *Proc. NeurIPS 2283* 载于 *Proc. NeurIPS 2284* 载于 *Proc. NeurIPS 2285* 载于 *Proc. NeurIPS 2286* 载于 *Proc. NeurIPS 2287* 载于 *Proc. NeurIPS 2288* 载于 *Proc. NeurIPS 2289* 载于 *Proc. NeurIPS 2290* 载于 *Proc. NeurIPS 2291* 载于 *Proc. NeurIPS 2292* 载于 *Proc. NeurIPS 2293* 载于 *Proc. NeurIPS 2294* 载于 *Proc. NeurIPS 2295* 载于 *Proc. NeurIPS 2296* 载于 *Proc. NeurIPS 2297* 载于 *Proc. NeurIPS 2298* 载于 *Proc. NeurIPS 2299* 载于 *Proc. NeurIPS 2300* 载于 *Proc. NeurIPS 2301* 载于 *Proc. NeurIPS 2302* 载于 *Proc. NeurIPS 2303* 载于 *Proc. NeurIPS 2304* 载于 *Proc. NeurIPS 2305* 载于 *Proc. NeurIPS 2306* 载于 *Proc. NeurIPS 2307* 载于 *Proc. NeurIPS 2308* 载于 *Proc. NeurIPS 2309* 载于 *Proc. NeurIPS 2310* 载于 *Proc. NeurIPS 2311* 载于 *Proc. NeurIPS 2312* 载于 *Proc. NeurIPS 2313* 载于 *Proc. NeurIPS 2314* 载于 *Proc. NeurIPS 2315* 载于 *Proc. NeurIPS 2316* 载于 *Proc. NeurIPS 2317* 载于 *Proc. NeurIPS 2318* 载于 *Proc. NeurIPS 2319* 载于 *Proc. NeurIPS 2320* 载于 *Proc. NeurIPS 2321* 载于 *Proc. NeurIPS 2322* 载于 *Proc. NeurIPS 2323* 载于 *Proc. NeurIPS 2324* 载于 *Proc. NeurIPS 2325* 载于 *Proc. NeurIPS 2326* 载于 *Proc. NeurIPS 2327* 载于 *Proc. NeurIPS 2328* 载于 *Proc. NeurIPS 2329* 载于 *Proc. NeurIPS 2330* 载于 *Proc. NeurIPS 2331* 载于 *Proc. NeurIPS 2332* 载于 *Proc. NeurIPS 2333* 载于 *Proc. NeurIPS 2334* 载于 *Proc. NeurIPS 2335* 载于 *Proc. NeurIPS 2336* 载于 *Proc. NeurIPS 2337* 载于 *Proc. NeurIPS 2338* 载于 *Proc. NeurIPS 2339* 载于 *Proc. NeurIPS 2340* 载于 *Proc. NeurIPS 2341* 载于 *Proc. NeurIPS 2342* 载于 *Proc. NeurIPS 2343* 载于 *Proc. NeurIPS 2344* 载于 *Proc. NeurIPS 2345* 载于 *Proc. NeurIPS 2346* 载于 *Proc. NeurIPS 2347* 载于 *Proc. NeurIPS 2348* 载于 *Proc. NeurIPS 2349* 载于 *Proc. NeurIPS 2350* 载于 *Proc. NeurIPS 2351* 载于 *Proc. NeurIPS 2352* 载于 *Proc. NeurIPS 2353* 载于 *Proc. NeurIPS 2354* 载于 *Proc. NeurIPS 2355* 载于 *Proc. NeurIPS 2356* 载于 *Proc. NeurIPS 2357* 载于 *Proc. NeurIPS 2358* 载于 *Proc. NeurIPS 2359* 载于 *Proc. NeurIPS 2360* 载于 *Proc. NeurIPS 2361* 载于 *Proc. NeurIPS 2362* 载于 *Proc. NeurIPS 2363* 载于 *Proc. NeurIPS 2364* 载于 *Proc. NeurIPS 2365* 载于 *Proc. NeurIPS 2366* 载于 *Proc. NeurIPS 2367* 载于 *Proc. NeurIPS 2368* 载于 *Proc. NeurIPS 2369* 载于 *Proc. NeurIPS 2370* 载于 *Proc. NeurIPS 2371* 载于 *Proc. NeurIPS 2372* 载于 *Proc. NeurIPS 2373* 载于 *Proc. NeurIPS 2374* 载于 *Proc. NeurIPS 2375* 载于 *Proc. NeurIPS 2376* 载于 *Proc. NeurIPS 2377* 载于 *Proc. NeurIPS 2378* 载于 *Proc. NeurIPS 2379* 载于 *Proc. NeurIPS 2380* 载于 *Proc. NeurIPS 2381* 载于 *Proc. NeurIPS 2382* 载于 *Proc. NeurIPS 2383* 载于 *Proc. NeurIPS 2384* 载于 *Proc. NeurIPS 2385* 载于 *Proc. NeurIPS 2386* 载于 *Proc. NeurIPS 2387* 载于 *Proc. NeurIPS 2388* 载于 *Proc. NeurIPS 2389* 载于 *Proc. NeurIPS 2390* 载于 *Proc. NeurIPS 2391* 载于 *Proc. NeurIPS 2392* 载于 *Proc. NeurIPS 2393* 载于 *Proc. NeurIPS 2394* 载于 *Proc. NeurIPS 2395* 载于 *Proc. NeurIPS 2396* 载于 *Proc. NeurIPS 2397* 载于 *Proc. NeurIPS 2398* 载于 *Proc. NeurIPS 2399* 载于 *Proc. NeurIPS 2400* 载于 *Proc. NeurIPS 2401* 载于 *Proc. NeurIPS 2402* 载于 *Proc. NeurIPS 2403* 载于 *Proc. NeurIPS 2404* 载于 *Proc. NeurIPS 2405* 载于 *Proc. NeurIPS 2406* 载于 *Proc. NeurIPS 2407* 载于 *Proc. NeurIPS 2408* 载于 *Proc. NeurIPS 2409* 载于 *Proc. NeurIPS 2410* 载于 *Proc. NeurIPS 2411* 载于 *Proc. NeurIPS 2412* 载于 *Proc. NeurIPS 2413* 载于 *Proc. NeurIPS 2414* 载于 *Proc. NeurIPS 2415* 载于 *Proc. NeurIPS 2416* 载于 *Proc. NeurIPS 2417* 载于 *Proc. NeurIPS 2418* 载于 *Proc. NeurIPS 2419* 载于 *Proc. NeurIPS 2420* 载于 *Proc. NeurIPS 2421* 载于 *Proc. NeurIPS 2422* 载于 *Proc. NeurIPS 2423* 载于 *Proc. NeurIPS 2424* 载于 *Proc. NeurIPS 2425* 载于 *Proc. NeurIPS 2426* 载于 *Proc. NeurIPS 2427* 载于 *Proc. NeurIPS 2428* 载于 *Proc. NeurIPS 2429* 载于 *Proc. NeurIPS 2430* 载于 *Proc. NeurIPS 2431* 载于 *Proc. NeurIPS 2432* 载于 *Proc. NeurIPS 2433* 载于 *Proc. NeurIPS 2434* 载于 *Proc. NeurIPS 2435* 载于 *Proc. NeurIPS 2436* 载于 *Proc. NeurIPS 2437* 载于 *Proc. NeurIPS 2438* 载于 *Proc. NeurIPS 2439* 载于 *Proc. NeurIPS 2440* 载于 *Proc. NeurIPS 2441* 载于 *Proc. NeurIPS 2442* 载于 *Proc. NeurIPS 2443* 载于 *Proc. NeurIPS 2444* 载于 *Proc. NeurIPS 2445* 载于 *Proc. NeurIPS 2446* 载于 *Proc. NeurIPS 2447* 载于 *Proc. NeurIPS 2448* 载于 *Proc. NeurIPS 2449* 载于 *Proc. NeurIPS 2450* 载于 *Proc. NeurIPS 2451* 载于 *Proc. NeurIPS 2452* 载于 *Proc. NeurIPS 2453* 载于 *Proc. NeurIPS 2454* 载于 *Proc. NeurIPS 2455* 载于 *Proc. NeurIPS 2456* 载于 *Proc. NeurIPS 2457* 载于 *Proc. NeurIPS 2458* 载于 *Proc. NeurIPS 2459* 载于 *Proc. NeurIPS 2460* 载于 *Proc. NeurIPS 2461* 载于 *Proc. NeurIPS 2462* 载于 *Proc. NeurIPS 2463* 载于 *Proc. NeurIPS 2464* 载于 *Proc. NeurIPS 2465* 载于 *Proc. NeurIPS 2466* 载于 *Proc. NeurIPS 2467* 载于 *Proc. NeurIPS 2468* 载于 *Proc. NeurIPS 2469* 载于 *Proc. NeurIPS 2470* 载于 *Proc. NeurIPS 2471* 载于 *Proc. NeurIPS 2472* 载于 *Proc. NeurIPS 2473* 载于 *Proc. NeurIPS 2474* 载于 *Proc. NeurIPS 2475* 载于 *Proc. NeurIPS 2476* 载于 *Proc. NeurIPS 2477* 载于 *Proc. NeurIPS 2478* 载于 *Proc. NeurIPS 2479* 载于 *Proc. NeurIPS 2480* 载于 *Proc. NeurIPS 2481* 载于 *Proc. NeurIPS 2482* 载于 *Proc. NeurIPS 2483* 载于 *Proc. NeurIPS 2484* 载于 *Proc. NeurIPS 2485* 载于 *Proc. NeurIPS 2486* 载于 *Proc. NeurIPS 2487* 载于 *Proc. NeurIPS 2488* 载于 *Proc. NeurIPS 2489* 载于 *Proc. NeurIPS 2490* 载于 *Proc. NeurIPS 2491* 载于 *Proc. NeurIPS 2492* 载于 *Proc. NeurIPS 2493* 载于 *Proc. NeurIPS 2494* 载于 *Proc. NeurIPS 2495* 载于 *Proc. NeurIPS 2496* 载于 *Proc. NeurIPS 2497* 载于 *Proc. NeurIPS 2498* 载于 *Proc. NeurIPS 2499* 载于 *Proc. NeurIPS 2500* 载于 *Proc. NeurIPS 2501* 载于 *Proc. NeurIPS 2502* 载于 *Proc. NeurIPS 2503* 载于 *Proc. NeurIPS 2504* 载于 *Proc. NeurIPS 2505* 载于 *Proc. NeurIPS 2506* 载于 *Proc. NeurIPS 2507* 载于 *Proc. NeurIPS 2508* 载于 *Proc. NeurIPS 2509* 载于 *Proc. NeurIPS 2510* 载于 *Proc. NeurIPS 2511* 载于 *Proc. NeurIPS 2512* 载于 *Proc. NeurIPS 2513* 载于 *Proc. NeurIPS 2514* 载于 *Proc. NeurIPS 2515* 载于 *Proc. NeurIPS 2516* 载于 *Proc. NeurIPS 2517* 载于 *Proc. NeurIPS 2518* 载于 *Proc. NeurIPS 2519* 载于 *Proc. NeurIPS 2520* 载于 *Proc. NeurIPS 2521* 载于 *Proc. NeurIPS*

Yu, F., Tang, J., Yin, W., Sun, Y., Tian, H., Wu, H., 与 Wang, H. ERNIE-ViL: 通过场景图增强的知识驱动视觉语言表示。*arXiv preprint arXiv:2006.16934*, 2020年。

Zeiler, M. D. 和 Fergus, R. 可视化和理解卷积网络。载于*European conference on computer vision*, 第818–833页。Springer出版社, 2014年。

翟旭、普伊格塞尔韦尔、科列斯尼科夫、鲁伊森、里克尔梅、卢西奇、乔隆加、平托、纽曼、多索维茨基等。一项基于视觉任务适应基准的大规模表征学习研究。*arXiv preprint arXiv:1910.04867*, 2019年。

张, R. 让卷积网络再次具有平移不变性。
arXiv preprint arXiv:1904.11486, 2019。

张, Y., 江, H., Miura, Y., Manning, C. D., 与 Langlotz, C. P. 基于配对图像与文本的医学视觉表征对比学习。
arXiv preprint arXiv:2010.00747, 2020.

祖博夫, S. 大型他者: 监控资本主义与信息文明的前景.
Journal of Information Technology, 30(1):75–89, 2015.

A. 线性探针评估

我们为本文中提出的线性探针实验提供了更多细节，包括用于评估的数据集和模型列表。

A.1. 数据集

我们采用了(Kornblith等人, 2019)提出的经过充分研究的评估套件中的12个数据集，并新增了15个数据集，以评估模型在更广泛分布和任务上的性能。这些数据集包括MNIST、面部表情识别2013数据集(Goodfellow等人, 2015)、STL-10(Coates等人, 2011)、EuroSAT(Helber等人, 2019)、NWPU-RESISC45数据集(Cheng等人, 2017)、德国交通标志识别基准(GTSRB)数据集(Stallkamp等人, 2011)、KITTI数据集(Geiger等人, 2012)、PatchCamelyon(Veeling等人, 2018)、UCF101动作识别数据集(Soomro等人, 2012)、Kinetics 700(Carreira等人, 2019)、CLEVR数据集的2500个随机样本(Johnson等人, 2017)、恶意表情包数据集(Kiela等人, 2020)以及ImageNet-1k数据集(Deng等人, 2012)。对于两个视频数据集(UCF101和Kinetics700)，我们使用每个视频片段的中间帧作为输入图像。STL-10和UCF101分别有10个和3个预定义的训练/验证/测试划分，我们报告所有划分的平均结果。各数据集详情及相应评估指标见表9。

此外，我们创建了两个数据集，分别命名为Country211和Rendered SST2。Country211数据集旨在评估视觉表征的地理定位能力。我们对YFCC100m数据集(Thome e等人, 2016年)进行了筛选，找出拥有至少300张带GPS坐标照片的211个国家（定义为具有ISO-3166国家代码），并通过为每个国家抽取200张训练照片和100张测试照片，构建了一个包含211个类别的平衡数据集。

渲染后的SST2数据集旨在衡量视觉表征的光学字符识别能力。为此，我们采用了斯坦福情感树库数据集(socher等人, 2013年)中的句子，并将其渲染成图像—白底黑字，分辨率为 448×448 。图19展示了该数据集中的两个示例图像。

A.2. 模型

结合上述数据集，我们使用线性探针评估以下一系列模型。

LM RN50 这是一个多模态模型，采用自回归损失而非对比损失，同时利用 $\{v^*\}$

采用与最小对比模型相同的ResNet-50架构。具体而言，CNN的输出被投影为四个标记，随后作为前缀自回归地输入语言模型以预测文本标记。除训练目标外，该模型与其他CLIP模型在相同数据集上训练了相同周期数。

CLIP-RN 包含五个基于ResNet的对比CLIP模型。如论文所述，前两个模型遵循ResNet-50和ResNet-101架构，而后三个模型则采用EfficientNet风格(Tan & Le, 2019)的缩放策略，同步调整模型宽度、层数和输入分辨率，从而分别获得计算量约为4倍、16倍和64倍的模型。

CLIP-ViT 我们包含了四种采用视觉变换器(Dosovitskiy等人, 2020)架构作为图像编码器的CLIP模型。其中包括三个基于 224×224 像素图像训练的模型：ViT-B/32、ViT-B/16、ViT-L/14，以及一个在 336×336 像素输入图像上微调的ViT-L/14模型。

EfficientNet 我们采用了原始EfficientNet论文(Tan & Le, 2019)中的九种模型(B0-B8)，以及噪声学生变体(B0-B7、L2-475和L2-800)(Tan & Le, 2019)。最大的模型(L2-475和L2-800)分别采用 475×475 和 800×800 像素的输入分辨率。

Instagram预训练的ResNeXt 我们采用(Mahajan等人, 2018)发布的四种模型($32 \times 8d$ 、 $32 \times 16d$ 、 $32 \times 32d$ 、 $32 \times 48d$)，以及它们的两个FixRes变体，后者使用了更高的输入分辨率(Touvron等人, 2019)。

大迁移(BiT) 我们采用了ImageNet-1k和ImageNet-21k数据集上训练的BiT-S与BiT-M模型(Kolesnikov等人, 2019)。BiT-L的模型权重尚未公开。

视觉变换器(ViT) 我们还包含了四个基于ImageNet-21k数据集预训练的ViT(Dosovitskiy等人, 2020)检查点，分别是ViT-B/32、ViT-B/16、ViT-L/16和ViT-H/14。需要注意的是，它们在JFT-300M数据集上训练的最佳性能模型并未公开提供。

SimCLRV2 SimCLRV2(Chen等人, 2020c)项目发布了多种设置下的预训练及微调模型。我们采用了七个仅预训练、带有选择性内核的检查点。

BYOL 我们采用了最近发布的BYOL模型权重(Grill等人, 2020年)，具体是其 50×1 和 200×2 版本



图19. Rendered SST2数据集中的两个示例图像

检查点。

动量对比 (MoCo) 我们包含了 MoCo-v1 (He等人, 2020年) 和 MoCo-v2 (Chen等人, 2020d) 的检查点。

VirTex 我们采用了 VirTex (Desai & Johnson, 2020) 的预训练模型。值得注意的是, VirTex 的模型设计与 CLIP-AR 相似, 但其训练数据集规模小了 1000 倍, 使用的是来自 MSCOCO 的高质量标注数据。

ResNet 我们添加了由 (He et al., 2016b) 发布的原始 ResNet 检查点, 即 ResNet-50、ResNet-101 和 ResNet-152。

A.3. 评估

我们采用从各模型倒数第二层提取的图像特征, 忽略任何提供的分类层。对于 CLIP-ViT 模型, 我们使用了线性投影到嵌入空间前的特征, 即图 3 中的 L_f 。我们使用 scikit-learn 的 L-BFGS 实现训练逻辑回归分类器, 最大迭代次数设为 1,000 次, 并报告各数据集对应的评估指标。通过验证集上的超参数扫描, 我们在 10^{-6} 至 10^6 范围内以 96 个对数间隔步长确定 L2 正则化强度 λ 。为节省扫描计算量, 我们采用参数化二分搜索: 初始以 $\lambda = [10^{-6}, 10^{-4}, 10^{-2}, 1, 10^2, 10^4, 10^6]$ 为起点, 迭代地将峰值周围区间减半, 直至达到每十倍频程 8 步的分辨率。超参数扫描在各数据集的验证集分割上进行。对于除训练集外还包含验证分割的数据集...

在测试集划分方面, 我们利用提供的验证集进行超参数搜索; 对于未提供验证集划分或未公布测试数据标签的数据集, 则通过拆分训练集来完成超参数搜索。最终结果阶段, 我们会将验证集重新合并至训练集, 并基于未使用的划分部分报告性能表现。

A.4. 结果

各线性探针得分详见表 10, 并绘制于图 20 中。表现最佳的 CLIP 模型采用 ViT-L/14 架构和 336×336 像素图像, 在 27 个数据集中的 21 个上达到了当前最优水平, 即其成绩均落入各数据集最高分的 Clopper-Pearson 99.5% 置信区间内。对于多数数据集, CLIP 显著优于其他模型, 这证明了基于自然语言监督的方法相较于传统图像分类预训练方式的优势。关于线性探针结果的更多讨论, 请参阅第 3.2 节。

Dataset	Classes	Train size	Test size	Evaluation metric
Food-101	102	75,750	25,250	accuracy
CIFAR-10	10	50,000	10,000	accuracy
CIFAR-100	100	50,000	10,000	accuracy
Birdsnap	500	42,283	2,149	accuracy
SUN397	397	19,850	19,850	accuracy
Stanford Cars	196	8,144	8,041	accuracy
FGVC Aircraft	100	6,667	3,333	mean per class
Pascal VOC 2007 Classification	20	5,011	4,952	11-point mAP
Describable Textures	47	3,760	1,880	accuracy
Oxford-IIIT Pets	37	3,680	3,669	mean per class
Caltech-101	102	3,060	6,085	mean-per-class
Oxford Flowers 102	102	2,040	6,149	mean per class
MNIST	10	60,000	10,000	accuracy
Facial Emotion Recognition 2013	8	32,140	3,574	accuracy
STL-10	10	1000	8000	accuracy
EuroSAT	10	10,000	5,000	accuracy
RESISC45	45	3,150	25,200	accuracy
GTSRB	43	26,640	12,630	accuracy
KITTI	4	6,770	711	accuracy
Country211	211	43,200	21,100	accuracy
PatchCamelyon	2	294,912	32,768	accuracy
UCF101	101	9,537	1,794	accuracy
Kinetics700	700	494,801	31,669	mean(top1, top5)
CLEVR Counts	8	2,000	500	accuracy
Hateful Memes	2	8,500	500	ROC AUC
Rendered SST2	2	7,792	1,821	accuracy
ImageNet	1000	1,281,167	50,000	accuracy

表9. 线性探针研究的数据集。我们注意到，对于Birdsnap和Kinetics700数据集，我们使用了撰写本文时在线可用的资源。

表10. 多种预训练模型在27个数据集上的线性探测性能。得分位于各数据集最高分99.5% Clopper-Pearson置信区间内的数值以粗体显示。

^{*}We updated the STL10 scores from the previous version of this paper after fixing a CUDA-related bug.

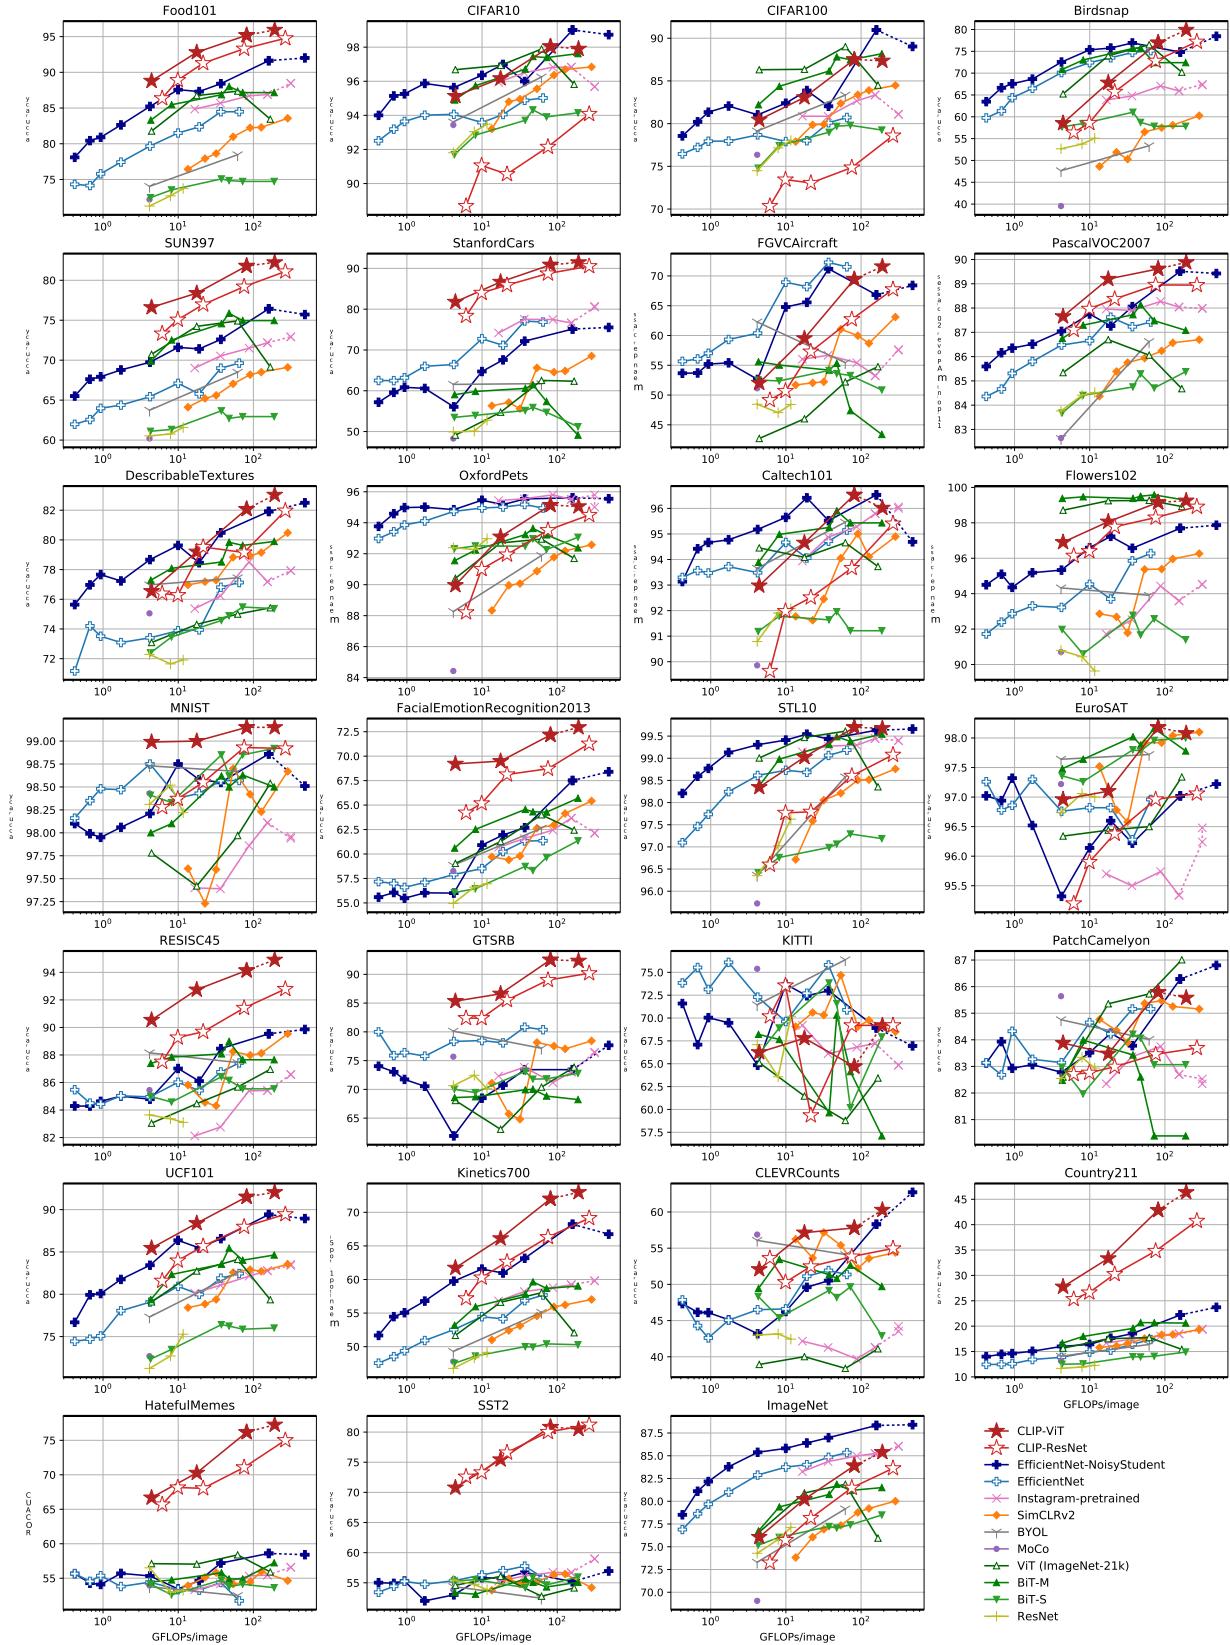


图20. 使用表10中的数据，针对27个数据集分别绘制的线性探针性能图。



图21. 36个CLIP零样本分类器的预测可视化展示。除为避免冒犯性内容而重新筛选的“Hateful Memes”外，所有示例均为随机选取。图中显示前5个类别的预测概率及对应类别的文本描述。当使用多个模板时，仅展示首个模板。真实标签以绿色标注，错误预测则以橙色标示。公式标记 $\{v^*\}$ 保留原样。

		COCO	ImageNet	StanfordCars	FGVC-Aircraft	Flowers102	SUN397	Birdsnap	CIFAR100	CIFAR10	Food101	PascalVOC2007	DescribableTextures	OxfordPets	Caltech101	EuroSAT	RESISC45	GTSRB	KITTI	UCF101	STL10	FacialEmotionRecognition2013	MNIST	KITTI	ImageNet	SST2	HatefulMemes	COCO	ImageNet	StanfordCars	FGVC-Aircraft	Flowers102	SUN397	Birdsnap	CIFAR100	CIFAR10	Food101	PascalVOC2007	DescribableTextures	OxfordPets	Caltech101	EuroSAT	RESISC45	GTSRB	KITTI	UCF101	STL10	FacialEmotionRecognition2013	MNIST	KITTI	ImageNet	SST2	HatefulMemes																																																																																							
N	RN50	81.1	75.6	41.6	32.6	59.6	55.8	19.3	82.1	41.7	85.4	82.1	65.9	66.6	42.2	94.3	41.1	54.2	35.2	42.2	16.1	57.6	63.6	43.5	20.3	59.7	56.9	59.6	RN101	83.9	81.0	49.0	37.2	59.9	62.3	19.5	82.4	43.9	86.2	85.1	65.7	59.3	45.6	96.7	33.1	58.5	38.3	33.3	16.9	55.2	62.2	46.7	28.1	61.1	64.2	62.2	RN50x4	86.8	79.2	48.9	41.6	62.7	67.9	24.6	83.0	49.3	88.1	86.0	68.0	75.2	51.1	96.4	35.0	59.2	35.7	26.0	20.2	57.5	65.5	49.0	17.0	58.3	66.6	65.8	RN50x16	90.5	82.2	54.2	45.9	65.0	72.3	30.3	82.9	52.8	89.7	87.6	71.9	80.0	56.0	97.8	40.3	64.4	39.6	33.9	24.0	62.5	68.7	53.4	17.6	58.9	67.6	70.5	RN50x64	91.8	86.8	61.3	48.9	66.9	76.0	35.6	83.8	53.4	93.4	90.6	77.3	90.8	61.0	98.3	59.4	69.7	47.9	33.2	29.6	65.0	74.1	56.8	27.5	62.1	70.7	73.6
T	B/32	84.4	91.3	65.1	37.8	63.2	59.4	21.2	83.1	44.5	87.0	87.9	66.7	51.9	47.3	97.2	49.4	60.3	32.2	39.4	17.8	58.4	64.5	47.8	24.8	57.6	59.6	63.2	V	B/16	89.2	91.6	68.7	39.1	65.2	65.6	27.1	83.9	46.0	88.9	89.3	70.4	56.0	52.7	98.2	54.1	65.5	43.3	44.0	23.3	48.1	69.8	52.4	23.4	61.7	59.8	68.6	P	L/14	92.9	96.2	77.9	48.3	67.7	77.3	36.1	84.1	55.3	93.5	92.6	78.7	87.2	57.5	99.3	59.9	71.6	50.3	23.1	32.7	58.8	76.2	60.3	24.3	63.3	64.0	75.3	L	L/14-336px	93.8	95.7	77.5	49.5	68.4	78.8	37.2	84.3	55.7	93.5	92.8	78.3	88.3	57.7	99.4	59.6	71.7	52.3	21.9	34.9	63.0	76.9	61.3	24.8	63.3	67.9	76.2																									

表11. CLIP模型在27个数据集上的零样本性能。

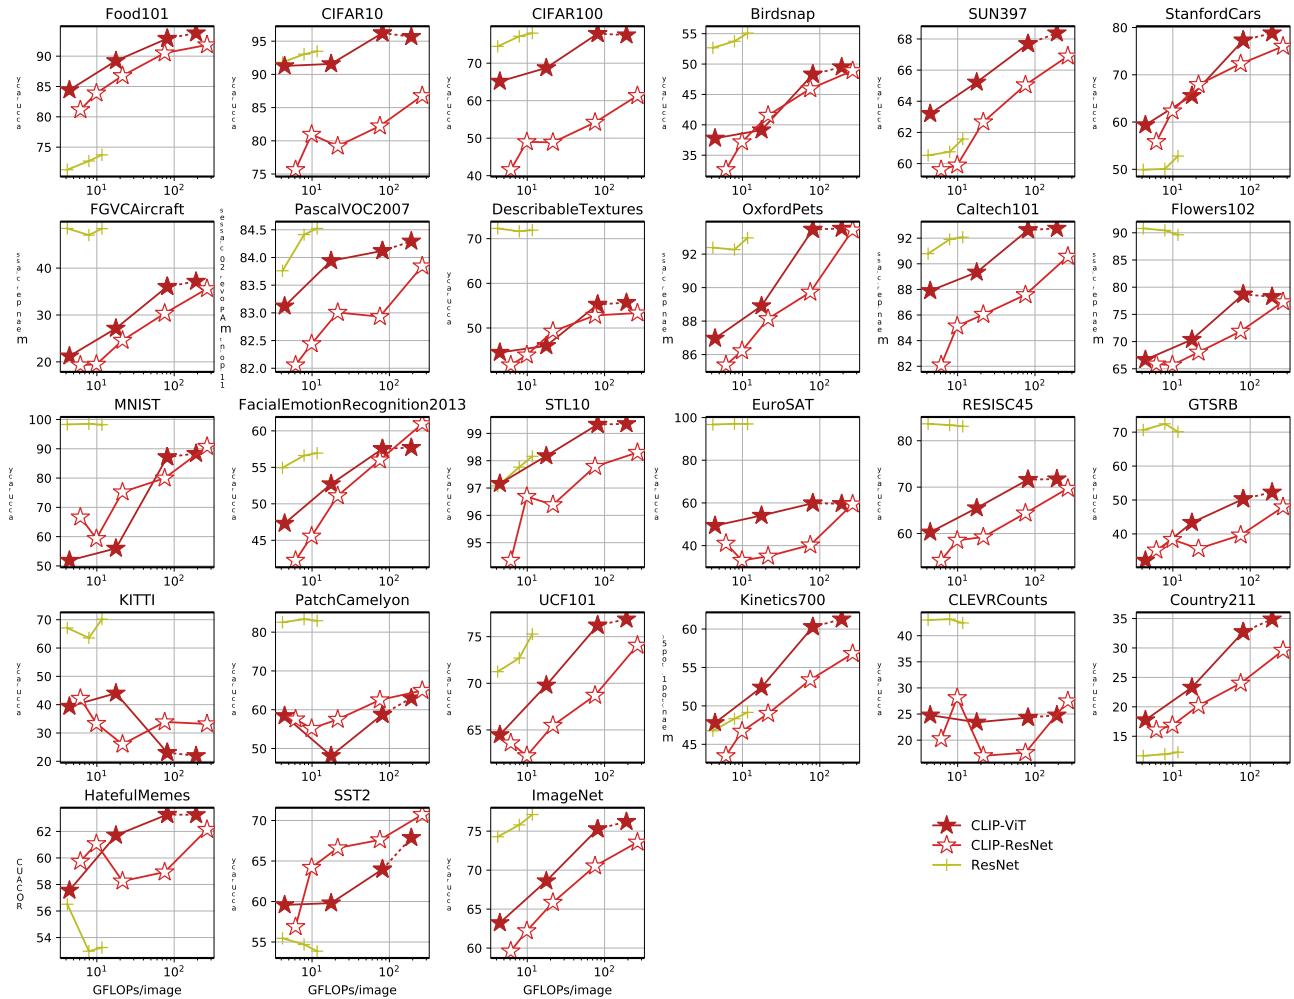


图22. CLIP零样本性能与线性探针ResNet性能对比

B. 零样本预测

为了对CLIP的零样本性能进行定性总结/概述，我们在图21中可视化了36种不同零样本CLIP分类器的随机预测结果。此外，表11和图22展示了各数据集的独立零样本性能得分。

C. 重复检测器

我们早期在重复检测和分析上的尝试，采用了模型学习到的嵌入空间中的最近邻方法。虽然利用模型自身对相似性的理解很直观，但我们遇到了一些问题。我们发现模型的特征空间过于偏重语义相似性，导致许多误判——那些描述相似但实际不同的物体（如足球、同种花卉等）获得了近乎完美的相似度评分。同时，模型在给某些近似重复项分配高相似度分数时表现欠佳。我们多次注意到，经过不同缩放算法（最近邻与双线性）预处理的高频纹理图像（如毛发或条纹图案），其相似度可能低得出人意料，这造成了大量漏检。

我们构建了自己的近重复检测器来解决这一问题。我们创建了一个合成数据增强流程，该流程结合了多种常见的图像处理操作。增强流程包括随机裁剪与缩放、长宽比扭曲、降采样与升采样至不同分辨率、轻微旋转、JPEG压缩以及HSV色彩抖动。此外，该流程还会在所有相关步骤中随机选择不同的插值算法。随后，我们训练了一个模型，旨在最大化图像与其变换版本之间的相似度，同时最小化与训练批次中其他所有图像的相似度。我们采用了与CLIP相同的n-pair/InfoNCE损失函数，但固定温度参数为0.07。

我们选择了ResNet-50作为模型架构。基于Zhang (2019) 提出的抗锯齿改进方案对基础ResNet-50进行了调整，并采用权重归一化 (Salimans & Kingma, 2016) 替代批归一化 (Ioffe & Szegedy, 2015)，以避免通过批次统计信息泄露重复样本的问题——这一问题在Henaff (2020) 中已有指出。我们还发现GELU激活函数 (Hendrycks & Gimpel, 2016) 在该任务中表现更优。模型训练采用总批次大小1,712，从预训练数据集中采样约3,000万张图像进行训练。最终模型在代理训练任务上达到了接近100%的准确率。

Dataset	Linear Classifier			Zero Shot		
	YFCC	WIT	Δ	YFCC	WIT	Δ
Birdsnap	47.4	35.3	+12.1	19.9	4.5	+15.4
Country211	23.1	17.3	+5.8	5.2	5.3	+0.1
Flowers102	94.4	89.8	+4.6	48.6	21.7	+26.9
GTSRB	66.8	72.5	-5.7	6.9	7.0	-0.1
UCF101	69.2	74.9	-5.7	22.9	32.0	-9.1
Stanford Cars	31.4	50.3	-18.9	3.8	10.9	-7.1
ImageNet	62.0	60.8	+1.2	31.3	27.6	+3.7
Dataset Average	65.5	66.6	-1.1	29.6	30.0	-0.4
Dataset “Wins”	10	15	-5	19	18	+1

表12. CLIP仅在YFCC100M上训练时表现相似。将仅在YFCC100M上训练的ResNet-50与WIT相同规模子集进行对比，可见在零样本和线性分类器评估中平均性能与获胜次数相近。然而，具体数据集上的性能差异显著。我们通过线性探针选取YFCC相对于WIT表现最佳和最差的3个数据集展示其性能，同时汇总所有线性与零样本评估及标准ImageNet数据集的整体表现，以突显这一现象。

D. YFCC100M数据集消融实验

为了研究我们的定制数据集对CLIP性能是否至关重要，我们在YFCC100M数据集的一个过滤子集上训练了一个模型（具体细节见第2.2节），并将其性能与在同等规模的WIT子集上训练的相同模型进行了比较。每个模型训练32个周期，此时由于过拟合，迁移性能开始趋于平稳。结果如表12所示。在整个评估套件中，YFCC和WIT在零样本和线性探针设置下的平均表现相似。然而，在特定的细粒度分类数据集上，性能差异可能很大——有时超过10%。我们推测这些性能差异反映了每个预训练数据集中相关数据的相对密度。例如，在YFCC100M上进行预训练（可能包含许多鸟类和花卉的照片，这是摄影师的常见主题）在Birdsnap和Flowers102上表现更好，而在WIT上进行预训练则能获得更好的汽车和宠物分类器（这些在我们的数据集中较为常见）。

总体而言，这些结果令人鼓舞，因为它们表明我们的方法可以利用任何经过合理过滤的（文本、图像）配对数据集合。这与近期在医学影像这一相对不同领域使用相同对比预训练目标取得积极成果的研究相呼应 (Zhang et al., 2020)。该发现也与噪声学生自训练的研究结果相似——当使用其JFT300M数据集与YFCC100M相比时，仅报告了轻微改进 (Xie et al., 2020)。我们推测，相较于现有的YFCC100M数据集，我们的数据集主要优势在于其规模更为庞大。

最后，我们提醒注意，WIT包含了YFCC100M的这一过滤子集。这可能导致我们的消融实验低估了YFCC100M与WIT其余部分之间性能差异的规模。但我们认为这种情况不太可能发生，因为YFCC100M仅占整个WIT数据混合体的3.7%，且在WIT创建过程中将其添加到现有数据混合体时，并未显著改变模型的性能。

E. 选定任务与数据集结果

由于本工作涉及的数据集和实验种类繁多，正文部分主要聚焦于总结和分析整体结果。在接下来的小节中，我们将针对特定任务组、数据集及评估设置详细报告性能表现。

E.1. 图像与文本检索

CLIP针对图像-文本检索任务在我们嘈杂的网络规模数据集上进行了预训练。尽管本文的重点在于表征学习和任务学习，目的是为了迁移到各种下游数据集，但验证CLIP能否在其预训练目标上实现高迁移性能，是一项重要的概念验证/合理性检验。在表13中，我们检查了CLIP在Flickr30k和MSCOCO数据集上对文本和图像检索的零样本迁移性能。零样本CLIP在这两个数据集上达到或超越了所有先前的零样本结果。对于Flickr30k的文本检索任务，零样本CLIP也与当前整体最先进技术（SOTA）具有竞争力。而在图像检索方面，CLIP相对于整体技术水平的性能明显较低。尽管如此，零样本CLIP仍能与经过微调的Unicoder-VL相媲美。在更大的MS-COCO数据集上，微调显著提升了性能，零样本CLIP则无法与最新研究成果竞争。针对这两个数据集，我们在每张图像的描述前添加了提示语“一张照片”，这一操作使CLIP的零样本R@1性能提升了1到2个百分点。

E.2. 光学字符识别

尽管可视化研究表明，ImageNet模型包含对图像中文字存在响应的特征（Zeiler & Fergus, 2014），但这些表征的粒度不足以用于光学字符识别（OCR）任务。为此，模型会通过集成定制OCR引擎的输出和特征来增强性能，以满足需要该能力的任务需求（Singh等人，2019；Yang等人，2020）。在CLIP开发的早期阶段，我们注意到CLIP开始学习初级的OCR能力，这种能力在整个项目过程中持续提升。为了定性评估这一观察到的行为，我们测量了其性能表现

在5个需要直接或间接使用OCR的数据集上进行了测试。其中三个数据集——MNIST（LeCun）、SVHN（Netzer等人，2011年）和IIIT5K（Mishra等人，2012年）——直接检验模型执行低级字符和单词识别的能力，而Hateful Memes（Kiela等人，2020年）和SST-2（Socher等人，2013年）则检验模型利用OCR执行语义任务的能力。结果报告在表14中。

CLIP的表现仍然存在较大波动，且似乎对领域（渲染图像或自然图像）与待识别文本类型（数字或单词）的某种组合较为敏感。CLIP的OCR能力在Hateful Memes和SST-2数据集上表现最佳——这些数据集的文本均为数字渲染且主要由单词构成。在IIIT5K（由自然图像中单独裁剪的单词组成）上，零样本CLIP的表现相对略好，其性能与Jaderberg等人（2014年）将深度学习与结构化预测相结合进行开放词汇OCR的早期工作相近。然而，在涉及手写数字和街景数字识别的两个数据集上，CLIP的表现明显较差。CLIP在完整数字SVHN数据集上51%的准确率远低于任何已发表结果。观察表明，CLIP在处理重复字符以及SVHN低分辨率模糊图像时存在困难。CLIP的零样本MNIST表现同样不佳，甚至逊色于基于原始像素的监督逻辑回归——这一最简单的机器学习基线方法之一。

SST-2是一个句子级别的自然语言处理数据集，我们将其转化为图像形式。引入SST-2旨在验证CLIP能否将底层OCR能力转化为更高层次的表征。在CLIP生成的句子图像表征上拟合线性分类器，准确率达到80.5%，这与采用8400亿token预训练GloVe词向量的连续词袋基线模型（Pennington等人，2014）80%的准确率相当。虽然以现今标准看这只是简单的NLP基线，远低于当前最优方法97.5%的水平，但CLIP能将文本图像转化为有效的句子级表征已令人鼓舞。完全监督的CLIP在恶意表情包检测任务中表现同样惊人，仅比当前单模型最优结果低0.7分，且显著超越原论文最佳基线数分。与SST-2类似，这些恶意表情包实验结果也使用了CLIP无法接触的真实文本数据。最后我们发现，零样本CLIP在我们评估套件涵盖的其余56个模型上，全面超越了全监督线性探针的最佳结果。这表明相比现有自监督与监督表征学习研究，CLIP的OCR能力至少具备一定独特性。

	Text Retrieval						Image Retrieval						
	Flickr30k			MSCOCO			Flickr30k			MSCOCO			
	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	R@1	R@5	R@10	
en n u e n F	Unicoder-VL ^a	86.2	96.3	99.0	62.3	87.1	92.8	71.5	90.9	94.9	46.7	76.0	85.3
	Uniter ^b	87.3	98.0	99.2	65.7	88.6	93.8	75.6	94.1	96.8	52.9	79.9	88.0
	VILLA ^c	87.9	97.5	98.8	-	-	-	76.3	94.2	96.8	-	-	-
	Oscar ^d	-	-	-	73.5	92.2	96.0	-	-	-	57.5	82.8	89.8
	ERNIE-ViL ^e	88.7	98.0	99.2	-	-	-	76.7	93.6	96.4	-	-	-
t o h S o z	Visual N-Grams ^f	15.4	35.7	45.1	8.7	23.1	33.3	8.8	21.2	29.9	5.0	14.5	21.9
	ImageBERT ^g	-	-	-	44.0	71.2	80.4	-	-	-	32.3	59.0	70.2
	Unicoder-VL ^a	64.3	86.8	92.3	-	-	-	48.4	76.0	85.2	-	-	-
	Uniter ^b	83.6	95.7	97.7	-	-	-	68.7	89.2	93.9	-	-	-
	CLIP	88.0	98.7	99.4	58.4	81.5	88.1	68.7	90.6	95.2	37.8	62.4	72.2

表13. CLIP提升了零样本检索性能，并在Flickr30k文本检索任务上与最佳微调结果相当。加粗表示整体最佳性能，下划线则表示类别内最佳性能（零样本或微调）。对于其他所有模型，无论模型规模/变体如何，均报告论文中的最佳结果。MSCOCO性能基于5k测试集报告。^a(Li等, 2020a) ^b(Chen等, 2019) ^c(Gan等, 2020) ^d(Li等, 2020b) ^e(Yu等, 2020) ^f(Li等, 2017) ^g(Qi等, 2020)

	IIIT5K				
	MNIST	SVHN	1k	Memes	SST-2
SOTA	99.8^a	96.4^b	98.9^c	78.0^d	97.5^e
JOINT ^f	-	-	89.6	-	-
CBoW ^g	-	-	-	-	80.0
Raw Pixels	92.5	-	-	-	-
ES Best	98.9 ^h	-	-	58.6 ^h	59.0 ⁱ
CLIP	99.2	-	-	77.3	80.5
CLIP	88.4	51.0	90.0	63.3	67.9

表14. 五个数据集上的OCR性能表现。除Hateful Memes采用开发集ROC AUC指标外，其余均报告测试集准确率。单模型SOTA结果为当前已知最佳。ES Best展示了我们评估套件中5个非CLIP模型中的最优性能。^a(Assiri, 2020) ^b(Jaderberg等, 2015) ^c(Wang等, 2020) ^d(Lippe等, 2020) ^f(Jaderberg等, 2014) ^g(Wang等, 2018) ^h(Xie等, 2020) ⁱ(Mahajan等, 2018)

E.3. 视频中的动作识别

就学习目的而言，自然语言一个潜在的重要特性是其能够表达并监督极其广泛的概念集合。CLIP模型由于训练时将半任意文本与图像配对，很可能接收到涉及普通名词、专有名词、动词和形容词的广泛视觉概念的监督信号。相比之下，ImageNet-1K仅标注普通名词。ImageNet中更广泛监督信号的缺失，是否会导致其模型在涉及非名词类视觉概念识别任务时迁移性能较弱？

为了探究这一点，我们测量并比较了CLIP与ImageNet模型在多个视频上的性能表现

	UCF101		K700		RareAct	
	Top-1	AVG	mWAP	mWSAP		
R(2+1)D-BERT ^a	98.7	-	-	-		
NS ENet-L2 ^b	-	84.8	-	-		
HT100M S3D ^d	91.3	-	-	-		
Baseline I3D ^e	-	70.2	-	-		
MMV FAC ^f	91.8	-	-	-		
NS ENet-L2 ^c	89.4 ^c	68.2 ^c	-	-		
CLIP	92.0	73.0	-	-		
HT100M S3D ^d	-	-	30.5	34.8		
CLIP	80.3	69.6	40.7	44.8		

表15. 三个视频数据集上的动作识别性能。单模型SOTA结果据我们所知为最佳。需注意，linear、CLIP和linear NS ENet-L2是在每个数据集的单帧降采样版本上训练和评估的，与先前工作不直接可比。在Kinetics-700上，我们报告ActivityNet竞赛指标，即top-1与top-5性能的平均值。^a(Kalafaglu等人, 2020) ^b(Lu等人, 2020) ^c(Xie等人, 2020) ^d(Miech等人, 2020b) ^e(Carreira等人, 2019) ^f(Alayrac等人, 2020)

动作分类数据集用于衡量模型识别动词的能力。在表15中，我们报告了UCF-101 (Soomro等人, 2012年) 和Kinetics-700 (Carreira等人, 2019年) 这两个该任务常用数据集上的结果。遗憾的是，由于训练帧数量极其庞大，我们基于CPU的线性分类器在视频数据集上的评估耗时过长。为解决这一问题，我们采取了激进的下采样策略，将每段视频仅保留中间一帧，实质上将其转化为图像分类数据集。因此，在线性评估设置下报告的性能可能被适度低估。

	IN Top-1	IN-V2 Top-1	IN-A Top-1	IN-R Top-1	ObjectNet Top-1	IN-Sketch Top-1	IN-Vid PM0	IN-Vid PM10	YTBB PM0	YTBB PM10
NS EfficientNet-L2 ^a	88.3	80.2	84.9	74.7	68.5	47.6	88.0	82.1	67.7	63.5
FixResNeXt101-32x48d V2 ^b	86.4	78.0	68.4	80.0	57.8	59.1	85.8	72.2	68.9	57.7
Linear Probe CLIP	85.4	75.9	75.3	84.2	66.2	57.4	89.1	77.2	68.7	63.1
Zero-Shot CLIP	76.2	70.1	77.2	88.9	72.3	60.2	95.3	89.2	95.2	88.5

表16. ImageNet鲁棒性性能详表。IN为ImageNet的缩写。^a(Xie等人, 2020) ^b(Touvron等人, 2019)

尽管存在这一局限, CLIP特征在此任务中的迁移表现却出奇地好。在线性探针评估设置下, CLIP在UCF-101数据集上追平了先前的最佳结果, 同时在我们评估套件中的所有其他模型中也表现更优。在Kinetics-700数据集上, CLIP同样超越了原论文中经过微调的I3D基线模型。由于无需训练阶段, 我们报告了CLIP在平均所有帧预测时的零样本性能。在此设置下, CLIP表现依然出色, 在Kinetics-700上的性能与完全监督的I3D基线(基于545,000个标注视频训练)仅相差1%。受这些结果的鼓舞, 我们还测量了CLIP在最新提出的RareAct数据集(Miech等人, 2020a)上的表现, 该数据集专为测试非常规动作(如“用锤子砸手机”“在鸡蛋上钻孔”)的零样本识别能力而设计。CLIP将此前基于1亿条教学视频自动提取字幕训练的S3D模型的最佳水平提升了10个百分点。

尽管CLIP在动作识别任务上表现出了令人鼓舞的强大性能, 但我们注意到, 被比较模型之间除了监督形式外, 还存在诸多差异, 如模型架构、训练数据分布、数据集规模以及所使用的计算资源等。要更精确地确定哪些具体设计决策有助于在该任务上实现高性能, 还需要进一步的研究工作。

E.4. 地理定位

在开发CLIP过程中, 我们注意到的另一个现象是其对众多地点与位置的识别能力。为量化这一特性, 我们如附录A所述创建了Country211数据集, 并在全文中报告相关结果。由于这是一个新基准, 为与先前地理定位研究进行对比, 我们还在表17中汇报了基于Hays & Efros (2008)的IM2GPS测试集结果。鉴于IM2GPS属于回归基准任务, 我们利用CLIP的嵌入空间预测了参考图像集中最近邻图像的GPS坐标。由于采用了最近邻回归方法, 该结果不属于零样本范畴。尽管仅查询了100万张图像(远少于先前研究), CLIP的表现仍与多个专用模型相当。不过, 其性能尚未达到当前最先进水平。

E.5. 对分布偏移的鲁棒性

3.3节对ImageNet相关鲁棒性结果进行了高层级概述与分析。本附录简要补充部分数值细节。各数据集性能结果详见表16, 并与Taori等人(2020)评估套件中报告的当前最优结果进行对比。零样本CLIP在7个数据集中的5个上实现了性能突破, 包括ImageNet-R、ObjectNet、ImageNet-Sketch、ImageNet-Vid和Youtube-BB。得益于其灵活的零样本能力, CLIP在ImageNet-Vid和Youtube-BB上的提升最为显著; 而在ImageNet-R上的优势, 可能源于CLIP预训练数据分布中包含大量创意内容。类似现象在Taori等人(2020)讨论的Instagram预训练ResNeXt模型中亦有记载。

	1km	25km	200km	750km	2500km
ISNs ^a	16.9	43.0	51.9	66.7	80.2
CPlaNet ^b	16.5	37.1	46.4	62.0	78.5
CLIP	13.9	32.9	43.0	62.0	79.3
Deep-Ret+ ^c	14.4	33.3	47.7	61.6	73.4
PlaNet ^d	8.4	24.5	37.6	53.6	71.3

表17. IM2GPS测试集上的地理定位性能。指标为在给定半径内定位成功的图像百分比。模型按平均性能排序。^a(Muller-Budack等人, 2018) ^b(Hongseok Seo等人, 2018) ^c(Vo等人, 2017) ^d(Weyand等人, 2016)

F. 模型超参数

Hyperparameter	Value
Batch size	32768
Vocabulary size	49408
Training epochs	32
Maximum temperature	100.0
Weight decay	0.2
Warm-up iterations	2000
Adam β_1	0.9
Adam β_2	0.999 (ResNet), 0.98 (ViT)
Adam ϵ	10^{-8} (ResNet), 10^{-6} (ViT)

表18. 常见的CLIP超参数

Model	Learning rate	Embedding dimension	Input resolution	ResNet blocks	width	Text layers	Transformer width	heads
RN50	5×10^{-4}	1024	224	(3, 4, 6, 3)	2048	12	512	8
RN101	5×10^{-4}	512	224	(3, 4, 23, 3)	2048	12	512	8
RN50x4	5×10^{-4}	640	288	(4, 6, 10, 6)	2560	12	640	10
RN50x16	4×10^{-4}	768	384	(6, 8, 18, 8)	3072	12	768	12
RN50x64	3.6×10^{-4}	1024	448	(3, 15, 36, 10)	4096	12	1024	16

表19. CLIP-ResNet超参数

Model	Learning rate	Embedding dimension	Input resolution	Vision layers	Transformer width	heads	Text layers	Transformer width	heads
ViT-B/32	5×10^{-4}	512	224	12	768	12	12	512	8
ViT-B/16	5×10^{-4}	512	224	12	768	12	12	512	8
ViT-L/14	4×10^{-4}	768	224	24	1024	16	12	768	12
ViT-L/14-336px	2×10^{-5}	768	336	24	1024	16	12	768	12

表20. CLIP-ViT超参数